

南京工业大学

2026 届毕业设计（论文）

题 目： 融合KNN与YOLOv8的智能牧

场牲畜计数与行为监测系统

专 业： 自动化

班 级： 自 2203

姓 名： 余涛

指导老师： 肖迪

起讫日期： 2025.12-2026.6

2026 年 05 月

南京工业大学本科毕业设计（论文）原创性声明

本人郑重声明：所呈交的毕业设计（论文），是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的作品成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

论文作者签名：

日期：2026 年 5 月 26 日

南京工业大学本科毕业设计（论文）使用授权声明

本学位论文作者完全了解学校有关保留、使用毕业设计（论文）的规定，同意学校保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。本人授权南京工业大学教务处可以将本毕业设计（论文）的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编毕业设计（论文）。

论文作者签名：

导师签名：

日期：2026 年 5 月 26 日

日期：2026 年 5 月 26 日

融合 KNN 与 YOLOv8 的智能牧场牲畜计数与行为监测系统

摘 要

牧场监控场景中常存在牛只遮挡、目标外观相似以及站立与行走行为区分困难等问题，容易造成计数误差和行为识别结果不稳定。针对上述问题，本文设计并实现了一种融合 YOLOv8、DeepSORT 与 KNN 的牲畜计数与行为监测方法。

方法以 YOLOv8 为检测基线，采用多动物数据集预训练结合牛只数据集微调的迁移学习策略完成目标定位与计数；引入 DeepSORT 实现帧间身份关联与轨迹获取；对检测到的牛只区域提取 HOG 与边界框长宽比特征，利用 KNN 分类器识别卧躺、站立、行走三类基础姿态。针对站立与行走在单帧中易混淆的问题，结合连续帧中心点位移进行动量修正，以抑制短时跳变；进一步结合牧场功能区域与停留时间设计区域语义规则，将基础姿态映射为采食、饮水、休息等管理行为。实验表明，迁移训练后 YOLOv8 的 mAP@0.5 达 0.9018，KNN 行为分类准确率为 87.96%，动量修正有效增强了视频行为识别的时序一致性。

本文还实现了一套 Web 端牧场行为监测系统，集成了实时监控、事件记录、异常告警与历史分析等功能，验证了方法的工程可行性。

关键词：牛只检测；行为监测；YOLOv8；KNN；DeepSORT

Intelligent Pasture Livestock Counting and Behavior Monitoring System

Integrating KNN and YOLOv8

Abstract

In pasture monitoring scenarios, cattle occlusion, similar target appearances, and the difficulty of distinguishing standing from walking often lead to counting errors and unstable behavior recognition. To address these problems, this paper designs and implements a livestock counting and behavior monitoring method that integrates YOLOv8, DeepSORT, and KNN. YOLOv8 serves as the detection baseline, with a transfer learning strategy—pretraining on a multi-animal dataset followed by fine-tuning on a cattle dataset—used to perform object localization and counting. DeepSORT is introduced for inter-frame identity association and trajectory acquisition. For each detected cattle region, HOG features and bounding box aspect ratios are extracted and fed into a KNN classifier to recognize three basic postures: lying, standing, and walking. To mitigate the confusion between standing and walking in single frames, center-point displacement across consecutive frames is used for momentum correction to suppress short-term label flickering. Furthermore, regional semantic rules that incorporate pasture functional zones and dwell time are designed to map basic postures to management-relevant behaviors such as feeding, drinking, and resting. Experimental results show that the transfer-trained YOLOv8 achieves an mAP@0.5 of 0.9018, the KNN classifier attains an overall accuracy of 87.96%, and the momentum correction mechanism effectively improves the temporal consistency of video-based behavior recognition.

A web-based pasture behavior monitoring system is also implemented, integrating real-time monitoring, event recording, anomaly alerting, and historical analysis, thereby validating the engineering feasibility of the method.

Key Words: cattle detection; behavior monitoring; YOLOv8; KNN; DeepSORT

目 录

摘 要	I
Abstract	II
第一章 绪论	1
1.1 研究背景与意义	1
1.2 牧场牲畜计数与行为监测研究内容与现状	1
1.2.1 牧场牲畜计数与行为监测研究发展历程	2
1.2.2 国内外研究现状	2
1.3 研究目标与技术路线	4
1.4 论文的结构安排	4
第二章 相关理论基础	5
2.1 YOLOv8 目标检测算法原理	5
2.2 目标跟踪相关理论	7
2.3 KNN 分类算法原理	9
2.4 本章小结	10
第三章 基于 YOLOv8 与 KNN 的融合检测方法	12
3.1 整体方法设计	12
3.2 YOLOv8 牛只检测与计数方法	13
3.2.1 迁移训练策略	13
3.2.2 检测结果筛选	13
3.3 DeepSORT 多目标跟踪方法	14
3.4 KNN 基础行为分类方法	15
3.5 视频动量修正方法	16
3.5.1 连续帧运动量计算	16
3.5.2 行为修正规则	16
3.6 区域语义行为细分方法	17
3.7 本章小结	18
第四章 实验结果与分析	19
4.1 实验环境	19

4.2 数据集构建	19
4.3 评价指标	21
4.4 实验结果与分析	22
4.4.1 YOLOv8牛只检测与计数实验结果	22
4.4.2 KNN基础行为分类实验结果	26
4.4.3 视频动量修正实验结果	29
4.4.4 区域语义行为细分功能验证	32
4.5 本章小结	32
第五章 牧场牲畜计数与行为监测平台设计与实现	34
5.1 系统需求分析	34
5.2 系统总体设计	34
5.2.1 系统总体架构	34
5.2.2 系统功能模块设计	35
5.3 系统功能实现	36
5.3.1 用户登录模块	36
5.3.2 设备管理模块	36
5.3.3 实时监控模块	37
5.3.4 区域管理与行为细分模块	37
5.3.5 行为事件与告警模块	38
5.3.6 历史数据分析模块	39
5.4 系统运行测试	39
5.5 本章小结	40
第六章 总结与展望	41
6.1 总结	41
6.2 展望	41
参考文献	43
致 谢	46

第一章 绪论

1.1 研究背景与意义

畜牧业是农业生产体系的重要组成部分，牛只养殖规模的扩大使牧场管理逐渐从经验式管理转向数据化、自动化和智能化管理^[1]。传统人工巡检方式难以满足全天候、连续性监测的需求，而基于视觉的自动监测方法具有非接触、覆盖广、可追溯的优势，正成为智慧牧场建设的重要技术支撑^[2-3]。

牛只行为与健康状态、采食饮水情况、发情状态和疾病风险密切相关。卧躺时间、行走频率、长时间停留、采食和饮水行为的变化，往往能够反映个体健康和群体管理状态。通过视觉监控自动识别牲畜数量与行为类别，牧场管理人员便能及时掌握牛群状态，并在异常发生时快速处理，从而降低人工巡检压力，提高养殖管理效率^[4-6]。

近年来，深度学习和计算机视觉技术快速发展，目标检测算法在畜牧养殖等领域的应用日益广泛。基于深度学习的目标检测方法因其检测速度快、实时性好，适用于牧场视频监控场景。与此同时，传统机器学习分类方法具有实现简单、训练成本低和可解释性较强的优点，适合在样本规模有限的情况下完成行为判别。将深度目标检测能力与传统分类方法结合，有望形成从目标定位、数量统计到行为识别的完整流程^[7-8]。




图 1-1 智慧牧场监控应用场景

基于上述背景，本文围绕牧场牲畜计数与行为监测需求展开研究，旨在探索一种适合规模化牧场部署的视觉监测技术方案。

1.2 牧场牲畜计数与行为监测研究内容与现状

1.2.1 牧场牲畜计数与行为监测研究发展历程

早期牧场管理主要依靠人工巡检完成牲畜计数和行为观察。这种方式操作简单，但受工作人员经验、巡检频率和观察范围影响较大，难以满足规模化养殖场全天候、精细化管理的需求。随着养殖规模扩大，人工巡检容易出现漏看、误判和记录不及时等问题，特别是在夜间、恶劣天气或牛只密集活动场景下，人工方式的局限性更加明显。

随后，以电子耳标、项圈、计步器为代表的接触式传感监测方案进入牧场。其优势在于可直接获取个体身份与活动量，在精准度上优于人工巡检。然而，这类方案始终面临‘穿戴成本’这个根本难题——设备采购、定期维护、电池更换以及牲畜佩戴舒适性均是规模化推广的阻碍。更关键的是，设备易因牲畜争斗、刮蹭而脱落损坏，导致数据断流。因此，接触式方案更多作为小范围精准监测的补充手段，难以成为大牧场低成本覆盖的主流选择。

随着摄像头设备和图像处理技术的发展，基于视觉的非接触式监测方法逐渐成为研究热点。传统视觉方法主要利用背景建模、背景减除、边缘检测、颜色分割和手工特征提取等方法识别牲畜目标^[9]。这类方法实现相对简单，计算量较小，但对光照变化、背景复杂度、目标遮挡和拍摄角度较为敏感，在真实牧场环境中的稳定性有限。

近年来，深度学习目标检测算法快速发展，推动牧场监测研究从传统图像处理方法逐渐转向智能化检测方法。YOLO 系列算法由于检测速度快、实时性较好，逐渐被应用于牛只检测、数量统计和行为监测任务中^[10]。同时，研究者还通过引入注意力机制、多尺度特征融合、轻量化网络结构和目标跟踪算法，提升模型在复杂牧场环境下的检测效果。行为识别方面，也逐渐由单帧图像分类发展到结合连续帧运动信息、目标轨迹和活动区域的综合判断方法。

1.2.2 国内外研究现状

在国外研究方面，牧场牲畜监测研究主要集中在复杂环境下的目标检测、个体跟踪和行为分析^[11]。由于真实牧场中存在光照变化、牛只遮挡、背景复杂、目标尺度差异较大等问题^[12]，许多研究在 YOLO 等目标检测模型基础上进行改进，以增强模型对牛只目标的识别能力。例如，部分研究将注意力机制引入检测网络，使模型更加关注牛只关键区域^[13]；也有研究将目标检测算法与 DeepSORT 等多目标跟踪算法结合，用于保持连续视频中牛只身份的一致性，从而减少重复计数和目标丢失问题^[14]。此外，一些研究还尝试使用 Transformer、时序网络等方法，对牛只运动过程和行为变化进行建模，提高复杂行为识别的准确率^[15-16]。

在国内研究方面，相关研究更多关注模型的检测精度、实时性和部署可行性。针对牧场环境中遮挡严重、夜间光照不足、背景干扰较多等问题，国内学者通常采用轻量化网络、通道剪枝、多尺度特征融合和改进检测头等方法，对 YOLO 系列模型进行优化^[17]。这类方法能够在保证检测效果的同时减少模型参数量^[18]，提高模型在实际监控设备或边缘计算设备上的运行效率^[19]。与此同时，将目标检测与目标跟踪^[20]、区域判断和行为分类方法^[21]结合，也成为国内智慧牧场研究中的重要方向，可用于实现牲畜计数、行为监测和异常状态预警^[22-23]。

在行为识别方面，现有研究主要围绕站立、行走、卧躺、采食、饮水、发情和跛行等行为展开^[24]。对于站立、卧躺等姿态差异较明显的行为，可以通过目标外观特征和姿态信息进行判断^[25]；而对于行走、采食和饮水等行为，则往往需要结合目标运动轨迹、活动区域和连续帧变化进行分析。近年来，也有研究尝试采用端到端的行为检测方法^[26-27]，即通过统一模型直接完成目标定位和行为类别识别^[28]。该类方法减少了多阶段处理流程，在视频行为理解方面具有一定优势，但通常对数据规模、训练成本和算力资源要求较高，在实际牧场部署中仍面临一定限制。

总体来看，牧场牲畜计数与行为监测研究已经取得了一定成果，但仍存在一些问题。当前研究仍面临若干瓶颈。其一，单一检测模型虽能完成目标定位，但在遮挡、密集及连续视频场景下，漏检与重复计数问题突出。其二，牛只行为具有连续性与外观相似性——站立与行走在单帧图像中差异微弱，仅凭静态特征极易发生误判。其三，行为识别层面，端到端方法虽可覆盖采食、饮水等细分行为，但对数据规模和算力资源要求较高，难以在牧场边缘设备上轻量化部署；而目前多数轻量方法仅输出卧躺、站立、行走等基础姿态标签，未进一步利用牧场功能区域信息将检测结果映射为采食、饮水、休息等具有管理语义的细分行为。从检测结果到牧场管理决策之间仍缺少一个低成本的语义转换层。

1.3 研究目标与技术路线

针对上述问题，本文的研究目标为：设计一种轻量、可部署的视觉监测方法，实现对牧场牛只的准确计数与稳定行为识别，并将基础姿态提升为具有管理意义的细分行为，同时构建配套的 Web 端监控系统以验证方法的工程可行性。

围绕这一目标，本文的技术路线遵循“检测—跟踪—分类—修正—细分—系统”六个环节逐层推进：检测环节完成牛只目标定位与数量统计；跟踪环节在视频帧间建立牛只身份关联；分类环节对单只牛进行基础姿态识别；修正环节利用时序运动信息抑制站立与行走之间的短时误判；细分环节结合牧场功能区域将基础姿态映射为采食、饮水、休息等管理行为；系统环节将上述算法封装为可交互的 Web 监控平台。第二章与第三章将分别介绍各环节的理论基础和具体方法设计。

1.4 论文的结构安排

本文围绕智慧牧场场景下的牲畜计数与行为监测问题展开研究，全文共分为六章，具体安排如下。

第一章：介绍课题研究背景与意义，梳理牧场牲畜计数与行为监测的发展历程和国内外研究现状，明确本文的研究目标与技术路线。

第二章：介绍YOLOv8目标检测算法、DeepSORT多目标跟踪算法及KNN分类算法的核心原理，为后续方法设计提供理论支撑。

第三章：介绍本文整体算法流程，包括基于 YOLOv8 的牛只检测与计数、基于 DeepSORT 的多目标跟踪与帧间身份关联、基于 KNN 的基础行为分类、连续帧动量修正以及基于区域语义的采食、饮水、休息等行为细分方法。

第四章：介绍实验环境、数据集构建和评价指标，对牛只检测、基础行为分类和视频动量修正进行定量实验分析，并对区域语义细分模块的设计逻辑与工程实现予以说明。

第五章：介绍智慧牧场监控系统的需求分析、总体架构、功能模块设计与实现过程，并展示系统运行效果。

第六章：总结本文主要工作，分析研究中存在的不足，并对后续优化方向进行展望。

第二章 相关理论基础

2.1 YOLOv8 目标检测算法原理

YOLOv8 是 YOLO 系列目标检测算法中的一种代表性模型，属于单阶段目标检测算法。单阶段目标检测算法不需要单独生成候选区域，而是直接在输入图像上完成目标类别预测和边界框回归，因此具有检测速度快、结构紧凑、实时性较好的特点。YOLOv8 在继承 YOLO 系列算法高效检测思想的基础上，对网络结构、检测头和损失函数等部分进行了优化，使其在检测精度和推理速度之间具有较好的平衡^[29]。

YOLOv8 的整体检测流程主要包括图像输入、特征提取、特征融合、检测预测和后处理几个阶段。输入图像首先经过尺寸调整、归一化等预处理操作，然后送入神经网络进行特征提取。网络输出目标边界框、类别概率和置信度信息，经后处理得到最终检测结果。




图 2-1 YOLOv8 目标检测流程

YOLOv8 的网络结构通常由 Backbone、Neck 和 Head 三个部分组成。Backbone 是主干特征提取网络，主要用于提取图像中的颜色、纹理、边缘、形状和语义特征。随着网络层数逐渐加深，特征图尺寸不断减小，但语义表达能力逐渐增强。浅层特征包含更多细节信息，深层特征则包含更强的目标语义信息。

Neck 是特征融合网络，主要用于融合不同层级的特征图。目标检测任务中，目标尺度可能存在较大差异，小目标更依赖浅层细节特征，大目标更依赖深层语义特征。通过多尺度特征融合，模型能够同时利用不同层级的信息，提高对不同大小目标的检测能力。YOLOv8 中的 Neck 结构通常结合特征金字塔思想，将高层语义信息与低层细节信息进行融合，从而增强网络的多尺度检测能力。

Head 是检测头部分，负责输出最终预测结果。YOLOv8 采用解耦检测头，分类分支和回归分支分别负责类别预测与边界框定位，减少了分类与定位任务之间的相互干扰，有助于提高检测精度。




图 2-2 YOLOv8 网络结构

YOLOv8 的一个重要特点是采用 Anchor-Free 检测思想。传统基于 Anchor 的检测算法需要预先设置不同尺度和比例的锚框，然后在锚框基础上进行目标预测。Anchor-Free 方法不依赖预设锚框，而是直接预测目标中心点和边界框位置，减少了手动设置锚框参数的过程，也提高了模型对不同数据集的适应性。

在边界框预测完成后，模型通常会产生多个候选检测框。为了避免同一目标被多个检测框重复表示，需要使用非极大值抑制方法进行后处理。非极大值抑制的基本思想是：先选择置信度最高的检测框，然后计算其与其他检测框的重叠程度，若重叠程度超过设定阈值，则删除置信度较低的重复检测框。检测框之间的重叠程度通常通过交并比表示，其计算公式为：

$$IoU = \frac{A \cap B}{A \cup B} \quad (2-1)$$

其中， A 和 B 表示两个检测框区域， $A \cap B$ 表示两个检测框的交集面积。 $A \cup B$ 表示两个检测框的并集面积。 IoU 值越大，说明两个检测框重叠程度越高。

YOLOv8 的训练过程通常涉及分类损失、边界框回归损失和分布焦点损失等内容。分类损失用于衡量类别预测结果与真实类别之间的差异，边界框回归损失用于衡量预测框与

真实框之间的位置差异，分布焦点损失用于提高边界框定位的精细程度。通过多种损失函数共同约束，模型能够同时提升分类准确性和定位精度。

目标检测解决了单帧图像中目标的定位与识别问题，但在视频场景下，相邻帧之间的目标缺乏身份关联，无法获知同一牛只在时间维度上的运动轨迹和行为变化。目标跟踪算法的作用正是在连续视频帧之间建立目标身份对应关系，使系统能够追踪每个牛只的完整活动过程。以下介绍目标跟踪的基本理论和本文所使用的 DeepSORT 算法。


2.2 目标跟踪相关理论

目标跟踪是视频分析中的重要研究方向，其任务是在连续视频帧中确定目标的位置变化，并保持目标身份的一致性。目标检测只关注单帧图像中的目标位置和类别，而目标跟踪则进一步关注目标在时间维度上的连续变化。多目标跟踪需要同时处理多个目标的检测框匹配、轨迹更新、目标遮挡、目标消失和重新出现等问题。

随着目标检测算法的发展，当前多目标跟踪中常见的方法是 Tracking-by-Detection，即先对每一帧进行目标检测，再根据检测结果完成目标关联和轨迹维护。

DeepSORT 是多目标跟踪领域中常用的算法之一，它是在 SORT 算法基础上改进得到的。SORT 算法主要由卡尔曼滤波和匈牙利算法组成，具有计算速度快、结构简单的特点。卡尔曼滤波用于预测目标在下一帧中的位置，匈牙利算法用于完成当前帧检测框与已有轨迹之间的匹配，其本质是求解一个二分图的最优指派问题——将检测框集合与轨迹集合视为二分图的两侧节点，以运动距离或 IoU 为匹配代价，寻找使总代价最小的匹配方案。SORT 虽然速度较快，但主要依赖运动信息和检测框重叠关系，当目标发生遮挡、交叉或短暂丢失时，容易出现目标 ID 切换问题^[30-31]。

DeepSORT 在 SORT 的基础上引入了深度外观特征，使目标匹配不仅依赖位置信息，还可以利用目标的外观相似度。通过结合运动特征和外观特征，DeepSORT 能够在目标遮挡、目标交叉等复杂场景中更好地保持身份一致性。



DeepSORT的核心流程涵盖检测输入、运动预测、外观特征提取、数据关联和轨迹管理五个阶段。检测器输出当前帧中的目标检测框后，卡尔曼滤波器依据已有轨迹状态预测目标在当前帧中的位置；外观特征提取网络对检测框区域提取特征向量，用于描述目标外观；算法随后综合运动距离与外观距离进行匹配；最终根据匹配结果更新已有轨迹、创建新轨迹或删除失效轨迹。

卡尔曼滤波是 DeepSORT 中进行运动预测的重要方法。它通过目标过去的状态估计当前状态，并根据新的检测结果不断修正预测值。DeepSORT 中常用的目标状态向量可表示为：

$$X=(x,y,a,h,\dot{x},\dot{y},\dot{a},\dot{h}) \quad (2-2)$$

其中， x 和 y 表示目标检测框中心点坐标， a 表示检测框宽高比， h 表示检测框高度， $\dot{x}, \dot{y}, \dot{a}, \dot{h}$ 分别表示对应状态量的变化速度。通过该状态向量，算法可以预测目标在下一帧中的大致位置。

数据关联是多目标跟踪中的关键步骤。DeepSORT 通常使用马氏距离衡量检测框与预测轨迹之间的运动匹配程度，使用余弦距离衡量检测目标与已有轨迹之间的外观相似程度。马氏距离能够考虑状态估计的不确定性，适合用于判断检测框是否落在预测轨迹的合理范围内；余弦距离则用于比较两个外观特征向量的相似程度，其值越小，表示两个目标外观越相似。

余弦相似度的计算公式为：

$$\cos(\theta) = \frac{A \cdot B}{\|A\| \|B\|} \quad (2-3)$$

其中， A 和 B 表示两个特征向量， $A \cdot B$ 表示向量内积， $\|A\|$ 和 $\|B\|$ 表示向量的模长。根据余弦相似度可以进一步得到余弦距离，用于目标外观匹配。

在完成距离计算后，DeepSORT 使用匈牙利算法进行全局最优匹配。匈牙利算法能够根据代价矩阵寻找检测框与轨迹之间的最优分配结果，使整体匹配代价最小。对于匹配成功的轨迹，算法会利用当前检测框更新其状态；对于未匹配到已有轨迹的检测框，算法会生成新的轨迹；对于连续多帧未匹配成功的轨迹，算法会将其标记为丢失或删除。

2.3 KNN 分类算法原理

KNN 算法，即 K 近邻算法，是一种经典的监督学习分类算法。该算法不需要复杂的参数训练过程，而是通过计算待分类样本与训练样本之间的距离，根据最近邻样本的类别完成分类^[32]。

KNN 的基本思想是：在特征空间中，如果一个样本附近的多数样本属于某一类别，则该样本也可以被划分为该类别。对于待分类样本，算法首先计算其与训练集中所有样本之间的距离，然后选取距离最近的 K 个样本，最后根据这 K 个邻近样本的类别投票得到分类结果。票数最多的类别即为预测类别。




图 2-4 KNN 分类原理示意图

KNN 算法主要包括样本特征表示、距离计算、近邻选择和类别投票四个步骤。样本特征表示是分类的基础，特征质量直接影响分类效果。在本文的牛只行为分类任务中，使用的特征为 HOG 梯度方向特征与检测框长宽比特征的组合，具体提取方式见第三章。

距离度量用于衡量待分类样本与训练样本之间的相似程度。常用的距离度量方式包括欧氏距离、曼哈顿距离和余弦距离等。其中欧氏距离表示两个样本在特征空间中的直线距离，是 KNN 中最常用的度量方式，也是本文所采用的距离度量。设两个样本特征向量分别为：

$$X = (x_1, x_2, \dots, x_n) \quad (2-4)$$

$$Y = (y_1, y_2, \dots, y_n) \quad (2-5)$$

则二者之间的欧氏距离为：

$$d(X, Y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2} \quad (2-6)$$

投票方式分为普通多数投票和距离加权投票两类，前者每个邻近样本具有相同权重，后者按距离远近赋予不同权重。本文采用距离加权投票，即权重为距离的倒数投票方式确定最终分类结果。

K值是KNN算法中的核心参数，直接决定分类器的性能倾向。若K值过小，分类结果容易受到噪声样本和异常样本影响，模型稳定性较差；若K值过大，分类结果会受到较多远距离样本影响，可能导致分类边界过于平滑，降低局部分类能力。因此，K值的选取需在偏差与方差之间取得平衡，通常根据实验结果进行选择。本文在第四章通过实验对比确定了适用于牛只行为分类的最优K值。

KNN算法具有原理简单、易于实现、无需复杂训练过程等优点，但也存在一定局限。当训练样本数量较大时，逐一计算待分类样本与全部训练样本之间的距离会带来较大的计算开销。此外，KNN对特征尺度较为敏感，不同特征维度的数值范围差异较大时，可能导致某些特征对距离计算产生过度影响，因此在实际使用前通常需要对特征进行归一化或标准化处理。

2.4 本章小结

本章介绍了 YOLOv8、目标跟踪与 KNN 分类的相关理论基础。首先说明了 YOLOv8 目标检测算法的基本流程、网络结构、Anchor-Free 思想和后处理方法；随后介绍了目标跟踪的基本概念，并重点阐述了 DeepSORT 算法中的卡尔曼滤波、外观特征匹配、匈牙利算法和轨迹管理机制；最后介绍了 KNN 分类算法的基本思想、距离度量、投票方式和 K 值选择问题。本章所介绍的目标检测、多目标跟踪与 KNN 分类原理，共同构成了第三章方法设计的理论基础。

第三章 基于 YOLOv8 与 KNN 的融合检测方法

3.1 整体方法设计

在方法设计层面，本文选择“检测+分类”的两阶段策略，而非直接使用端到端的行为识别模型，主要基于以下考虑。**其一，数据依赖性与标注成本。**端到端行为识别模型通常需要大规模、细粒度标注的时序行为视频数据，涵盖卧躺、站立、行走、采食、饮水等多种类别，采集和标注成本极高。将任务解耦为目标检测与行为分类两个子任务后，目标检测仅需牛只边界框标注，行为分类仅需对裁剪后的单牛图像标注姿态标签，两类标注均相对易得。**其二，可解释性与部署灵活性。**KNN分类器的特征输入——HOG梯度方向分布与检测框长宽比——物理含义明确，分类结果可追溯至具体的特征维度，便于分析误判成因。同时，面对不同牧场的监控视角、环境光照或牛只品种差异，可通过调整区域规则或动量阈值来适配新场景，无需重新训练深度学习模型。

基于上述思路，本文方法的整体流程如下。

本文方法以YOLOv8检测器为起点，对输入的视频帧执行牛只目标检测，输出边界框与置信度。检测结果送入DeepSORT多目标跟踪模块，在帧间建立身份关联，为每个检测目标分配唯一ID并记录其运动轨迹。针对每个已跟踪的牛只实例，系统从原始帧中裁剪出对应区域，送入KNN分类器进行卧躺、站立、行走三类基础姿态识别。分类完成后，系统并不直接输出结果，而是综合连续帧轨迹动量与牧场功能区域上下文，对行为标签做进一步修正与细分。

本文方法主要包括五个部分：牛只目标检测与计数、DeepSORT目标跟踪、KNN基础行为分类、视频动量修正和区域语义行为细分。其中，YOLOv8负责牛只目标定位和数量统计；DeepSORT保持同一牛只在连续帧中的身份一致性；KNN识别卧躺、站立、行走三类基础行为；动量修正减少站立与行走之间的误判；区域语义行为细分进一步判断采食、饮水、休息等牧场管理行为。整体而言，系统的行为识别遵循“基础姿态→场景上下文→管理行为”的映射逻辑：先由KNN识别单帧中的基础姿态，再结合DeepSORT提供的连续帧运动信息修正站立/行走的误判，最后引入牧场功能区域和停留时间，将基础姿态映射为采食、饮水、休息等管理行为。




图 3-1 整体算法流程

3.2 YOLOv8 牛只检测与计数方法

3.2.1 迁移训练策略

YOLOv8是本文进行牛只检测的基础模型。考虑到单一牛只数据集规模有限，从零开始训练容易导致收敛速度慢、泛化能力不足。因此，本文采用迁移训练策略，先利用牧场场景下的多动物数据集训练基础检测模型，再在牛只数据集上进行微调。

本文使用的牧场多动物数据集包含犬、狐、牛、山羊、马、猪、羊、鹿、骡、羊驼等 11 类牧场常见动物。相比通用图像数据集，该数据集更贴近牧场动物监控场景，使模型提前学习动物目标的外观轮廓、姿态变化、尺度差异和场景背景特征。其中牛相关类别与本文任务高度相关，有利于模型在后续迁移学习时更快收敛。

迁移训练过程分两步：先在牧场多动物数据集上训练YOLOv8基础模型，使其具备牧场动物目标的通用检测能力；再加载该模型权重，在本文构建的牛只数据集上进一步训练，使模型聚焦于牛只目标在具体监控场景中的特征。与从零训练相比，该策略减少了对大规模牛只标注数据的依赖，加快了收敛速度，并提升了牛只检测效果。

3.2.2 检测结果筛选

YOLOv8对输入图像进行检测后，输出目标边界框、类别和置信度信息。检测框表示为：

$$B = (x_1, y_1, x_2, y_2, c, s) \quad (3-1)$$

其中, (x_1, y_1) 和 (x_2, y_2) 分别表示检测框左上角和右下角坐标, c 表示目标类别, s 表示置信度。

模型可能产生低置信度检测框或重复检测框, 需对检测结果进行筛选: 先根据置信度阈值 (本文设为 0.25) 剔除低可靠性结果, 再利用非极大值抑制去除同一目标上的重复检测框。筛选后的检测框作为后续计数、跟踪和行为分类的输入。

在单帧图像中, 筛选后保留的牛只检测框数量即为当前图像中的牛只数量。设当前帧检测框集合为:

$$D = \{B_1, B_2, \dots, B_n\} \quad (3-2)$$

则当前帧牛只数量为:

$$N = |D| \quad (3-3)$$

其中, N 表示当前帧检测到的牛只数量, $|D|$ 表示检测框集合中的元素个数。

在视频场景中, 由于牛只遮挡、检测框抖动和目标进出画面等因素, 单帧计数结果可能存在短时波动。因此, 本文在视频分析中进一步结合 DeepSORT 跟踪结果: 同一目标在连续帧中保持相同 ID, 通过统计当前帧中活跃的跟踪 ID 数量, 可降低因短暂遮挡或重复检测造成的计数波动, 使视频场景下的牛只计数结果更加稳定。

3.3 DeepSORT 多目标跟踪方法

YOLOv8检测当前帧中的牛只位置, 但无法判断不同帧中的检测框是否属于同一头牛。为获得牛只在视频中的连续运动状态, 本文引入DeepSORT对检测结果进行目标跟踪。

DeepSORT以YOLOv8输出的检测框为输入, 通过卡尔曼滤波预测目标位置, 并结合外观特征和运动信息完成检测框与已有轨迹的匹配。匹配成功的目标继承原有ID, 未匹配的检测框分配新ID, 连续多帧未匹配成功的轨迹则被删除或标记为丢失。

经过目标跟踪后, 每个牛只目标表示为:

$$T_i = (id_i, B_i, P_i) \quad (3-4)$$

其中, id_i 表示目标编号, B_i 表示当前帧检测框, P_i 表示该目标在连续帧中的位置序列。

对于每一个跟踪目标, 根据检测框坐标计算中心点位置:

$$x_c = \frac{x_1 + x_2}{2} \quad (3-5)$$

$$y_c = \frac{y_1 + y_2}{2} \quad (3-6)$$

设同一目标在连续帧中的中心点序列为：

$$P_i = \{(x_1, y_1), (x_2, y_2), \dots, (x_t, y_t)\} \quad (3-7)$$

该轨迹序列反映了牛只在视频中的位移变化，是后续视频动量修正、站立/行走区分以及区域停留时间判断的基础。

3.4 KNN 基础行为分类方法

在获得牛只检测框后，本文根据检测框从原始视频帧中裁剪单个牛只目标区域，并将裁剪图像统一缩放至 64×64 像素。随后对图像进行灰度化处理，提取 HOG 特征以描述牛只的边缘、轮廓和姿态信息。考虑到卧躺、站立、行走在整体外形比例上存在差异，本文进一步引入检测框长宽比作为补充特征。设检测框宽度为 w ，高度为 h ，则长宽比为：

$$r = \frac{w}{h} \quad (3-8)$$

最终，KNN 分类器的输入特征表示为：

$$F = [HOG_1, HOG_2, \dots, HOG_n, r] \quad (3-9)$$

其中， $HOG_1, HOG_2, \dots, HOG_n$ 表示图像的 HOG 特征向量， r 表示检测框长宽比特征。

KNN 分类时，首先计算待分类样本 X 与训练样本 Y_i 之间的欧氏距离：

$$d(X, Y_i) = \sqrt{\sum_{j=1}^m (x_j - y_{ij})^2} \quad (3-10)$$

其中， m 表示特征维度， x_j 和 y_{ij} 分别表示两个样本在第 j 维上的特征值。随后选取距离最近的 K 个样本，并采用距离加权投票得到最终类别。本文通过第四章实验对比确定 K 值，分类输出为卧躺、站立和行走三类基础行为。

需要说明的是，采食、饮水和休息并非 KNN 直接输出结果，而是在基础行为分类结果的基础上，结合牧场功能区域和停留时间进一步判断得到。




图 3-2 KNN基础行为分类流程

3.5 视频动量修正方法

单帧图像中，站立与行走行为在外观上较为相似，KNN 分类结果容易出现短时跳变。为提高视频行为识别的稳定性，本文利用 DeepSORT 输出的目标轨迹信息，计算同一牛只在连续帧中的运动量，并根据运动趋势对站立和行走结果进行修正。

3.5.1 连续帧运动量计算

设同一目标在第 t 帧和第 $t-1$ 帧的中心点坐标分别为 (x_t, y_t) 和 (x_{t-1}, y_{t-1}) ，则相邻两帧之间的位移为：

$$d_t = \sqrt{(x_t - x_{t-1})^2 + (y_t - y_{t-1})^2} \quad (3-11)$$

由于不同牛只在画面中的尺度不同，直接使用像素位移容易受到目标远近影响。因此，本文使用检测框尺度对位移进行归一化。设第 t 帧检测框宽度为 w_t ，高度为 h_t ，则归一化运动量为：

$$M_t = \frac{d_t}{\max(w_t, h_t)} \quad (3-12)$$

为减少单帧检测抖动带来的影响，本文采用连续 k 帧的平均运动量表示目标近期运动状态：

$$\bar{M} = \frac{1}{k} \sum_{i=t-k+1}^t M_i \quad (3-13)$$

其中， k 取6， $\bar{M}$ 表示目标在连续多帧中的平均运动强度。

3.5.2 行为修正规则

根据连续帧平均运动量 $\bar{M}$ 判断目标是否具有持续运动趋势。本文在验证集视频中统计站立和行走样本的归一化运动量分布，并据此设置运动阈值 T_{high} 和静止阈值 T_{low} 。当 $\bar{M} \geq T_{\text{high}}$ 时，说明目标在连续帧中存在明显位移，可将其判定为行走；当 $\bar{M} \leq T_{\text{low}}$ 时，说明目标整体处于相对静止状态，可用于修正行走误判。阈值取值及鲁棒性分析见第四章 4.4.3 节。

由于卧躺行为的姿态特征较为明显，且通常不伴随明显位移，因此当 KNN 输出结果为卧躺时，本文直接保留该结果。对于站立和行走两类易混淆行为，本文进一步结合连续帧平均运动量进行修正：当 KNN 将目标判定为行走，但其连续帧平均运动量低于静止阈值 T_{low} 时，将其修正为站立；当目标连续帧平均运动量高于运动阈值 T_{high} 时，将其判定为行走；其余情况下，保持 KNN 的原始分类结果不变。

该规则主要用于修正站立与行走之间的单帧误判。当 KNN 将静止牛只误判为行走时，可依据较低的运动量将其修正为站立；当牛只在连续帧中存在明显移动时，则依据较高的运动量确认为行走。通过引入时间维度上的运动趋势，系统能够在不增加额外复杂模型的情况下，提高视频行为识别结果的稳定性。




图 3-3 视频动量修正示意图

3.6 区域语义行为细分方法

卧躺、站立和行走属于基础行为类别，而智慧牧场管理中更关注采食、饮水和休息等具有管理意义的细分行为。由于采食和饮水仅凭单帧外观难以准确区分，本文在前述行为识别结果的基础上，进一步结合牧场功能区域和停留时间进行行为细分。

根据监控画面中的实际布局，本文将画面划分为采食区、饮水区和休息区。功能区域可采用矩形或多边形进行标注，其中采食槽附近区域对应采食区，饮水设备附近区域对应饮水区，牛只卧躺较集中的区域对应休息区。对于检测到的牛只目标，本文根据检测框中心点判断其是否位于某一功能区域内。设牛只中心点为 (x_c, y_c) ，功能区域为 R ，则当目标中心点满足式3-14时，可认为该目标位于对应功能区域内。

$$(x_c, y_c) \in R \quad (3-14)$$

为减少牛只短暂经过造成的误判，本文进一步引入停留时间约束。只有当同一目标在对应区域内连续停留达到设定阈值时，才输出相应的细分行为。具体而言，当目标处于站立状态，且在采食区内连续停留时间达到阈值 T_f 时，将其判定为采食；当目标处于站立状

态，且在饮水区内连续停留时间达到阈值 T_d 时，将其判定为饮水；当目标处于卧躺状态，且在休息区内连续停留时间达到阈值 T_r 时，将其判定为休息。若目标未满足上述细分条件，则保留其原有行为识别结果。

其中， T_f 、 T_d 、 T_r 分别表示采食区、饮水区和休息区的停留时间阈值。

通过区域语义行为细分，系统可将卧躺、站立、行走三类基础行为进一步扩展为采食、饮水、休息等更具管理意义的行为类别。该方法无需额外训练端到端行为识别模型，规则透明，便于根据不同牧场布局进行调整。受当前数据集时长和场景覆盖范围限制，本文暂未对该模块进行独立的长时序定量评估，而是将其作为可配置规则组件集成至第五章系统中，并通过系统功能测试验证其工程可行性。

3.7 本章小结

本章完整阐述了YOLOv8与KNN融合检测方法的设计方案。围绕整体算法流程，梳理了YOLOv8检测、DeepSORT跟踪、KNN基础行为分类、视频动量修正与区域语义行为细分五个环节之间的衔接逻辑。各部分依次展开：基于牧场多动物数据集迁移训练的牛只检测与计数方法；DeepSORT连续帧目标关联与轨迹获取；基于目标裁剪、HOG特征、检测框长宽比特征和KNN的基础行为分类；针对视频场景下站立与行走易混淆问题设计的连续帧动量修正机制；以及融合功能区域、基础行为状态与停留时间的采食、饮水、休息细分行为判断规则。以上方法构成了完整的检测-跟踪-分类-修正-细分流程，第四章将对其各环节进行实验验证。

第四章 实验结果与分析

为验证本文构建的融合 YOLOv8、DeepSORT 与 KNN 的牧场牲畜计数与行为监测方法的有效性，本章从目标检测、基础行为分类、视频动量修正三个方面进行定量实验分析，并对区域语义行为细分模块的设计逻辑与工程实现进行说明。以下依次介绍实验环境、数据集构建、评价指标及各部分实验结果。

4.1 实验环境

本文实验在Windows系统下完成，硬件与软件环境配置如表 4-1 所示。

表 4-1 实验环境配置表

环境种类	名称	具体信息
硬件环境	CPU	Intel Core i5-13600KF
	GPU	NVIDIA RTX 5070 Ti
	显存	16G
	内存	32G
软件环境	Conda 环境	YOLOv8
	Python	3.10.20
	PyTorch	2.10.0+cu128
	CUDA	12.8
	cuDNN	9.10.2
	NumPy	2.2.6

目标检测部分采用YOLOv8模型完成牛只检测与计数，目标跟踪部分采用DeepSORT对连续帧目标进行关联，行为分类部分采用HOG特征、检测框长宽比特征与KNN分类器实现卧躺、站立、行走三类基础行为识别。

4.2 数据集构建

本文实验共使用三类数据集。为便于后文引用，依次记为数据集 A、B、C。数据集 A 为牧场多动物数据集，用于 YOLOv8 基础检测能力预训练；数据集 B 为牛只目标检测数据集，用于检测模型微调；数据集 C 为牛只行为姿态数据集，用于 KNN 基础行为分类。

数据集 A 共包含 46,307 张图像, 涵盖 Dog、Fox、Cattle、Goat、Horse、Pig、Sheep、Deer、Bull、Mule、Alpaca 等 11 类牧场常见动物, 各类别样本数量分布基本均匀。该数据集场景与牧场动物监控环境接近, 有助于模型学习动物目标的轮廓、姿态及尺度变化特征, 适合作为迁移训练的起点。

数据集 B 共包含 4,110 张图像, 标注框总计 17,054 个, 类别为 cow。该数据集全部用于数据集 A 预训练基础上的微调阶段。

数据集 C 共包含 4,932 张从监控图像中裁剪的牛只目标图像, 其中 lying 1,805 张、standing 1,983 张、walking 1,144 张。standing 类样本最多、walking 类样本最少, 样本数量差异可能对分类结果产生一定影响, 后续实验中需结合混淆矩阵对不同类别的识别效果进行细化分析。

数据集的示例图像如图 4-1 至图 4-3 所示。



图 4-1 数据集A示例




图 4-2 数据集B示例



图 4-3 数据集C示例

4.3 评价指标

目标检测实验主要采用 Precision、Recall、mAP@0.5 和 mAP@0.5:0.95 作为评价指标。Precision 表示检测结果中正确检测目标所占比例，Recall 表示真实目标中被正确检测出的比例。mAP 用于综合评价模型检测效果，其中 mAP@0.5 表示 IoU 阈值为 0.5 时的平均精度，mAP@0.5:0.95 表示 IoU 阈值从 0.5 到 0.95 范围内的平均精度均值。

行为分类实验主要采用 Accuracy、Precision、Recall 和 F1 作为评价指标。Accuracy 表示整体分类正确率，Precision 表示某一类别预测结果的准确程度，Recall 表示该类别真实样本被正确识别的比例，F1 是 Precision 和 Recall 的综合指标。

$$Accuracy = \frac{TP+TN}{TP+TN+FP+FN} \quad (4-1)$$

$$Precision = \frac{TP}{TP+FP} \quad (4-2)$$

$$Recall = \frac{TP}{TP+FN} \quad (4-3)$$

$$F1 = \frac{2 \times Precision \times Recall}{Precision + Recall} \quad (4-4)$$

其中， TP 表示正确识别的正样本数量， FP 表示被错误识别为正样本的数量， FN 表示未被正确识别的正样本数量， TN 表示正确识别的负样本数量。

4.4 实验结果与分析

4.4.1 YOLOv8牛只检测与计数实验结果

为验证迁移训练策略对牛只检测效果的影响，本文对比了三种训练方式下YOLOv8的检测性能，结果如表 4-2 所示。

表 4-2 YOLOv8 检测结果对比表

训练方式	Precision	Recall	mAP@0.5	mAP@0.5:0.95
仅在数据集A训练、直接检测牛只	0.6894	0.6808	0.7134	0.6035
仅在数据集B训练	0.8547	0.7786	0.8560	0.6289
数据集A预训练 + 数据集B微调	0.9095	0.8292	0.9018	0.7094

由表 4-2 可见，仅在数据集A训练的模型检测效果较弱，而仅在数据集B训练后，Precision、Recall 和 mAP 均明显提升，说明牛只场景数据对检测性能具有关键作用。在此基础上，采用“数据集A预训练 + 数据集B微调”的迁移训练策略后，模型取得最优结果，Preci

on 达到 0.9095，mAP@0.5 达到 0.9018，表明预训练阶段学习到的动物目标通用特征有助于提升牛只检测的泛化能力。

为进一步确定检测阶段所采用的置信度阈值，本文对不同阈值下的模型性能进行了对比，结果如表 4-3 所示。

表 4-3 不同置信度阈值对检测性能的影响

置信度阈值	Precision	Recall	mAP@0.5
0.15	0.9035	0.8362	0.8913
0.25	0.9095	0.8292	0.9018
0.35	0.9140	0.8215	0.8576
0.45	0.9160	0.8206	0.8124

由表 4-3 可见，随着置信度阈值升高，Precision 总体上升，Recall 逐步下降。当阈值为 0.25 时，模型在精度与召回率之间取得较好平衡，mAP@0.5 达到最高值 0.9018。因此，本文后续实验采用 0.25 作为检测置信度阈值。

模型训练过程及检测可视化结果分别如图 4-4 和图 4-5 所示。由图 4-5 可见，经过迁移训练后的 YOLOv8 能够较好地完成牧场场景中牛只目标的定位与检测，为当前帧牛只计数以及后续视频序列分析提供基础。




图 4-4 YOLOv8迁移学习训练结果



图 4-5 YOLOv8牛只检测可视化结果图

在目标检测结果的基础上，本文进一步进行牛只数量统计实验。对于每张测试图像，系统将 YOLOv8 输出的牛只检测框数量作为预测数量，并将同名标注文件中的目标数量作为真实数量。

本文在B数据集的测试集上进行计数实验，共测试 954 张图像。实验中检测置信度阈值设置为 0.25，IoU 阈值设置为 0.45。牛只计数实验结果如表 4-4 所示。

表 4-4 YOLOv8 牛只计数实验结果

测试图像数量	真实总数	预测总数	MAE	RMSE	完全准确率	误差 ≤ 1 准确率
954	3946	3833	0.4518	1.1369	74.21%	91.51%

由表 4-4 可见，YOLOv8 在牛只数量统计任务中具有较好的计数效果。954 张测试图像中，预测总数为 3833，真实总数为 3946，二者总体差异较小。模型的平均绝对误差为 0.4518，说明单张图像的平均计数误差不足 1 只牛。当采用完全一致作为评价标准时，计数准确率为 74.21%；当允许单张图像存在 1 只以内误差时，计数准确率达到 91.51%。这说明模型在复杂牧场图像中能够较稳定地完成牛只数量统计。

牛只计数可视化结果如图 4-6 所示。图中黄色检测框表示 YOLOv8 检测到的牛只目标，图像上方给出了真实数量和预测数量。由图可见，在中近景样本中，模型能够较准确地检测出图像中的主要牛只目标，并完成数量统计。




图 4-6 YOLOv8 牛只计数结果示例

为进一步分析模型的计数误差分布，本文统计了测试集中不同绝对误差对应的图像数量，结果如图 4-7 所示。由图 4-7 可见，大多数图像的计数误差集中在 0 或 1，其中完全计数正确的图像数量为 708 张，误差为 1 的图像数量为 165 张，二者合计占测试集的 91.51%。说明 YOLOv8 在多数测试图像中能够获得较为准确的计数结果，但在目标遮挡、远距离小目标以及牛只密集分布等场景下仍可能出现漏检或误检，从而导致计数误差增加。






图 4-7 YOLOv8 牛只计数误差分布

在完成单帧目标检测后，本文进一步利用目标跟踪方法对连续视频帧中的牛只进行轨迹关联。为直观展示跟踪模块在较长时间间隔下的身份保持效果，选取同一视频中相隔 123 帧的两帧跟踪结果进行对比，如图 4-8 所示。图中不同颜色的检测框表示不同牛只目

标，框上方的 ID 表示系统为目标分配的轨迹编号。由图可见，在第 297 帧和第 420 帧中，多个牛只目标仍保持相同的 ID 编号，说明跟踪模块能够在连续视频序列中维持目标身份的一致性，从而为后续运动量计算和行为修正提供轨迹基础。



(a) 第 297 帧



(b) 第 420 帧

图 4-8 连续帧目标跟踪结果：（a）第 297 帧；（b）第 420 帧

4.4.2 KNN基础行为分类实验结果

KNN 分类器用于识别卧躺、站立、行走三类基础行为。本文以 HOG 特征和检测框长宽比作为输入。

为确定 KNN 的最优 K 值，本文分别以 K=5、7、9、11 进行实验对比，结果如表 4-5 所示。

表 4-5 不同 K 值对基础行为分类性能的影响

K值	整体准确率	lying F1-score	standing F1-score	walking F1-score
5	87.19%	0.9004	0.8601	0.8471
7	88.27%	0.9056	0.8700	0.8696
9	87.96%	0.8964	0.8656	0.8800
11	86.83%	0.8932	0.8547	0.8621

由表 4-5 可见，K=7 时整体准确率最高，为 88.27%；K=9 时整体准确率为 87.96%，但 walking 类 F1-score 达到 0.8800，高于 K=7。由于后续动量修正主要针对 standing 与 walking 的混淆问题，walking 类识别效果会直接影响视频修正结果，因此本文在整体性能接近的情况下选择 K=9 作为后续实验参数。

确定 K=9 后，在数据集 C 的测试集上进行基础行为分类实验，结果如表 4-6 所示。

表 4-6 KNN 基础行为分类结果表

类别	Precision	Recall	F1-score
lying	0.8724	0.9217	0.8964
standing	0.9018	0.8322	0.8656
walking	0.8462	0.9167	0.8800
平均值	0.8735	0.8902	0.8807

由表 4-6 可见，KNN 分类器在测试集上的整体准确率为 87.96%。其中 lying 和 walking 的召回率分别为 92.17% 和 91.67%，识别效果较好；standing 的召回率为 83.22%，说明站立样本更容易与其他类别混淆。




图 4-9 KNN基础行为分类结果示例：（a）lying；（b）standing；（c）walking

为直观展示 KNN 分类器对不同基础行为的识别效果，本文选取测试集中的典型样本进行可视化，如图 4-9 所示。图中分别给出了 lying、standing 和 walking 三类行为的分类结果。可以看出，KNN 分类器能够根据牛只外观姿态特征对三类基础行为进行区分，为后续视频动量修正和区域语义行为细分提供基础行为识别结果。

表 4-7 KNN 基础行为分类混淆矩阵

真实类别/预测类别	lying	standing	walking
lying	212	18	0
standing	30	248	20
walking	1	9	110

由表 4-7 可见，主要误判集中在 standing→walking、standing→lying 和 lying→standing。其中 standing 与 walking 在单帧图像中外观相似，容易受起立、转向和小幅移动影响；lying 与 standing 的混淆则多与拍摄角度和身体轮廓变化有关。因此，在视频场景下引入连续帧运动信息对 standing/walking 进行修正具有必要性。

为进一步验证HOG特征与长宽比特征的互补性，本文进行了特征消融实验。分别以“仅HOG特征”“仅长宽比特征”和“HOG+长宽比特征”三种输入配置训练KNN分类器（K=9），在相同测试集上对分类效果，结果如表 4-8 所示。

表 4-8 KNN 行为分类特征消融实验结果

特征组合	整体准确率	lying F1	standing F1	walking F1
仅长宽比	71.42%	0.7835	0.6892	0.6701
仅HOG	83.15%	0.8523	0.8217	0.8406
HOG + 长宽比	87.96%	0.8964	0.8656	0.8800

由表 4-8 可见，仅使用长宽比特征时准确率较低，仅为 71.42%；仅使用 HOG 特征时准确率提升至 83.15%；融合 HOG 与长宽比特征后，准确率进一步提升至 87.96%。这说明 HOG 特征能够描述牛只边缘和姿态信息，长宽比特征能够补充整体形态约束，二者结合有助于提升基础行为分类效果。




图 4-10 KNN 基础行为分类混淆矩阵图

4.4.3 视频动量修正实验结果

为抑制 **standing** 与 **walking** 之间的单帧误判，本文在视频检测流程中引入连续帧动量修正机制。该方法利用 DeepSORT 输出的目标 ID 与中心点轨迹，计算同一牛只在连续帧中的平均归一化运动量 $\bar{M}$ 。当 $\bar{M}$ 超过上限阈值 T_{high} 时，行为倾向判定为 **walking**；当 $\bar{M}$ 低于下限阈值 T_{low} 时，若 KNN 误判为 **walking**，则修正为 **standing**。

为定量评估修正效果，本文统计了动量修正前后 **standing** 与 **walking** 两类易混淆行为的分类混淆情况，结果如表 4-9 所示。

表 4-9 动量修正前后 standing/walking 分类混淆对比

指标	修正前	修正后	变化
standing→walking 误判数（占standing样本比例）	43（14.4%）	14（4.7%）	下降29
walking→standing 误判数（占walking样本比例）	10（8.3%）	4（3.3%）	下降6
standing 类准确率	83.22%	90.08%	上升6.86%
walking 类准确率	91.67%	95.83%	上升4.16%

由表 4-9 可见，动量修正后 standing→walking 误判数由 43 降至 14，walking→standing 误判数由 10 降至 4；standing 和 walking 的准确率分别提升至 90.08% 和 95.83%。结果表明，连续帧运动量能够有效抑制单帧分类中的短时误判，提高视频行为识别的稳定性。


为验证动量修正阈值的鲁棒性，本文在 $\pm 20\%$ 和 $\pm 40\%$ 范围内调整 T_{high} 和 T_{low} ，比较不同阈值组合下的修正效果，结果如表 4-10 所示。

表 4-10 动量修正阈值敏感性分析

阈值组合 (T_{high} , T_{low})	standing 准确率	walking 准确率
(0.008, 0.004)	89.41%	94.17%
(0.01, 0.005)	90.08%	95.83%
(0.012, 0.006)	83.22%	95.00%
(0.014, 0.007)	90.52%	91.67%

由表 4-10 可见，阈值变化会影响 standing 和 walking 的修正效果。默认阈值组合 (0.01, 0.005) 下，两类行为准确率均较高，说明该阈值设置较为合理。综合分类效果与稳定性，本文后续采用该组阈值作为动量修正参数。

动量修正并不新增行为类别，而是在 KNN 单帧分类结果基础上引入时间一致性约束。当目标在连续帧中存在明显位移时，系统倾向于判定为 walking；当目标运动量较低且被误判为 walking 时，系统将其修正为 standing，从而减少相邻帧间的行为标签跳变。



(a) 修正前



(b) 修正后

图 4-11 动量修正前后结果对比：（a）修正前；（b）修正后

为直观展示动量修正模块对行为识别结果的影响，本文选取同一视频帧在修正前后的识别结果进行对比，如图 4-11 所示。图 4-11（a）为仅采用 KNN 分类器得到的基础识别

结果，图 4-11 (b) 为引入连续帧平均运动量后的修正结果。可以看出，修正前部分目标仅依据单帧外观特征进行行为判断，容易在站立与行走之间产生混淆；修正后，系统结合目标在连续帧中的位移变化，对运动量较低的目标进行站立修正，对存在明显位移的目标进行行走确认，从而减少单帧误判对视频行为识别结果的影响。

4.4.4 区域语义行为细分功能验证

KNN 分类器只能输出卧躺、站立、行走三类基础行为，无法直接识别采食、饮水、休息等更具管理意义的细分行为。为满足智慧牧场的实际需求，本文在基础行为分类与动量修正的结果之上，进一步结合牧场功能区域与停留时间进行行为细分。区域语义行为细分规则如表 4-11 所示。

表 4-11 区域语义行为细分规则

细分行为	基础行为	功能区域	停留时间要求
采食	站立	采食区	$\text{Time} \geq T_f$
饮水	站立	饮水区	$\text{Time} \geq T_d$
休息	躺卧	休息区	$\text{Time} \geq T_r$

由于当前数据集主要由短视频片段和单帧姿态样本构成，缺少带有完整时间戳标注的长时序行为数据，本文暂未对区域语义细分模块进行独立定量评估。作为替代，本文将该模块集成至第五章系统中，通过采食、饮水和休息三类模拟场景进行功能验证。测试结果表明，系统能够根据区域位置、基础行为和停留时间输出对应细分行为，验证了该规则模块的工程可用性。

由表 4-12 可见，加入区域语义细分后，系统可识别行为由卧躺、站立、行走三类基础姿态扩展为六类行为，增强了检测结果的牧场管理语义。

表 4-12 可识别行为类别对比

方法	可识别行为类别	类别数
仅基础行为分类	卧躺、站立、行走	3
本文方法（含区域语义细分）	卧躺、站立、行走、采食、饮水、休息	6

4.5 本章小结

本章对本文方法的检测、分类、动量修正和区域语义细分模块进行了实验与功能验证。实验结果表明，迁移训练后的 YOLOv8 模型 $\text{mAP}@0.5$ 达到 0.9018；融合 HOG 与长宽比

特征的 KNN 分类器在 $K=9$ 时整体准确率为 87.96%；视频动量修正能够降低 **standing** 与 **walking** 之间的误判，提高视频行为识别稳定性；区域语义规则模块则将基础行为扩展为采食、饮水、休息等管理行为。上述结果验证了本文融合方法的可行性。

第五章 牧场牲畜计数与行为监测平台设计与实现

为验证本文设计的 YOLOv8、DeepSORT 与 KNN 融合方法在智慧牧场场景中的应用效果，本文设计并实现了一套牧场牲畜行为检测系统。系统以视频监控为基础，集成牛只检测计数、目标跟踪、基础行为识别、区域语义细分、事件记录、异常告警和历史数据分析等功能。本章主要介绍系统需求、总体架构、功能实现和运行测试情况。

5.1 系统需求分析

智慧牧场监控系统的主要目标是辅助管理人员实时掌握牧场中牛只数量和行为状态。系统需要接入牧场监控视频，对画面中的牛只进行检测与计数，识别卧躺、站立、行走等基础行为，并结合采食区、饮水区、休息区等功能区域进一步判断采食、饮水和休息等细分行为。

系统主要功能包括：用户登录与权限管理、摄像头设备管理、实时视频监控、区域配置与行为细分、行为事件记录、异常告警和历史数据分析。其中，实时监控模块负责展示检测框、目标 ID、牛只数量和行为标签；事件与告警模块负责保存识别结果并提示异常情况；历史分析模块用于查询和统计不同时间段的牛只行为变化。

5.2 系统总体设计

5.2.1 系统总体架构

本系统采用前后端分离架构，整体由前端展示层、后端服务层、算法推理层和数据存储层组成。前端负责页面展示、视频播放和用户交互；后端负责登录认证、设备管理、区域管理、事件记录和告警处理；算法推理层负责调用 YOLOv8、DeepSORT 与 KNN 完成视频分析；数据存储层负责保存用户信息、设备信息、区域配置、行为事件和告警记录。




图 5-1 系统总体架构图

系统运行流程如下：用户登录后进入实时监控页面并选择摄像头设备，系统读取对应视频流并将视频帧送入推理模块。推理模块首先通过 YOLOv8 完成牛只检测与计数，再利用 DeepSORT 保持连续帧中目标 ID 的一致性，随后通过 KNN 对牛只裁剪图像进行基础行为分类。分类结果经过动量修正和区域语义规则处理后，生成最终行为标签，并将事件结果写入数据库，最后返回前端页面展示。

系统实现中，前端采用 Vue 3、TypeScript 和 Vite，后端采用 FastAPI，数据库采用 PostgreSQL，缓存和部分实时状态管理采用 Redis，整体服务通过 Docker Compose 进行部署和运行管理。

5.2.2 系统功能模块设计

根据系统需求，本文将系统划分为用户登录模块、设备管理模块、实时监控模块、区域管理模块、行为事件与告警模块和历史数据分析模块。




图 5-2 系统功能模块图

各模块之间围绕“视频接入-算法推理-结果展示-事件记录-历史分析”的流程协同工作。设备管理模块提供视频源信息，实时监控模块调用推理服务获取检测结果，区域管理模块为行为细分提供空间约束，事件与告警模块保存识别结果并生成异常提醒，历史分析模块对已保存数据进行查询与统计展示。

5.3 系统功能实现

5.3.1 用户登录模块

用户登录模块是系统的入口。用户提交账号和密码后，后端对用户信息进行校验。验证通过后，系统生成登录凭证，并开放设备管理、实时监控、历史分析等页面的访问权限。登录机制有效隔离了未授权用户的访问，增强了系统安全性。



图 5-3 用户登录界面图

5.3.2 设备管理模块

设备管理模块用于维护牧场摄像头信息，包括设备名称、设备编号、视频流地址、在线状态和所属区域等。系统根据设备配置读取对应视频流，并将其作为算法推理模块的输入。当设备无法正常连接时，系统会在页面中显示离线状态，方便管理人员及时排查。



图 5-4 设备管理界面图

5.3.3 实时监控模块

实时监控模块是系统的核心展示模块。系统在视频画面中叠加显示牛只检测框、目标 ID、当前数量和行为识别结果，使管理人员能够直观查看牛群状态。

在处理流程上，系统先读取视频帧并调用推理服务，由 YOLOv8 输出检测框和置信度；DeepSORT 维护目标 ID；KNN 对检测框内的牛只图像进行基础行为分类；动量修正模块根据连续帧位移修正站立与行走之间的短时误判；区域语义规则进一步结合功能区域和停留时间输出采食、饮水、休息等细分行为。




图 5-5 实时监控界面



图 5-6 实时检测结果

5.3.4 区域管理与行为细分模块

区域管理模块用于配置采食区、饮水区和休息区等功能区域。系统保存区域类型和区域坐标，并在实时分析过程中判断牛只是否位于对应区域内。

行为细分模块在基础行为识别结果上进一步处理：当牛只处于站立状态并在采食区停留超过设定时间时，系统判定为采食；当牛只处于站立状态并在饮水区停留超过设定时间时，系统判定为饮水；当牛只处于卧躺状态并位于休息区时，系统判定为休息。通过该模块，系统将基础姿态识别结果转化为更具牧场管理意义的行为类别。




图 5-7 自定义区域

5.3.5 行为事件与告警模块

行为事件模块负责保存系统识别到的行为结果。每条事件记录包含目标 ID、设备编号、行为类别、发生时间、持续时间和截图等信息，便于后续查询与追溯。

告警模块用于提示异常情况。例如，当设备离线、功能区域长时间无牛只活动，或某类行为持续时间超过设定范围时，系统生成告警记录并在前端页面展示，辅助管理人员及时发现异常状态。




图 5-8 行为事件与告警界面

5.3.6 历史数据分析模块

历史数据分析模块提供行为事件和告警记录的查询统计功能。用户可按照时间范围、设备名称和行为类别筛选数据，可以查看不同行为的发生次数和变化趋势。该模块能够帮助管理人员了解牛群活动规律，为牧场管理提供数据参考。




图 5-9 历史数据分析界面

5.4 系统运行测试

为验证系统功能是否正常运行，本文对登录、设备管理、区域配置、实时监控、事件记录、告警显示和历史查询等功能进行了测试。测试结果如表 5-1 所示。

表 5-1 系统功能测试表

测试模块	测试内容	测试结果
用户登录模块	输入账号密码并进入系统	正常
设备管理模块	查看设备列表和设备状态	正常
实时监控模块	显示视频流、检测框、行为结果	正常
区域管理模块	设置采食区、饮水区、休息区	正常
行为事件模块	记录行为事件信息	正常
告警模块	展示异常告警信息	正常
历史分析模块	查询和统计历史行为数据	正常

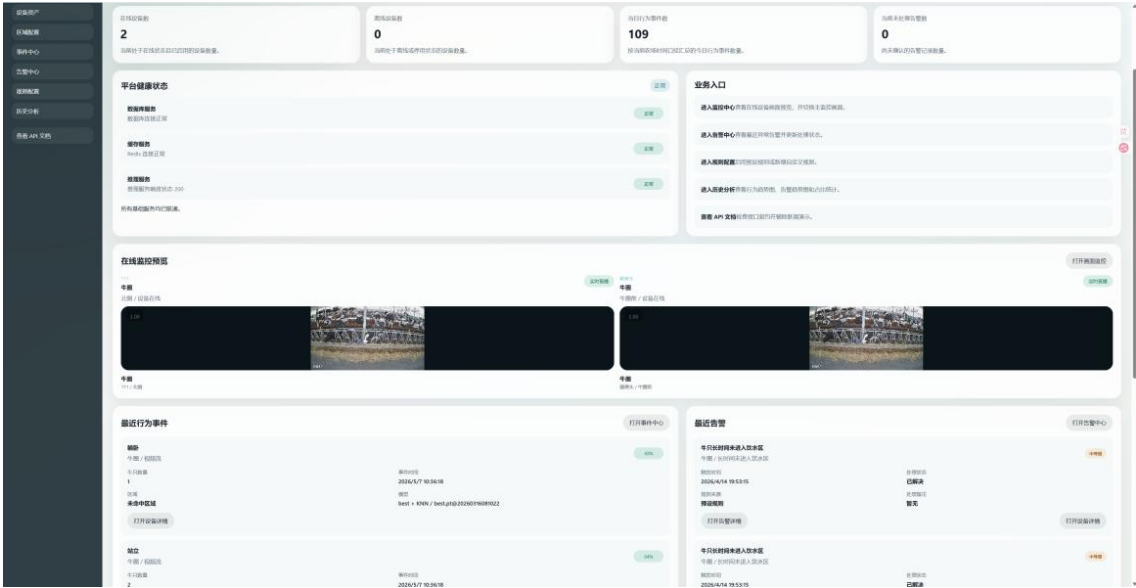


图 5-10 系统运行效果总览

5.5 本章小结

本章设计并实现了一套牧场牲畜行为检测系统。系统采用前后端分离架构，集成 YOLOv8、DeepSORT 与 KNN 融合方法，实现了牛只检测计数、行为识别、区域语义细分、事件记录、异常告警和历史数据分析等功能。运行测试结果表明，系统各模块能够正常工作，验证了本文方法在智慧牧场监控场景中的工程可行性。

第六章 总结与展望

6.1 总结

本文围绕智慧牧场场景下的牛只计数与行为监测问题，设计并实现了一种融合YOLOv8、DeepSORT与KNN的多阶段检测方法。方法以YOLOv8为检测基线，通过迁移学习策略（牧场多动物数据集预训练+牛只数据集微调）完成目标定位与计数；引入DeepSORT实现帧间牛只身份关联与轨迹获取；在行为识别环节，对检测到的牛只区域进行裁剪，提取HOG与检测框长宽比特征，利用KNN分类器实现卧躺、站立、行走三类基础姿态的识别。针对单帧分类中站立与行走易混淆的问题，设计了基于连续帧中心点位移的动量修正机制；进一步结合牧场功能区域划分、基础姿态与停留时间，通过区域语义规则将基础行为映射为采食、饮水、休息等细化管理行为。

在目标检测实验中，本文采用牧场多动物数据集进行基础训练，再迁移到牛只数据集上进行微调。实验结果表明，相比直接训练，迁移训练后的YOLOv8模型在检测精度和召回率方面均有所提升，能够较好完成牛只检测与计数任务。在行为分类实验中，基于HOG特征、长宽比特征和KNN的方法能够完成三类基础行为识别，但standing与walking之间仍存在一定误判。通过引入目标跟踪和连续帧动量修正后，视频中的行为判断更加稳定，减少了单帧分类造成的短时跳变。

此外，本文还设计并实现了牧场牲畜行为检测系统。系统包含用户登录、设备管理、实时监控、区域管理、行为事件与告警、历史数据分析等功能模块，能够展示牛只检测框、目标ID、数量统计和行为识别结果，并对行为事件进行记录和查询。整体来看，本文方法能够完成从目标检测、数量统计到行为监测和系统展示的完整流程，具有一定的实用价值。

6.2 展望

本文完成了牛只计数与行为监测的方法设计与系统实现，但受限于数据规模、算法复杂度与规则设计的权衡，仍有若干方向值得进一步推进。

数据层面，当前数据集在复杂光照、夜间环境、严重遮挡及不同牧场布局等条件下的样本覆盖尚不充分。后续宜扩大真实牧场视频的采集范围，补充多天气、多角度及不同饲养密度下的标注数据，以增强模型在开放环境中的泛化能力。尤其需要补充包含完整采

食、饮水行为周期的长时序牧场视频数据，以支撑区域语义行为细分模块的定量验证，并为停留时间阈值的优化标定提供数据基础。

算法层面，本文的行为识别依赖HOG特征、长宽比特征与KNN分类器的组合，实现简单、可解释性强，但对细粒度姿态差异的刻画能力有限。一个可行的方向是引入牛只骨骼关键点检测作为中间表示——姿态骨架对卧躺、站立、行走等行为具有更强的判别力，且对光照和背景干扰相对鲁棒。在此基础上，可进一步探索时序模型（如LSTM或轻量Transformer）对连续姿态序列建模，将行为识别从单帧分类推向时序推理。

规则层面，本文的采食、饮水、休息细分行为基于区域语义与停留时间的规则引擎实现，优势在于逻辑透明、易于调整，但判断精度对区域划分的合理性依赖较大。后续可融合目标朝向、头部姿态及运动轨迹等多维信息，构建更细粒度的行为判定逻辑，减少因牛只“经过但未进食”等情况造成的误判。此外，行为事件记录的实时性为牧场异常预警提供了数据基础，未来可在现有告警框架基础上，扩展长时间未采食、活动量异常等自动检测功能，使系统由行为记录工具进一步发展为具备主动预警能力的牧场管理辅助平台。

参考文献

- [1] 周鑫宇,杨君香,黄文明,等.对我国规模奶牛养殖模式的思考[J].中国畜牧杂志,2010,46(12):35-41.
- [2] 兰玉彬,赵德楠,张彦斐,等.生态无人农场模式探索及发展展望[J].农业工程学报, 2021, 37(9): 312-327.
- [3] 尹崇崇.生态无人农场模式及发展分析[J].农业工程技术,2023,43(32):18-19.
- [4] 苑文博,宗哲英,李亚男.奶牛行为检测的研究现状与展望[J].当代畜禽养殖业,2024,44(05):44-47.
- [5] 韩书庆,张晶,程国栋,等.奶牛跛行自动识别技术研究现状与挑战[J].智慧农业(中英文),2020,2(03):21-36.
- [6] 郭雷风,王文生,Paul KWAN,等.基于加速仪运动传感器的牲畜行为监测研究进展[J].中国农业科技导报,2019,21(03):94-101.
- [7] 薛芳芳,王月明,李琦.基于计算机视觉技术的牲畜行为识别研究进展[J].黑龙江畜牧兽医, 2021, (11): 33-38.
- [8] 邵延华,张铎,楚红雨,等.基于深度学习的YOLO目标检测综述[J].电子与信息学报,2022,44(10):3697-3708.
- [9] Kaixuan Z, Dongjian H. Target detection method for moving cows based on background subtraction[J]. International journal of agricultural and biological engineering, 2015,8(1): 42-49.
- [10] Redmon J, Divvala S, Girshick R, et al. You Only Look Once: Unified, real-time object detection[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Las Vegas: IEEE, 2016: 779-788.
- [11] Tassinari P, Bovo M, Benni S, et al. A computer vision approach based on deep learning for the detection of dairy cows in free stall barn[J]. Computers and Electronics in Agriculture, 2021, 182: 106030-106036.
- [12] Jiang B, Wu Q, Yin X, et al. FLYOLOv3 deep learning for key parts of dairy cow body detection[J]. Computers and Electronics in Agriculture, 2019, 166: 104982-105002.
- [13] Guo Y, Hong W, Wu J, et al. Vision-based cow tracking and feeding monitoring for autonomous livestock farming: the YOLOv5s-CA+ DeepSORT-vision transformer[J]. IEEE Robotics & Automation Magazine, 2023,30(4): 68-76.
- [14] Wang J, Zhang Z, Dai B, et al. Cow-YOLO: Automatic cow mounting detection based on non-local CSPDarknet53 and multiscale neck[J]. International Journal of Agricultural and Biological Engineering, 2024,17(3): 193-202.

- [15] Xudong Z, Xi K, Ningning F, et al. Automatic recognition of dairy cow mastitis from thermal images by a deep learning detector[J]. Computers and Electronics in Agriculture, 2020, 178: 105754-105758.
- [16] Mishra M, Anand N, Verma P. A Hybrid YOLOv8-Transformer Framework for Accurate Cattle Behavior Classification and Tracking in Complex Farm Environments[J]. IETE Journal of Research, 2025, 71(3): 1-18.
- [17] 王政, 许兴时, 华志新, 等. 融合YOLOv5n与通道剪枝算法的轻量化奶牛发情行为识别[J]. 农业工程学报, 2022, 38(23): 130-140.
- [18] 付辰伏, 任力生, 王芳. 自动化场景区分下FABF-YOLOv8s轻量化肉牛行为识别方法[J]. 农业工程学报, 2024, 40(15): 152-163.
- [19] 张立印, 张姬, 杨庆璐, 等. 基于视频和BCE-YOLO模型的奶牛采食行为检测[J]. 华南农业大学学报, 2024, 45(05): 782-792.
- [20] 张宏鸣, 汪润, 董佩杰, 等. 基于DeepSORT算法的肉牛多目标跟踪方法[J]. 农业机械学报, 2021, 52(04): 248-256.
- [21] 付辰伏, 任力生, 王芳. 基于改进YOLOv8的牛只行为识别与跟踪方法[J]. 农业机械学报, 2024, 55(05): 290-301.
- [22] 苏宇, 肖志云, 鲍鹏飞. 采用改进YOLOv5s检测牧区牲畜[J]. 农业工程学报, 2023, 39(24): 165-176.
- [23] 汪琪, 马灵玲, 王宁, 等. 系留球载光学影像的草原牲畜数量自动核算方法[J]. 无线电工程, 2021, 51(12): 1485-1492.
- [24] 赵凯旋, 何东健. 基于卷积神经网络的奶牛个体身份识别方法[J]. 农业工程学报, 2015, 31(05): 181-187.
- [25] 拉毛杰, 安见才让. 基于卷积神经网络的畜牧业动物图像识别研究[J]. 软件, 2020, 41(08): 43-45.
- [26] 卫阳森. 基于深度学习的牲畜行为识别研究与应用[D]. 河北科技师范学院, 2023.
- [27] 刘亚楠, 沈明霞, 刘龙申, 等. 基于机器视觉的母猪哺乳行为监测方法研究[J]. 南京农业大学学报, 2022, 45(02): 404-411.
- [28] 肖德琴, 曾瑞麟, 周敏, 等. 基于DH-YoloX的群养马岗鹅关键行为监测[J]. 农业工程学报, 2023, 39(02): 142-149.
- [29] 肖英豪, 高军伟, 薛保国, 等. 绝缘子自爆缺陷YOLOv8识别方法仿真[J]. 计算机仿真, 2025, 42(04): 119-123.

- [30]Bewley A, Ge Z, Ott L, et al. Simple online and realtime tracking[C]//2016 IEEE International Conference on Image Processing. Phoenix: IEEE, 2016: 3464-3468.
- [31]Cover T, Hart P. Nearest neighbor pattern classification[J]. IEEE Transactions on Information Theory, 1967, 13(1): 21-27.
- [32]Dalal N, Triggs B. Histograms of oriented gradients for human detection[C]//2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition. San Diego: IEEE, 2005, 1: 886-893.

致 谢