

南京工业大学

2025 届毕业设计（论文）

题 目： 基于深度学习的 PCB

电路板缺陷检测

专 业： 自动化

班 级： 自 2103

姓 名： 胡可宇

指导老师： 肖迪

起讫日期： 2024.12-2025.6

2025 年 05 月

南京工业大学本科毕业设计（论文）原创性声明

本人郑重声明：所呈交的毕业设计（论文），是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的作品成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

论文作者签名：胡可章

日期：2024 年 5 月 26 日

南京工业大学本科毕业设计（论文）使用授权声明

本学位论文作者完全了解学校有关保留、使用毕业设计（论文）的规定，同意学校保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。本人授权南京工业大学教务处可以将本毕业设计（论文）的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编毕业设计（论文）。

论文作者签名：胡可章

导师签名：

日期：2024 年 5 月 26 日

日期：2024 年 5 月 26 日

基于深度学习的 PCB 电路板缺陷检测

摘 要

随着智能工业产业的不断发展，PCB 电路板成为诸多电子产品不可或缺的器件，然而 PCB 的生产工艺复杂，不可避免地存在多种制造缺陷。市面上常常使用目标识别等方法进行自动化识别电路板缺陷，但是 PCB 本身具有背景复杂和目标微小的特点，传统检测方法存在漏检误检的问题。

本文针对上述问题进行改进，采用了以下方法：在主干网络和颈部网络新增了 CBAM 注意力机制层，对通道域和空间域的数据进行了加权处理，摘取重要信息，提升精确率；在颈部网络增加了小目标检测层，同时与 CBAM 注意力机制相融合，使模型能额外引出一个 160×160 的检测头，加强模型检测小目标的能力；将 YOLOv8s 模型原有的 FPN+PAN 网络结构替换为 BiFPN 网络结构，增强了的信息同层级间传输能力，提升了模型的整体精度。

本文对上述改进方法做了一系列消融实验，层层分析各个模块对模型的影响。实验结果表明，改进后模型的性能指标与原模型对比，精确率提升了 7.1%， $\text{map}@0.5$ 提升了 2.8%，召回率提升了 4%，结果证明了本模型的改进能够有效提高模型整体检测能力。

同时本文还设计了一个人机交互系统，能够引入训练好的模型权重，对单个图片或批量待检目标进行检测输出，并且能够汇总相关检测信息，以表格的形式导出。

关键词：PCB 缺陷检测 YOLOv8s CBAM BiFPN

PCB defect detection base on deep learning

Abstract

With the continuous development of the intelligent industrial sector, PCB have become indispensable components in numerous electronic products. However, PCB manufacturing involves complex processes that inevitably introduce various defects. Current automated defect detection solutions in the market typically employ object recognition methods. Nevertheless, the intricate backgrounds and minuscule targets inherent to PCBs often lead to missed detections and false positives in conventional approaches.

To address these challenges, this study proposes the following methodological improvements: Integration of CBAM attention modules into both the backbone and neck networks to perform channel-wise and spatial-wise feature weighting, thereby enhancing critical feature extraction and improving detection precision; Implementation of a small object detection layer in the neck network, synergistically combined with the CBAM mechanism, to introduce an additional 160×160 detection head for superior small defect identification; Replacement of the original FPN+PAN architecture with BiFPN to strengthen cross-scale feature fusion and boost overall model accuracy.

Ablation experiments were conducted to systematically evaluate the contributions of each proposed module. Experimental results demonstrate that the enhanced model achieves significant improvements over the baseline YOLOv8s: +7.1% in precision, +2.8% in mAP@0.5, and +4% in recall, validating the effectiveness of the proposed modifications.

Furthermore, an interactive human-machine interface system was developed, capable of loading trained model weights to perform single or batch image inference. The system automatically aggregates detection results and exports comprehensive reports in tabular format.

Key Words: PCB; Defect Detection; YOLOv8s; CBAM; BiFPN

目 录

摘 要	I
Abstract.....	II
第一章 绪论	1
1.1 研究背景和意义	1
1.2 PCB 缺陷检测研究的内容和现状.....	2
1.2.1 PCB 缺陷检测研究发展历程	2
1.2.2 国内外研究现状	2
1.3 论文的结构安排	4
第二章 目标检测相关理论知识	5
2.1 目标检测技术演进与架构革新	5
2.1.1 传统视觉方法	5
2.1.2 深度学习框架	6
2.1.3 实时检测框架	8
2.2 卷积神经网络基本结构	8
2.2.1 感受野.....	9
2.2.2 卷积层	10
2.2.3 池化层	10
2.2.4 全连接层	11
2.3 YOLOv8 总体架构	11
2.3.1 Backbone 层	12
2.3.2 Neck 层.....	12
2.3.3 Head 层.....	13
2.4 本章小结	13
第三章 YOLOv8s 算法改进.....	14
3.1 前言	14
3.2 CBAM 注意力机制	14
3.2.1 CBAM 注意力机制原理	14
3.2.2 改进方法	16

3.3 小目标检测层	17
3.3.1 小目标检测层原理	17
3.3.2 改进方法	17
3.4 BiFPN 特征融合网络	18
3.4.1 BiFPN 特征网络原理	18
3.4.2 改进方法	20
3.5 本章小结	21
第四章 实验结果与分析	22
4.1 前言	22
4.2 实验环境	22
4.3 数据集构建	23
4.3.1 数据集介绍	23
4.3.2 数据集拓展	23
4.4 评价指标	24
4.5 消融实验与结果分析	25
4.5.1 消融实验结果	25
4.5.2 归一化混淆矩阵分析	27
4.5.3 改进模型图片检测对比	28
4.6 本章小结	30
第五章 PCB 电路板缺陷检测交互系统	31
5.1 前言	31
5.2 PCB 缺陷检测交互系统设计与实现	31
5.3 本章小结	33
第六章 总结和展望	34
6.1 总结	34
6.2 展望	35
参考文献	36
致 谢	38

第一章 绪论

1.1 研究背景和意义

近年来，PCB(Printed Circuit Board，印制电路板)缺陷检测技术作为电子制造质量控制的基石，在图像处理、深度学习与人工智能交叉领域实现了跨越式发展，成为推动智能制造转型升级的核心驱动力。这一技术体系不仅重塑了传统检测范式，更通过多模态感知与智能决策的融合，为复杂电子元器件的可靠性保障提供了全新解决方案^[1]。在多模态图像处理技术的发展过程中，红外成像^[2]和 X 射线^[3]检测等方法的引入，显著提升了对较小的、隐蔽的缺陷的针对性检测能力。同时 PCB 缺陷检测技术正在从传统图像处理向深度学习与人工智能深度集成转型，检测精度与效率得以显著提升^[4]。YOLO 系列算法与轻量化 CNN（Convolutional Neural Network，卷积神经网络）模型在工业应用中成为主流，而多模态数据融合与边缘计算则代表了未来智能化、实时化的发展方向^[5]。

PCB 电路板虽然已经实现大规模无人化量产，但是其工序本身十分复杂，所以难以保证百分百的良品率，PCB 上有可能会存在多种类的缺陷。



图 1-1 无人化 PCB 检测

PCB 是电子产品的核心组件，它的制造质量直接影响设备可靠性。传统缺陷检测依赖人工目视或基于规则的自动光学检测，存在效率低、误检率高、对微小缺陷敏感度不足等问题^[6]。随着电子产品向高密度、微型化发展，缺陷类型日益复杂，如焊点虚焊、线路残铜、孔偏移等，传统方法难以满足工业高速、高精度检测需求。

深度学习技术的突破为 PCB 缺陷检测提供了新思路。其通过自动提取图像特征，显著提升了检测精度与效率。例如，基于卷积神经网络的模型在精确率、召回率等指标上已超越传统方法，能适应复杂工业环境下的噪声干扰。该技术的应用不仅能降低人工成本，还可推动智能制造的质量控制体系升级，具有重要的工程价值与经济效益^[7]。

1.2 PCB 缺陷检测研究的内容和现状

1.2.1 PCB 缺陷检测研究发展历程

在经典计算机视觉框架下，阈值分割、边缘检测与区域生长算法构成了缺陷特征提取的三重基石。阈值分割技术通过动态调整策略，有效解决了 PCB 表面金属反光与基材色差带来的分割难题；边缘检测器结合先进的抑制与滞后机制，精准定位导线边缘的细微缺陷；区域生长算法则通过优化种子点选取与生长准则，成功实现微小缺陷区域的完整分割。这些算法通过级联式预处理流水线，在保留关键特征的同时一定程度上降低了后续分析的计算负载。

随着检测场景复杂度指数级增长，单一可见光的检测性能越发局限。有学者使用红外热成像技术通过捕捉 PCB 工作状态下的热分布特征，成功破解了隐性缺陷的检测难题；X 射线层析成像系统采用先进的重建算法，实现了内部缺陷的三维可视化，检测精度达到微米级别。多光谱融合检测平台的出现，通过同步采集多种数据，构建了缺陷特征的互补表征体系，使复合缺陷的联合诊断准确率大幅提升。

随着时代发展，逐步引入了先进架构的实时检测系统，加入注意力机制与特征增强模块，在保持高速检测的同时，也能将微小缺陷的识别准确率进一步提升；还有模型轻量化方面的发展，其部署在边缘计算终端，能够满足产线的高速检测要求，即使是较快的流水线也能及时检测。这类实时监测系统在缺陷分类任务中展现出了很好的性能，能够识别特定缺陷，其细粒度分类准确率得到显著提升。

1.2.2 国内外研究现状

随着电子制造业的发展，国内对于 PCB 缺陷检测技术的需求日益增长，涌现了许多针对该方向研究创新的学者。武汉科技大学的余丽媛^[8]等人对 YOLOv5 算法进行改进，通过增强骨干网络高层与浅层的联系，引入优化后的自注意力机制，提高了对 PCB 缺陷的检测精确率和检测速率。

Shen M^[9]等学者提出了一种基于 YOLOv5 的 PCBA-YOLO 方法,可以有效提高 PCBA 缺陷检测的准确率。他们在 YOLOv5 的颈部网络中替换具有跨阶段部分结构的空金字塔池化模块,捕获多尺度下的分辨率特征,同时在主干网络中引入大核卷积,采用考虑角度代价的 SIOU 损失函数来提高模型的收敛速度。重庆邮电大学的刘辉^[10]等学者采用轻量化主干网络 StarNet 替换了 YOLOv8n 的主干网络,同时为了增强 PCB 检测的小目标检测能力,删除了大目标检测层,新增小目标检测层,既优化了网络结构,减少冗余又保持了检测性能。安徽理工大学的朱启玥^[11]等学者设计了一种基于双层路由注意力机制的特征提取模块,用于替换 backbone 网络中的 C2f 层,同时采用了 SPPFCSPC 替换 SPPF 层,更好地融合浅层和深层网络之间的特征信息。江南大学的李恩慈^[12]通过图像配准、缺陷定位和缺陷分类等方法,并变换图像尺度和改进的 SURF 算法,使配准速度提高了三倍。

国内的一些企业和研究机构也在积极探索 PCB 缺陷检测技术的创新应用,比如汇萃智能有限公司推出的 HCvisionQuick 视觉检测平台,集成了定位、检测、测量和识别功能,可应用于 PCB 板的缺陷检测,并且能够与产线内 PLC、机械臂、检测头等合作,更快更高效地完成识别检修任务。其系统搭载高精度工业相机和光源,结合自主开发的算法,实现了高稳定性的检测解决方案,尤其在应对高密度 PCB 板检测需求时表现突出。这些系统在电子制造业中得到了广泛应用,有效提高了 PCB 电路板的生产质量和效率^[13], 汇萃智能有限公司的视觉智能软件平台架构如图 1-2 所示。




图 1-2 汇萃智能有限公司视觉智能平台架构图

在国外，PCB 缺陷检测技术同样受到了广泛关注，同时许多学者发表了具有创造性的学术成果。Gaidhane Vilas H^[14]等人提出的 PCB 表面缺陷检测的相似性度量方法可以免于复杂的图像矩阵计算，并且能一定程度容忍局部变化和错位，其实验结果证明了所提方法对复杂元器件 PCB 图像中局部缺陷检测与定位的有效性。Van Truong Nguyen^[15]等人提出了用于测试不同场景之间的 PCBs 质量实时自动监管算法。其专注于分析 PCB 布局的密度和表面复杂度，利用 ORB 特征和 Brute-force 匹配方法将输入图像与 PCB 模板进行匹配，将 PCB 表面缺陷区域混合分割，从而达到精确贴装微型电子元件的效果。

实际应用方面，部分发达国家不断落实企业技术部署，比如德国国际知名的工业视觉检测方案提供商 ISRA VISION，其 PCB 检测系统支持高速实时检测（高达 120 片/min），并融合了光学与红外成像技术，在复杂工业环境中表现优异；美国国家仪器（NI）的 LabVIEW 平台结合机器视觉工具包，被用于开发 AOI 系统，通过模板匹配技术实现快速缺陷检测，但主要适用于标准化缺陷场景，对非标缺陷适应性有限。

1.3 论文的结构安排

本文针对 PCB 背景复杂、目标较小的特点，基于 YOLOv8s 模型进行了一定程度上的改进。

第一章：介绍本文的课题背景，当前发展状况及研究意义，包括介绍了几种主流的 PCB 电路板缺陷检测方法。

第二章：对目标检测相关理论知识进行介绍，介绍目标检测的发展历程，同时对传统的 YOLOv8s 模型进行分析。

第三章：采用了增加 CBAM 注意力机制、增加小目标检测层和替换 BiFPN 网络结构的 YOLOv8s 改进方法，以达到提升模型识别精度的目的。

第四章：交代了相关实验环境、实验配置和数据集构成，并针对第三章所采用的三种方法进行了消融实验，从多种性能指标分析实验结果。

第五章：基于 python 制作了用于交互的 PCB 故障检测的软件，能导入训练好的权重快速识别检查 PCB 电路板上的缺陷，并且能够汇总相关检测信息，以表格的形式导出。

第六章：对整体文章的内容做了大体总结，并从经济、社会和工程应用方面对改进模型进行分析，对下一步工作作出展望。

第二章 目标检测相关理论知识

2.1 目标检测技术演进与架构革新

目标检测作为计算机视觉的核心任务，其技术发展历经手工特征设计到深度自主学习的关键跨越，逐步实现从静态场景到动态实时检测的能力跃迁。

2.1.1 传统视觉方法

传统视觉方法往往利用存在差异的尺寸的滑动窗口框住图像，将被框选的部分作为候选区，其后提取它的关键特征，常见的有人脸常用的 Harr 特征和行人目标检测技术的 HOG 特征，然后再利用分类器进行识别。最后再使用传统分类器进行识别，常用的有 SVM 模型。

(1) 候选框的生成

在传统的目标检测技术中，候选框一般依赖于滑动窗口法，其基本原理是采用不同大小或者长宽比的窗口在待检测图片上进行等步长的移动，同时对这些图片进行区域分类，从而实现对整张图片的检测，如图 2-1 所示。

其缺点也是显而易见，因为不知道相对图片的大小和规模，所以每次检测图片使用的步长如果是恒定的话，会导致大量资源的浪费，或者是很多有待检测的特征没有提取到。传统的滑动窗口方法效率较低，而且不确定性较大，无法灵活应对不同大小的图片和特征物。^[16]




图 2-1 滑动窗口法图示

(2)特征提取

所谓特征提取是对每个窗口中的信息进行提取，这些信息主要包含颜色、纹理、形状等，相应地衍生出了基于这些特征的方法，还有其它更高层次语义的特征方法。

其中底层特征包含颜色和纹理；中层特征就显得繁复很多，包含如 PCA 特征、LDA 学习特征，都是经过对底层特征进行一定算法演化的来的加工过的图形特征；而高层次特征代表着对基础特征的进一步挖掘，更加符合作为一个人类对于语义的理解，比如对行人是否摔倒、工人安全帽是否佩戴进行语义表征。早期的传统目标检测算法中往往就是使用上述方法中的低层和中层特征表征，也就是依赖于手工设计的特征和基于学习的特征。

在特征工程时代，尺度不变特征变换、方向梯度直方图等算法突破几何约束，通过关键点描述与梯度统计构建鲁棒特征表达。Canny 边缘检测与形状匹配技术进一步强化轮廓捕捉能力，为后续机器学习方法奠定基础。

(3)分类判定

将图片信息提取出来后，需要对其进行分类判定。单目标判定时只需要区分当前窗口的对象是规定的检测类别还是背景即可，多目标判定时可能会存在多个目标框重叠的情况，需要使用 NMS (Non-Maximum Suppression, 非极大值抑制) 技术对多个目标框进行统合，只剩下一个目标框方便使用者观察，如图 2-2 所示。




图 2-2 非极大值抑制技术效果图

2.1.2 深度学习框架

随着机器学习技术的发展，人们发现人工智能产品在开发的过程中通常涉及不同的步骤和工作环境，这使得人工智能的开发极度依赖固定的环境，其安装、调整、部署、测试和准确迭代会花费大量时间，为了加速优化这个过程步骤，学界研究并发展了深度学习框架，并且完善和发展了多个基础工具平台。这是任何高度复杂技术发展过程中不可避免的

过程，因为想要推广一个技术的普适性，是不可避免地需要降低其门槛和操作难度，相应所谓的“工具包”或者操作平台就会诞生，这样部分学者们就可以只掌握工具的操作从而把精力投入到技术的研究的产品的创新。

而深度学习的框架主要有 Caffe、Torch、TensorFlow、PyTorch 等。因为本文 YOLOv8 模型基于 PyTorch 开发，所以这里着重介绍 PyTorch 框架结构。

(1) PyTorch 和 Tensorflow 框架的区别

PyTorch 是 Torch 的 python 版本，由 Facebook 开源的神经网络框架，主要是用于能够利用 GPU 加速的深度神经网络（DNN）。而其前身 Torch 是一个经典的能够对多维矩阵数据操作的张量库，在机器学习中有非常广泛的应用。PyTorch 与 Tensorflow 的静态图片处理不同，PyTorch 能够以动态图片的方式进行处理，是能够根据计算需要实时改变计算图的。^[17]同时 PyTorch 对于 python 的使用非常友好，能够与 python 语言相互沟通，拥有更适合 python 掌握者的框架适性。

(2) PyTorch 架构

PyTorch 主要由三部分构成：张量计算引擎、自动求导机制、神经网络高级接口，如图 2-3 所示。

其中张量计算引擎的基本对象是 tensor，可以类比于 array 之于 matlab。在实现 CPU 常用操作之外，PyTorch 还提供了 GPU 实现，这是深度学习进行高速矩阵计算必不可少的一步。^[18]自动求导机制能够自动它能够自动跟踪和计算张量上的所有操作，并构建计算图以便在需要时计算梯度，从而大大简化了深度学习模型的开发过程。神经网络高级接口则常用于网络结构，包括全连接层、卷积层、RNN 等。




图 2-3 PyTorch 框架示意图

2.1.3 实时检测框架

以 YOLO 系列为代表的实时监测框架已经颠覆了传统检测流程。它将任务重构为网格化回归问题，单次前向推理即可输出检测结果，在自动驾驶等实时场景展现优势。在历代 YOLO 模型中，YOLOv3 引入特征金字塔与 Darknet-53 主干网络，平衡了速度与精度；YOLOv5 优化数据实现了数据增强，对于工业场景的部署更为方便。

同时 SSD 作为单阶段目标检测框架的典型代表，通过多尺度特征图预测机制革新了检测范式，其核心设计在于利用不同层级的卷积特征图直接生成边界框与类别概率。网络架构中，浅层特征图负责捕捉小尺度目标细节，深层特征图则专注于大尺度目标定位，通过预设不同长宽比的锚框实现了多尺度覆盖。这种设计摒弃了区域建议生成环节，单次前向传播即可完成密集预测。相比于 YOLO 系列，SSD 采用 VGG16 等标准主干网络提取多级特征，并在预测层引入局部感受野扩展策略，通过 3×3 卷积核同时输出类别置信度与坐标偏移量，结合非极大值抑制后处理，有效平衡了检测精度与速度。

2.2 卷积神经网络基本结构

CNN 作为深度学习体系中的重要分支，其核心思想源于对生物视觉系统的仿生建模。其核心结构由特征提取模块与分类决策模块协同构成，前者通过多层卷积-池化组合逐步抽象视觉特征，后者利用全连接层完成语义映射。一般神经网络由输入层、隐藏层和输出层构成，如图 2-4 所示。




图 2-4 一般神经网络结构图

2.2.1 感受野

卷积神经网络与传统神经网络不同，它通过卷积核的滑动扫描机制构建局部感受野，在保留空间关联性的同时实现权值共享，显著降低了参数规模。卷积神经网络的种特性能高效处理二维网格结构数据，尤其在图像识别领域。

而感受野指的是卷积神经网络中一个单独的神经元在输入图像中映射的范围，其大小决定了所在网络层对输入图像的理解程度，也就是能够捕捉到多少范围以内的信息或特征，如图 2-5 所示。如果感受野较小，则适合捕捉更细节的特征，但是也有可能忽略掉更大范围内的信息；相对而言，较大的感受野能够捕捉到更全局的信息，相应的也会忽略掉更细节的特征。




图 2-5 感受野含义图

感受野的推导由下式可得：

$$r_l = r_{(l-1)} + (k_l - 1) \times \prod_{i=0}^{l-1} s_i \quad (2-1)$$

公式(2-1)中，第 r_{l-1} 层代表着 $l-1$ 感受野的大小， k_l 代表着第 l 层的卷积核大小， s_i 则代表着第 i 层的卷积步长。默认情况下 $r_0 = 1$ ， $s_0 = 1$ 。

同时还可以使用下列公式计算感受野的中心：

$$start_l = start_{l-1} + \left(\frac{k_l - 1}{2} - p_l \right) \times \prod_{i=0}^{l-1} s_i \quad (2-2)$$

公式(2-2)中计算的当前层(0, 0)座标处感受野中心位置，前置条件是卷积核长宽一致。其中， $start_l$ 是第 $l-1$ 层特征图左上角对应的感受野中心坐标，而 k_l 是第 l 层卷积核的大小， p_l 对应于第 l 层卷积 padding 大小。同样的，此时默认 $r_0 = 1$ ， $s_0 = 1$ 。

$$start_l^n = start_l + n \times \prod_{i=0}^{l-1} s_i \quad (2-3)$$

$$start_l^m = start_l + m \times \prod_{i=0}^{l-1} s_i \quad (2-4)$$

公式(2-3)(2-4)则代表在该层不断去检索下一个像素点的感受野中心，其坐标是 (n, m) 。

2.2.2 卷积层

卷积层通过可学习的滤波器实现局部特征探测，其核心机制包含局部连接与权值共享两大特性。每个卷积核在输入特征图上滑动时，仅与局部感受野内的像素进行点积运算，通过多通道叠加生成特征响应图。该设计大幅减少了参数规模。ReLU 等非线性激活函数的引入，赋予网络对复杂模式的表达能力。深层卷积逐步捕获从边缘、纹理到物体部件的高阶语义特征，形成层次化特征金字塔。

2.2.3 池化层

池化层通过下采样操作降低特征图空间维度，其核心价值体现在平移不变性增强与计算效率提升。最大池化选取局部区域最大值，保留显著特征的同时抑制噪声；平均池化计算区域均值，提供平滑的特征表达^[19]。实际使用较多的是最大池化层，其对于每个 2×2 的窗口中挑选出最大的数，写入到输出矩阵的相应元素的值^[20]，最后形成输出矩阵，示意图如图 2-6 所示。现代网络设计中，空洞卷积与步长卷积部分替代了传统池化功能，但池化层仍在小目标检测等场景中发挥重要作用。空间金字塔池化通过多尺度池化窗口，实现了对任意尺寸输入的适配。




图 2-6 最大池化方法示意图

2.2.4 全连接层

全连接层通过密集连接将分布式特征转化为分类概率，其本质是全局特征整合器。每个神经元与前一层的全部激活值相连，通过矩阵乘法实现高维空间映射，如图 2-7 所示。在经典架构中，连续的全连接层构成分类头部。现代轻量化网络常保留单个全连接层作为输出适配器，其余部分通过卷积操作实现等效的特征变换。




图 2-7 全连接层结构图

2.3 YOLOv8 总体架构

YOLOv8 是由 Ultralytics 团队于 2023 年推出的目标检测算法，其继承并优化了 YOLO 系列的单阶段检测框架，在实时性、检测精度与工程部署效率上均实现了显著突破。作为 YOLO 家族的最新成员，该算法通过引入模块化设计思想与动态优化策略，成为当前工业界与学术界广泛应用的检测模型之一。YOLOv8 的网络架构延续了经典的 Backbone-Neck-Head 三阶段范式，如图 2-8 所示。




图 2-8 YOLOv8 模型架构图

2.3.1 Backbone 层

YOLOv8 的主干网络基于改进的 CSPDarknet53 架构，继承并优化了 YOLOv5 的 CSPNet 设计思想。与 YOLOv5 不同的是，YOLOv8 针对计算冗余问题引入了 C2f 模块 (Cross Stage Partial Fusion) 代替了 C3 模块。C2f 相较于 C3，有更多的跳层连接，与更多的特征的 concat，梯度流更丰富，有助于更为丰富的特征融合和提取。该模块将输入特征图在通道维度上分割为两部分，一部分通过堆叠的 Bottleneck 残差单元进行特征提取，另一部分直接进行跨阶段融合。^[21]相较于 YOLOv5 的 C3 模块，C2f 模块通过梯度流分支的细粒度拆分，显著提升了梯度传播效率并减少大量计算量^[22]。在 YOLOv5 中，使用了 Focus 模块以进行切片操作减少计算量，而 YOLOv8 移除了 Focus 模块，采用更高效的卷积层来替代，简化了结构并提升了推理速度^[23]。

2.3.2 Neck 层

YOLOv8 的 Neck 层采用了 PAN-FPN 相结合的结构。FPN (Feature Pyramid Network, 特征金字塔网络) 结构的特征是自顶向下，也就是从深层特征开始不断逐层向上采样，同

时每一层的向上采样都会与前一层相融合，从而能够弥补语义信息和空间信息的缺失。而 PAN（Path Aggregation Network，路径聚合网络）与之相反，其采用的是自下而上的路径，从底向上逐层传递特征，与更高层的特征图相融合。而 YOLOv8 的颈部网络所采用的 PAN-FPN 能够通过双向路径的融合确保语义的保存，同时着丰富上下文和空间环境的信息，在一定程度上增强了模型的检测能力。

2.3.3 Head 层

YOLOv8 Head 部分相比 YOLOv5 改动较大，直接将耦合头改为类似 YOLOx 的 Decoupled-Head 结构，将回归分支和预测分支分离，并针对回归分支使用了 DFL（Distribution Focal Loss，分布焦点损失）策略中提出的积分形式表示法。之前的目标检测网络将回归坐标作为一个确定性单值进行预测，DFL 将坐标转变成一个分布。

2.4 本章小结

本章着重介绍了目标检测技术的历史演变过程。目标检测技术从传统手工特征驱动迈入深度学习时代，实现了从静态到动态的跨越。早期方法依赖滑动窗口与手工特征，通过分类器完成目标定位，但受限于计算冗余与泛化能力弱。VJ 框架以积分图加速特征计算，结合 AdaBoost 级联分类器，开启了机器学习驱动的实用化检测。随着深度学习的兴起，以 PyTorch 等框架为代表的自动求导与动态计算图进一步降低开发门槛，推动检测任务从多阶段流水线向单阶段高效推理演进。

同时本章介绍了卷积神经网络的基本结构和特征，包括感受野的原理，卷积层、池化层和全连接层在卷积神经网络中发挥的重要作用^[24]。再以此衍生到 YOLOv8 本身，介绍了其大体框架：Backbone-Neck-Head 三阶段范式，这样的基本架构保证了 YOLOv8 的稳定性和易于操作和更改的特性。

第三章 YOLOv8s 算法改进

3.1 前言

随着人工智能技术的日益发展，目标检测手段不断被使用在工业领域，其中 PCB 缺陷检测就是其中之一。尽管目标检测在该领域取得了显著的成就，但在处理小目标和复杂背景方面，众多算法仍然力不从心，存在误检率高、漏检率高的情况。

本章基于 YOLOv8s 模型进行改进，在提升目标检测精度方面着重笔墨，采用了多种方法手段：在模型的主干网络处和颈部网络处增加 CBAM 注意力机制，提升模型精度；在颈部网络引入新的卷积结构，加强处理小目标的能力；改进模型原有网络结构，替换为 BiFPN 特征网络。

3.2 CBAM 注意力机制

3.2.1 CBAM 注意力机制原理

注意力机制是一种基于对人类的认知过程进行模仿的视觉识别方法，能够加强整个神经网络在处理任务时的推理能力，其具体实现的表现形式是神经网络在处理任务时能够自适应地选择相对重要的目标，同时经过权重处理能够忽略掉相对不重要的输入，显著提升模型识别效果。

在神经网络模型中引入合适的注意力机制能够增强模型的整体效果和泛化能力。常见的注意力机制类型有：通道域、空间域以及混合域。其中通道域主要原理是在通道维度上进行操作，使用自我调整的权重信息来对通道的特征进行改变。空间域则更加关注图片信息中的不同区域的特征，有选择性地提取不同区域的特征来增强重要区域的特征。而混合域以 CBAM（Convolutional Block Attention Module）为代表，能够将不同数据域的信息相结合，在结合的过程中，CBAM 还可以使用自适应的方法决定不同域之间的重要性差异，给予每个数据域相应的权重，从而更加全面地获取特征图像^[25]。

CBAM 注意力机制主要包含了 CAM（Channel Attention Module，通道注意力模块）和 SAM（Spatial Attention Module，空间注意力模块）^[26]。在通道的重要性调配方面，CAM 来确定对于给定任务哪个通道需要赋更大的权重；SAM 则负责帮助模型理解空间结构中的位置关系，捕捉相应的空间特征。两者相辅相成，共同铸造了 CBAM 注意力机制，CBAM

的结构示意图如图 3-1 所示。




图3-1 CBAM注意力机制结构图

CBAM将输入的特征图 G_{in} 像经过CAM模块进行通道维度处理，产生了经过处理的新特征图像 G_1 ，再将该特征图像输入SAM模块生成新的特征图，该特征图再和 G_1 做相乘处理，最后得到所需的输出特征图像 G_{out} ，流程图如图3-2所示。




图3-2 CBAM注意力机制算法流程图

CBAM注意力机制的计算算式如下所示：

$$G_1 = M_c(G_{in}) \otimes G_{in} \quad (3-1)$$

$$G_{out} = M_c(G_1) \otimes G_1 \quad (3-2)$$

3.2.2 改进方法

考虑到PCB缺陷检测本身具备背景复杂、目标受干扰多等属性，决定使用CBAM注意力机制来对整体算法进行优化。具体原因如下：

(1)PCB缺陷检测具有目标小、背景复杂的特点，并且其分布可能密集，周围相似的目标较多，易于混淆，CBAM注意力机制适用于这样的场景。

(2)CBAM注意力机制具备简单高效、即插即用的属性，能够快速应用于网络结构，对网络的整体变动影响小，不需要规模地修改，操作十分方便。

(3)CBAM注意力机制相较于其他域注意力机制有着结合空间的通道维度的特点，能够囊括更多的信息量，提高算法精度效果更加明显。

如图3-3所示，本文将CBAM注意力机制引入主干网络的SPFF层前，以抑制无关量并且增强相关量的权重；同时在每个head的C2f层后加入CBAM注意力机制，使得颈部网络在输出至检测网络时对变量加以筛选。




图3-3 YOLOv8s-CBAM结构

3.3 小目标检测层

3.3.1 小目标检测层原理

传统YOLOv8s模型只有三个检测头，其特征图大小分别是 80×80 、 40×40 和 20×20 。这样的检测头固然能够正常完成大部分的检测目标，但是对于更小的检测目标其精度表现不佳，正如本文所研究对象PCB微小缺陷，其具有背景复杂和目标微小的特点。

为了增强小目标的检测精度可以在颈部网添加新的采样层、卷积层和C2f层，并将其与主干网络融合。小目标检测层拓宽了模型处理的深度，使得不同层次的模型能够更好地互补，融合后的特征图不仅能保留高层的语义信息，而且增强了底层空间细节，能够显著提升小目标图像的识别精度^[27]。

3.3.2 改进方法

小目标检测层的添加方法如图3-4所示。在YOLOv8原有三个检测头基础上，增加一个更高分辨率的检测头，对应图中的Detect 160×160 模块，其直接利用网络浅层的高分辨率特征，从而能够识别更微小的目标。同时因为前文已经添加了CBAM模块，所以在增加小目标检测层的时候应当考虑到CBAM模块的兼容性，即随着检测头的数量的增加再新增一个该模块，得益于CBAM模块的即插即用的特性，这样的操作能够顺利进行。

最后修改代码中相应连接层的输入指向层路，将原先颈部网络的第二个C2f模块的引出指向新增小目标检测层，将小目标检测层的引出重新指向Detect 80×80 模块前的CBAM模块，在新增的CBAM模块上再引出Detect 80×80 模块即可。




图 3-4 添加小目标检测层

3.4 BiFPN 特征融合网络

3.4.1 BiFPN 特征网络原理

BiFPN (Bidirectional Feature Pyramid Network, 加权双向特征金字塔)网络是一种高效并从多角度对特征进行融合的网络。

在传统的YOLOv8框架中，颈部网络源自YOLOv5结构，由FPN和PAN组成。FPN自下而上地传递语义信息，PAN结构自上而下地传递位置信息^[28]，如图3-5所示，这两种传递信息的方法充分地融合了不同结构中的同尺寸特征图，增强了主干网络输出信息的使用效率。但是值得注意的是，这种结构并没有融合跨尺寸特征图的能力，特征信息的使用效率还能够进一步地提高。




图3-5 YOLOv8传统金字塔网络

BiFPN网络不同于原始颈部网络，原始颈部网络平等处理每个融合特征，而BiFPN网络的作用于一些对网络贡献小的节点，削减了它们的权重，并增加了一条由输入点连接到输出点的通道，使得信息能够更迅速地流动，同时特征融合将不局限于跨层次的上下传递，还可以进行同层级的传输。因为各级特征在特征融合时所作出的贡献度各不相同，BiFPN网络在特征进入输出端的时候赋予其权重，确保其关键特征能得到强调^[29]。




图3-6 BiFPN特征融合网络

如图3-6，本文以P4层为例，计算 P_4^{td} 和 P_4^{out} 融合特征的值。

$$P_4^{td} = \text{Conv}\left(\frac{w_1 \times P_4^{in} + w_2 \times R(P_5^{in})}{w_1 + w_2 + \varepsilon}\right) \quad (3-3)$$

$$P_4^{out} = \text{Conv}\left(\frac{w'_1 \times P_4^{in} + w'_2 \times P_4^{td} + w'_3 \times R(P_3^{out})}{w'_1 + w'_2 + w'_3 + \varepsilon}\right) \quad (3-4)$$

公式(3-3)中， R 代表特征图的上采样或下采样操作； Conv 指代卷积操作； P_3^{out} 代表第三层的输出特征， P_4^{in} 代表第四层的输入特征， P_4^{td} 代表第四层的中间特征， P_4^{out} 代表第四层的输出特征， P_5^{in} 代表第五层的输入特征； w_i 和 w'_i 代表可用于学习的权重参数。通过上述计算，得到了第四层的中间特征和输出特征，其它层的特征参数可以依此类推。

3.4.2 改进方法

在PCB缺陷检测中，待检测目标往往占用像素数量相较于图片体积小很多，这种特性在越高分辨率的图片中越发明显。而BiFPN引入了可学习的权重参数，对不同层级的特征进行动态加权，避免传统FPN简单相加导致的特征稀释问题，这种聚焦于关键特征的机制在本文的复杂场景中能凸显。

如图3-7所示，按照上一小节的BiFPN网络结构方法，将连接层与C2f层的连接方式改变，在第15、18、22层的连接层前加入卷积层，在SPFF层后加入卷积层。因为需要考虑到上文已经引入了小目标检测层，整体网络已经增加了新的小目标结构，所以最后卷积层的数量比单独使用BiFPN网络结构要多一个。

在引入四个卷积模块后，调整各个连接层的输入模块对应位置，将连接层的原有的C2f模块输入改为卷积输入，同时第26、30层连接层处新接入一级卷积模块输出，以融合更多的特征量，达到提高平均检测精度的目的。




图3-7 YOLOv8s-CBAM-小目标检测层-BiFPN结构

3.5 本章小结

本章主要介绍了针对 YOLOv8s 精度提升的三种改进方法。通过结合混合域注意力机制 CBAM 实现了通道的动态分配和特征图像权重的添加,能够有效抑制背景噪声和聚焦关键区域;新增了一个小目标检测结构,从而形成新的 160×160 高分辨率检测头,颈部网络增加的上采样层、C2f 模块及跨层连接路径能够实现特征互补,检测更加微小的目;将 YOLOv8s 种传统的 FPN+PAN 结构替换为 BiFPN,重构了连接层与 C2f 层的连接方式,实现跨尺度特征交互。

第四章 实验结果与分析

4.1 前言

为了验证本文所提出的三种优化策略，本章设计针对添加CBAM模块、新增小目标检测层、替换BiFPN网络的单独效果和相互作用设计了消融实验，该实验方法可以更加直观地了解各个改进的作用效果。同时本章还会介绍一些评价指标的使用，有益于量化实验结果和理解比对模型效果。

4.2 实验环境

本文使用Pytorch框架进行YOLOv8s检测模型的搭建，利用矩池云平台实现视觉模型的在线训练。矩池云是一家专注于人工智能领域的GPU云服务商，能够提供稳定的人工智能云服务器，本文作者的电脑显存过小不能满足训练需求，因而选择租用矩池云GPU。

详细环境见表4-1。

表4-1 训练详细环境

环境种类	名称	具体信息
硬件环境	CPU	Intel(R) Xeon(R) CPU E5-2680 v4
	GPU	RTX A2000
	显存	12G
	内存	30G
软件环境	云操作方式	VNC viewer
	操作系统	Ubuntu20.04
	python	3.8
	pytorch	1.13.1
	CUDA	11.6
	cuDNN	8
	Numpy	1.26.2
训练设置环境	训练轮数	80
	训练步长	20

在实际操作中，因为数据清晰度高、标注准确，所以本文通过设置patience值为20，启动了YOLOv8s的早停机制来确定具体训练轮数。最终原始模型的训练模型停留在第74轮，因此设置训练轮数为80，并且在后续的实验过程中，各个模型均呈现收敛状态。

4.3 数据集构建

4.3.1 数据集介绍

实验数据来源于北京大学智能机器人开放实验室发布的公开PCB缺陷数据集，该数据集针对工业场景需求构建，包含6类典型的缺陷类别：“missing hole（缺孔）”“mouse bite（鼠咬）”“open circuit（开路）”“short（短路）”“spur（毛刺）”和“spurious copper（假铜）”^[30]，6类缺陷的经典案例如图4-1所示，分辨率范围为2048×1536至4096×3072像素，共计687张图片。




图 4-1 PCB 常见印制缺陷分类图

4.3.2 数据集拓展

考虑到工业现场的种种不确定性，可能会存在各类自然环境变化，最常见的有光线的强弱变化，所以本文对数据集进行了拓展，使用python脚本对各个图片进行处理，各新增了一张0.75-1.25倍亮度变化的数据集图片，如图4-2，最终数据集共计1374张。




图 4-2 PCB 数据集光暗程度拓展

在数据拓展后，得到总体缺陷数据分布，如图 4-3 所示，反映了工业场景中导电性缺陷的高发性。该数据集多样性强，包含单层板、多层板及柔性 PCB 样本；数据间缺陷尺度差异，缺陷尺寸跨度从 0.1mm 的微型毛刺至 5mm 的大面积缺孔都有，符合检测需求；同时背景复杂性，图像包含焊盘、丝印字符、过孔等干扰要素，模拟实际产线中 PCB 版中背景存在花纹、编号的噪声场景。




图4-3 数据集缺陷种类分布

4.4 评价指标

精确率 (precision)是预测为正类的样本中实际为正类的比例，反映预测结果的准确性。其计算公式为：

$$precision = \frac{TP}{TP + FP} \quad (4-1)$$

其中 TP 为真正例， FP 为假正例，当分类阈值升高时，模型仅保留高置信度预测，此时精确率理论上应提升，但可能以牺牲召回率为代价。

召回率($recall$)是实际为正类的样本中被正确预测为正类的比例，反映模型对正例的覆盖能力。其计算公式为^[31]：

$$recall = \frac{TP}{TP + FN} \quad (4-2)$$

FN 为假反例，当分类阈值升高时，模型更严格，召回率理论上会下降，因部分真正例可能被过滤。

在计算 mAP (Mean Average Precision, 均值平均精度) 前，应当先了解 AP (Average Precision, 平均精度) 的计算方法。平均精度，指的是所有图片内的具体某一类的 PR 曲线下的面积。而 PR 曲线是以召回率为横轴、精确率为纵轴的统计曲线^[32]，用以展示两者在不同分类阈值下的动态平衡。如果曲线越靠近右上角，表明模型能同时实现高精确率与高召回率，性能越优。曲线下围成的面积就是平均精度的大小：

$$AP = \int_0^1 P(r) dr \quad (4-3)$$

通过式(4-3)得到的 AP 值，可以代入下式计算 mAP 的大小：

$$mAP = \frac{\sum_{i=1}^C AP_i}{C} \quad (4-4)$$

mAP 值越大说明模型在检测方面的综合性能越好，是评价一个模型优劣的主要指标。

4.5 消融实验与结果分析

4.5.1 消融实验结果

为了验证第三章使用的 $CBAM$ 模块、小目标检测层、 $BiFPN$ 网络三种改进策略对原模型检测性能的提升效果，本章设计了8组消融实验，在扩展后的数据集上进行实验。为了兼顾到每次实验的偶然性，本章在实验时每组实验运行三次，取结果的中间值，在结合了时间和效率的基础上很大程度减少了偶然性对实验结果的影响。消融实验结果如表4-2所示。

表4-2 消融实验结果

YOLOv8s	CBAM	小目标检测层	BiFPN	精确率/%	map@0.5/%	召回率/%
√				80.00	93.90	94
√	√			89.10	93.80	95
√		√		81.90	95.90	98
√			√	86.00	93.70	95
√	√		√	87.30	93.80	95
√	√	√		91.40	93.50	94
√		√	√	82.90	96.10	98
√	√	√	√	87.10	96.70	98

从表中可知，YOLOv8s-CBAM的精确率提升了9.1%，同时可以发现CBAM模块在与其它模块共同作用时，对精确率的提升都较大，有理由推测CBAM在作用于YOLOv8s模型时能有效提升模型精确率；YOLOv8s-小目标检测层的mAP@0.5值提升了2.0%，召回率提升了3%，明显提高了均值平均精度；YOLOv8s-BiFPN的精确率提升了6.0%。最终改进后模型的性能指标与原模型对比，精确率提升了7.1%，map@0.5提升了2.8%，召回率提升了4%，结果证明了本模型的改进能够有效提高模型整体检测能力。




图4-4 改进后模型的P-R曲线图

由图4-4可以看出，在平均精度方面，网络检测缺孔为99.5%，鼠咬为95.3%，开路为97.7%，短路为99.5%，毛刺为90.0%，余铜为99.0%，总体的mAP为96.7%。模型在毛刺和

鼠咬方面有所欠缺。

4.5.2 归一化混淆矩阵分析

混淆矩阵是神经网络对于各个缺陷类别的预测结果展示，横轴表示为真实缺陷类别，纵轴表示为该模型预测的缺陷类别^[33]。在YOLOv8的评估体系中，混淆s矩阵单元格 M_{ij} 的数值直接反映了模型将实际属于类别 i 的样本判定为类别 j 的频次，而在归一化混淆矩阵中，则是以列为单位，按照下列公式对各个 M_{ij} 进行了归一化处理：

$$M_{ij}^{norm} = \frac{M_{ij}}{\sum_{k=1}^C M_{ik}} \times 100\% \quad (4-5)$$

在分析归一化混淆矩阵的时候，应当聚焦于以下几个观察角度：

(1)主对角线：

矩阵对角线 M_{ii} 单元格记录完全正确的分类计数。该区域数值密度越高，表明模型对该类别的特征提取能力和判别力越强，尤其在缺陷检测场景中，高主对角线值直接对应关键缺陷类别的精准识别。

(2)非对角线：

非对角线区域 $M_{ij(i \neq j)}$ 揭示误分类模式。例如在PCB检测中，若 M_{ij} 出现显著数值，则表明两类缺陷存在视觉特征重叠，需通过可视化误检样本分析具体混淆原因。

(3)行维度分析：

每行横向求和 $\sum_0^j M_{ij}$ 反映该类别在测试集中的实际分布频次。当某行总和显著低于其他行时，可能暗示数据集存在类别不平衡问题，需通过采样策略进行校正。

(4)列维度分析：

每列纵向求和 $\sum_0^i M_{ij}$ 体现模型对预测类别的倾向性。若某列总和异常偏高，可能表明模型对该类别存在过拟合倾向，或该类别在数据集中具有显著特征模式。



图4-5 改进后模型的归一化混淆矩阵

图4-5是改进后模型的归一化混淆矩阵，对角线的颜色更深，意味着绝大部分的待检测图片的标签都能够被分类到应当属于它的类别，而最底层的一行也存在部分数据，意味着有部分标签的归类失败了，亦或是未通过IoU的判定，存在一定的检测误差。


由图可知，改进后模型在缺孔标签处表现最好，在毛刺和鼠咬部分表现较差，鼠咬被识别为开路的比例占全部鼠咬标签的4%，说明鼠咬和开路缺陷易于混淆，还存在5%的漏检率，这导致改进网络对鼠咬缺陷的识别精度略低；同时毛刺的漏检率高达12%，说明网络对毛刺整体识别能力差，可以考虑增加毛刺的数据集数量，或者定向改进网络。

4.5.3 改进模型图片检测对比


为了验证该改进算法对PCB缺陷的检测效果，本文在拓展PCB缺陷数据集的测试集中选取了部分PCB图片检测，将其与原模型对比。6种缺陷对比如图4-6所示。

从改进前后的检测对比图可以看出，原模型经常会出现误检漏检情况，比如在开路检测图(e)中将开路缺陷识别成了鼠咬，而在新模型中成功检测出了开路缺陷。同时改进后模型在正确的检测中还具备着更高的置信度，比如图(a)(b)中原模型的开孔置信度分别是0.85、0.79、0.79、0.60，而在改进后模型中其置信度分别是0.87、0.81、0.83，置信度显著提高。


但是也可以观察到，改进后模型在图(j)毛刺检测中虽然相较于原模型有提升，但依然存在着漏检的问题，需要继续加强改进。




(a)原算法模型缺孔检测效果




(b)改进后模型缺孔检测效果




(c)原算法模型鼠咬检测效果




(d)改进后模型鼠咬检测效果




(e)原算法模型开路检测效果



(f)改进后模型开路检测效果



(g)原算法模型短路检测效果



(h)改进后模型短路检测效果




图4-6 原算法模型和改进后模型检测效果对比

4.6 本章小结

本章介绍了训练时的环境配置，使用云GPU、采用Ubuntu操作系统等，介绍了训练集的引入以及如何拓展训练集，调整亮度使其更加贴近现场环境。为了更好地理解实验结果，本章还介绍了精确率、召回率、mAP等指标。为了验证第三章中CBAM模块、小目标检测层、BiFPN网络三种改进策略的具体效果和各自作用程度，本章设计了8组消融实验。由实验结果可知，最终改进后模型的性能指标与原模型对比精确率提升了7.1%， $\text{map}@0.5$ 提升了2.8%，召回率提升了4%，结果证明了本模型的改进能够有效提高模型整体检测能力。

第五章 PCB电路板缺陷检测交互系统

5.1 前言

本章阐述了基于改进YOLOv8模型的PCB缺陷检测交互系统设计，该系统深度融合改进后的检测算法与可视化人机交互技术，能够实现以视觉检测为核心的诸多功能。系统采用模块化架构设计，集成图像预处理、智能检测、结果可视化及批量处理等核心功能模块，同时还能输出批量处理的各类缺陷统计报表，支持从单张样本调试到批量检测的大量作业需求。

5.2 PCB 缺陷检测交互系统设计 with 实现

本系统基于Python Tkinter框架构建图形化界面，集成了YOLO目标检测模型，实现了PCB缺陷检测的单张分析和批量处理功能，同时还具备对于批量检测数据的记录统计功能。系统采用模块化设计，主要包含以下核心部分：

(1) 界面布局和组件配置

左侧面板用于显示原始PCB图像，配备了“打开图片”按钮；右侧面板展示检测结果图像，配备“执行检测”按钮；底部控制台包含了批量处理控件、进度条和状态提示栏。




图5-1 初始化界面

如图5-1所示，通过filedialog模块实现了目录选择的功能，让用户点击“选择输入目录”和“选择输出目录”按钮时，能自动弹出相应选择框。采用双按钮工作模式，用于独立控

制单张检测与批量处理。程序还加入了流程进度反馈组件，同时包含可更新进度条和状态标签，让用户能够实时观察到检测进度。

(2) 单张图片检测

先对图像进行预处理，程序采用了OpenCV进行BGR-RGB转换，调用PIL库以实现图像缩放显示。显示完成后预加载改进后YOLOv8s训练模型，支持对预存图片的目标检测。得到图像处理结果后，通过results[0].plot()生成标注图像，再反馈给用户界面，如图5-2所示。




图5-2 单张图片检测

(3) 批量图片处理优化

程序采用多线程处理，使用了threading模块防止界面卡顿，定时通过os.makedirs方法检查目录是否还存在，预防程序因为目录结构变化而崩溃，同时增加了文件过滤机制，仅能够处理jpg，jpeg和png格式图像文件。

(4) 数据统计功能

程序通过解析results[0].boxes获取各类型缺陷数量，同时生成一份csv报表，如图5-3所示。报表中包含了每张图片的缺陷标签数量，自动统计缺陷总数并绘制统计图如图5-4所示。图中显示了各类型缺陷数量，因为这里举例的统计数据来源于验证集，因此可以结合该模型混淆矩阵比对，缺孔的整体精度最高，只有4例未被识别出来。鼠咬和余铜缺陷方面有部分的背景被误判，这显著降低了模型的准确率，应当考虑继续改进。开路缺陷检测中有20例未被检测到，短路缺陷中有11例背景被误判，毛刺缺陷存在着部分漏检问题，对模型精度影响较大。

S408								
	A	B	C	D	E	F	G	H
361	11_spur_08_brightened.1.20.jpg	0	0	0	0	2	1	
362	11_spur_09.jpg	0	0	0	0	4	0	
363	11_spur_09_darkened.0.77.jpg	0	0	0	0	4	0	
364	11_spur_10.jpg	0	0	0	0	5	0	
365	11_spur_10_brightened.1.19.jpg	0	0	0	0	5	0	
366	12_missing_hole_08.jpg	5	0	0	0	0	0	
367	12_missing_hole_08_darkened.0.87.jpg	5	0	0	0	0	0	
368	12_missing_hole_09.jpg	5	0	0	0	0	0	
369	12_missing_hole_09_brightened.1.04.jpg	5	0	0	0	0	0	
390	12_missing_hole_10.jpg	5	0	0	0	0	0	
391	12_missing_hole_10_darkened.0.87.jpg	5	0	0	0	0	0	
392	12_mouse_bite_08.jpg	0	5	0	0	0	0	
393	12_mouse_bite_08_brightened.1.18.jpg	0	5	0	0	0	0	
394	12_mouse_bite_09.jpg	0	5	0	0	0	0	
395	12_mouse_bite_09_brightened.1.23.jpg	0	5	0	0	0	0	
396	12_mouse_bite_10.jpg	0	5	0	0	0	0	
397	12_mouse_bite_10_brightened.1.13.jpg	0	5	0	0	0	0	
398	12_open_circuit_08.jpg	0	0	5	0	0	0	
399	12_open_circuit_08_brightened.1.09.jpg	0	0	5	0	0	0	
400	12_open_circuit_09.jpg	0	0	5	0	0	0	
401	12_open_circuit_09_brightened.1.12.jpg	0	0	5	0	0	0	
402	12_open_circuit_10.jpg	0	0	5	0	0	0	
403	12_open_circuit_10_brightened.1.02.jpg	0	0	5	0	0	0	
404	12_short_08.jpg	0	0	0	5	0	0	
405	12_short_08_darkened.0.95.jpg	0	0	0	5	0	0	
406	12_short_09.jpg	0	0	0	5	0	0	
407	12_short_09_brightened.1.01.jpg	0	0	0	5	0	0	
408	12_short_10.jpg	0	0	0	5	0	0	
409	12_short_10_darkened.0.92.jpg	0	0	0	5	0	0	
410	12_spurious_copper_08.jpg	0	0	0	0	0	6	
411	12_spurious_copper_08_brightened.1.06.jpg	0	0	0	0	0	6	
412	12_spurious_copper_09.jpg	0	0	0	0	0	6	
413	12_spurious_copper_09_brightened.1.19.jpg	0	0	0	0	0	6	
414	12_spurious_copper_10.jpg	0	0	0	0	0	5	
415	12_spurious_copper_10_darkened.0.77.jpg	0	0	0	0	0	5	
416	12_spur_08.jpg	0	0	0	0	4	0	
417	12_spur_08_darkened.1.00.jpg	0	0	0	0	5	0	
418	12_spur_09.jpg	0	0	0	0	6	0	
419	12_spur_09_brightened.1.06.jpg	0	0	0	0	6	0	
420	12_spur_10.jpg	0	0	0	0	5	0	
421	12_spur_10_brightened.1.14.jpg	0	0	0	0	5	0	
422	汇总	298	336	264	301	257	316	
423								

图5-3 缺陷统计报表




图5-4 缺陷统计图

5.3 本章小结

本章介绍了前端基于Tkinter框架构建的可视化界面，集成了双视图对比和实时进度监控功能，软件系统支持单张检测与批量处理双模式，前者实现即时缺陷定位与可视化标注，后者通过流水线作业自动完成图像遍历、结果渲染及统计报表生成，满足工业场景中灵活多样的检测需求。

第六章 总结和展望

6.1 总结

随着智能工业产业的不断发展，PCB 电路板成为日常生活中许多电子产品和工业领域不可或缺的器件，本文根据课题任务的要求，分析了现有 PCB 缺陷检测方法的不足，翻阅了众多论文资料，介绍了从传统的目标检测算法到现在的实时监测框架的发展历程。本文也学习了许多必备的基础知识，发现和体会到了新技术、新方法在 PCB 缺陷检测中的应用。但是 PCB 本身具有背景复杂和目标微小的特点，传统检测方法依然存在漏检误检的问题。

因此本文根据课题任务要求，研究了系统 Pytorch 环境搭建及 OpenCV 等库的安装，建立了稳定的算法平台，选取了适当的 PCB 缺陷数据集，并对其进行光照条件的拓展。同时选取了适当的技术路线和算法流程，对 PCB 传统缺陷检测方法中存在的漏检误检问题进行改进：新增了 CBAM 注意力机制层，对通道域和空间域的数据进行了加权处理；在颈部网络添加了小目标检测层；把 YOLOv8s 模型原有的 FPN+PAN 网络结构更新为 BiFPN 网络结构，有助于网络间信息更快传递。

本文还做了一系列消融实验，目的是对比原有 YOLOv8s 模型和改进后模型的效果，并且比较了各个改进方法之间的效果差距和侧重，使得实验内容更加具体全面。实验结果表明改进后模型相较于原模型精确率提升了 7.1%， $\text{map}@0.5$ 值提升了 2.8%，召回率提升了 4%，该实验证明了本模型的改进能够有效提高模型整体检测能力。

同时本文还设计了一个人机交互系统，引入训练权重后，对单个图片或批量待检目标进行检测输出，并且能够汇总相关检测信息，以表格的形式导出。

从经济角度看，改进后的 PCB 缺陷检测模型通过提升精确率、召回率及检测效率，显著降低了生产中的不良品率与人工复检成本，同时批量检测功能缩短了产品交付周期，增强了企业市场竞争力。基于 PyTorch 和 OpenCV 的开源技术方案降低了中小厂商的智能化升级门槛。

从社会层面看，自动化检测技术推动了 PCB 制造业向智能化转型，减少人工经验依赖的同时，通过提升缺陷检出率降低了电子产品安全隐患，保障消费者权益；人机交互系统简化了操作流程，使普通工人可快速掌握技术，而传统质检岗位需求减少倒逼劳动力向算法维护等高技能岗位流动，促进产业人才结构优化。

从工程应用方面看，本研究针对 PCB 背景复杂、目标微小等特点，通过引入 CBAM

注意力机制强化特征聚焦能力、增设小目标检测层提升灵敏度、采用 BiFPN 网络结构加速信息融合，系统性解决了传统方法漏检误检问题。集成的人机交互系统支持图片批量处理与检测结果可视化导出，为工业场景下的快速部署与质量追溯提供了参考。

6.2 展望

PCB作为现代电子设备的核心载体，其质量直接关系到终端产品的可靠性。本文提出的基于改进YOLOv8s的检测模型，通过引入注意力机制、优化网络结构和增强小目标检测能力，在检测精度方面取得了显著提升。展望未来，可以继续从以下三个角度进行继续改进：

(1)完善数据集的构建，可以对PCB图片进行旋转处理、增加噪声，更好地体现真实工业环境，扩建更加完善的数据集。其次应当计划引入更多先进的数据增强方法，增加数据多样性，为目标检测算法提供更为可靠的基础。

(2)增加研究方法策略，可以考虑加入新的注意力机制、引入更为复杂的网络架构，以进一步提升网络性能。

(3)还可以从轻量化模型等方面考虑优化，比如加入ghost网络结构，减小模型参数量。

参考文献

- [1] 李宇轩,曾庆涛,陆利坤.基于人工智能的 PCB 表面缺陷检测研究综述[J].北京印刷学院学报,2024,32(12):62-72.
- [2] 郭澎.红外成像技术在风电行业中 PCB 电路板维修应用分析.第五届中国风电后市场专题研讨会论文集[C].北京:中国农业机械工业协会风力机械分会,2018.
- [3] 刘红玉.X-RAY 检测技术在 PCB 板中的应用[J].电子质量,2022,(07):35-39.
- [4] 吴一全,赵朗月,苑玉彬,等.基于机器视觉的 PCB 缺陷检测算法研究现状及展望[J].仪器仪表学报,2022,43(08):1-17.
- [5] 姚文清.基于深度学习的印刷电路板缺陷检测研究[D].西安:西京学院,2023.
- [6] Zhitao J ,Meng W ,Shiming Z .A review of deep learning-based approaches for defect detection in smart manufacturing[J].Journal of Optics,2023,53(02):1345-1351.
- [7] 陈景胜.基于 CNN 和 Transformer 的轻量级 PCB 表面缺陷检测研究[D].长沙:湖南工业大学,2024.
- [8] 余丽媛,戴慷.基于改进 YOLOv5 的 PCB 缺陷检测算法研究[J].科学技术创新,2025,(05):105-108.
- [9] Shen M,Liu Y,Chen J, et al.Defect detection of printed circuit board assembly based on YOLOv5[J].Scientific Reports,2024,14(1):19287.
- [10] 刘辉,刘旭,李校林,等.改进 YOLOv8n 的轻量化 PCB 缺陷检测算法[J/OL].(2025-05-15)[2025-05-25].
<http://kns.cnki.net/kcms/detail/11.2175.TN.20250514.2011.032.html>.
- [11] 朱启玥,胡宗仁,朱家兵.基于改进 YOLOv8 的 PCB 缺陷检测方法[J/OL].(2024-10-09)[2025-05-25].
<http://kns.cnki.net/kcms/detail/50.1155.n.20241008.1306.005.html>.
- [12] 李恩慈.PCB 板质量检测方法研究[D].无锡:江南大学,2024.
- [13] 张璐.杭州汇萃智能科技有限公司:打造一流智能高速机器视觉平台[J].今日科技,2021,(04):50-51.
- [14] Gaidhane V H,Hote Y V,Vijander S.An efficient similarity measure approach for PCB surface defect detection[J]. Pattern Analysis and Applications,2018,21(01):277-289.
- [15] Nguyen T V,Bui A H.A real-time defect detection in printed circuit boards applying deep learning[J].EUREKA:Physics and Engineering,2022,(02):143-153.
- [16] 曹泽.基于深度学习的快递面单识别系统[D].南京:南京邮电大学,2023.
- [17] 邹文琪.基于深度学习的变压器局部放电分类及定位方法研究[D]. 临沂:临沂大学,2023.
- [18] 戴博闻.基于改进 SSD 算法的复杂环境下混凝土裂缝识别研究[D].南京:东南大学,2022.
- [19] 李欣然.基于深度学习的低照度图像增强技术的研究[D].桂林:桂林电子科技大学,2023.
- [20] 孟繁荣.基于图像显著性和增量深度学习的高分辨 SAR 图像变化检测[D].西安:西安电子科技大学,2018.
- [21] 李志斌.基于计算机视觉的扶梯乘降人员异常行为识别研究[D].安徽:安徽理工大学,2022.
- [22] Wang C Y, Liao H Y M, Wu Y H, et al.CSPNet: A New Backbone that can Enhance Learning Capability of CNN[C].CVPRW, 2020:1571-1580.

- [23] Casas E,Ramos L,Bendek E, et al.YOLOv5 vs. YOLOv8: Performance Benchmarking in Wildfire and Smoke Detection Scenarios[J].Journal of Image and Graphics,2024,12(02): 127-136.
- [24] 吴文韬.基于深度学习的宫颈细胞识别的系统设计[D].武汉:武汉大学,2020.
- [25] 黄熙.基于深度学习的 PCB 缺陷检测研究与应用[D].抚州:东华理工大学,2024.
- [26] Wujiu P,Yinghao S,Ranran C, et al.A SENet-TSCNN model developed for fault diagnosis considering squeeze-excitation networks and two-stream feature fusion[J].Measurement Science and Technology, 2023,34(12):125117.
- [27] 周昶雯,宋强,张月.基于改进 YOLOv8 的凝视雷达小目标检测算法[J].信号处理,2025,41(05):853-866.
- [28] 王发.基于机器视觉的玉米种子检测分选系统设计[D].保定:河北农业大学,2023.
- [29] 徐慕君,葛艳,时东亮.基 YOLOv8 的轻量级自适应权重手势识别模型[J/OL].计算机测量与控制, 2025(05):1-11.
- [30] 王悍悍,沈珊瑚,李明泽.基于改进 YOLOv8 的 PCB 缺陷检测算法[J].杭州师范大学学报(自然科学版), 2025,24(01):19-26.
- [31] 时广彬,任杨千千,石磊,等.基于机器学习的网球最佳回球落点决策模型[J].体育科学,2023, 43(06):53-60.
- [32] 张如琳,王海龙,柳,等.音乐自动标注分类方法研究综述[J].计算机科学与探索,2023,17(06):1225-1248.
- [33] 岳孟帅.基于深度学习的 PCB 缺陷检测算法研究[D].太原:太原科技大学,2023.

致 谢

本论文的顺利完成，离不开导师肖迪教授的悉心指导。肖老师以其深厚的学术造诣、严谨的治学精神以及高尚的师德风范，给予了我极大的启迪和帮助，令我受益匪浅。在毕业设计的推进过程中，我也走了许多弯路，浪费了一些时间，肖老师总会在此时以启发式的教学方法引导我，使我认识到其实还有更多的方法和更快捷的手段。在此，我谨向肖迪老师致以最诚挚的谢意，感谢她在整个论文研究过程中所付出的辛勤努力，以及对我无微不至的关怀。我还要感谢王建学长对我的帮助，王学长十分友善、有问则答，对于我提出的有关模型训练方面的问题都能够细致讲解，启发性地为我指明了研究的方向，对于训练过程中难以解决的 bug 王学长也不吝赐教。

此外，我要感谢我的家人，在四年的大学学习与生活中，我得到了家人们的鼎力支持。我是个恋家的人，每天晚上我都会给家人打去视频电话，每次通话父母都会和我说“今天有什么好玩的事吗”“晚上吃了啥”“早点睡”——最深的爱往往藏在寻常的唠叨里，他们或许不知道我所学的东西未来能做些什么，却总是愿意耐心地听完我学习上的苦恼，失利时父母会安慰我人生没什么非做不可的事，得意时他们又会劝我戒骄戒躁。

在大学四年的生活中，我也得到了学院各位领导、各位老师以及同学们的深切关怀与无私帮助。这些宝贵的经历与情谊，我将铭记于心。在此，我怀着无比崇敬的心情，向所有关心和帮助过我的老师和同学表达最衷心的感谢。