

南京工业大学

2025 届毕业设计（论文）

题 目：基于深度学习的钢材表面缺陷检测

专 业：自动化

班 级：自2103

姓 名：李天宇

指导老师：肖迪

起讫日期：2025年1月~2025年6月

2025 年 5 月

南京工业大学本科毕业设计（论文）原创性声明

本人郑重声明：所提交的毕业设计（论文），是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的作品成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

论文作者签名：

李天宇

日期：2025 年 6 月 4 日

南京工业大学本科毕业设计（论文）使用授权声明

本学位论文作者完全了解学校有关保留、使用毕业设计（论文）的规定，同意学校保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。本人授权南京工业大学教务处可以将本毕业设计（论文）的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编毕业设计（论文）。

论文作者签名：

李天宇

导师签名：

肖迪

日期：2025 年 6 月 4 日

日期：2025 年 6 月 4 日

基于深度学习的钢材表面缺陷检测

摘 要

钢铁作为工业生产的核心材料，其表面缺陷检测对保障产品质量至关重要。本文采用 YOLO11n 模型，利用 NEU-DET 数据集进行了训练，实现了对钢铁表面缺陷的检测。

为了解决钢材表面缺陷检测任务中存在精度低、模型尺寸大等问题，本文在 YOLO11n 基础上进行了一定改进。在模型的颈部网络中引入 CA 注意力机制，提升其对复杂缺陷特征的提取能力；并利用 Ghost 卷积模块替换主干网络中的标准卷积，在大幅削减模型参数量的同时，减少了模型的检测推理所需时间。实验结果显示，改进后的模型在 NEU-DET 数据集上的平均精度均值为 79.0%，精确率提升至76.7%，较原模型分别提高0.1%和2%；模型参数量与计算量则分别下降9.6%和11.1%，有效说明了改进方案是合理有效的。为了研究模型的泛化能力，本文还在 GC10-DET 数据集上开展实验，结果显示改进模型的性能表现与 NEU-DET 数据集上的实验结论保持一致，充分证明了改进方案的通用性优势。

在模型构建完成后，本文还基于 PyQt5库开发了检测系统用户交互界面，支持图像上传、实时检测与结果可视化，为钢材表面缺陷检测提供了一种高效、轻量化的解决方案，具有一定的实用价值。

关键词：钢材表面缺陷 深度学习 YOLO11 PyQt5

Design of surface defect detection based on deep learning

Abstract

As the core material of industrial production, surface defect detection of steel is crucial for ensuring product quality. This article uses the YOLO11n model and trains it on the NEU-DET dataset to detect steel surface defects.

Aiming at addressing the challenges of low accuracy and excessive model scale in steel surface defect detection, this paper proposes specific improvements based on the YOLO11n model. Introducing a Coordinate Attention mechanism in the neck network of the model to enhance its ability to extract complex defect features; And using Ghost convolution module to replace Conv convolution in the backbone network significantly reduces the number of model parameters while reducing the time required for model detection and inference. The experimental results show that the improved model has an average precision mean of 79.0% on the NEU-DET dataset, and the precision has been improved to 76.7%, which is 0.1% and 2% higher than the original model, respectively; the number of model parameters and computational complexity decreased by 9.6% and 11.1% respectively, effectively demonstrating that the improvement plan is reasonable and effective. To investigate the model's generalization ability, this paper also conducted experiments on the GC10-DET dataset. The results showed that the performance of the improved model is consistent with the experimental conclusions on the NEU-DET dataset, fully demonstrating the universality advantage of the improved scheme.

After the model construction was completed, this article developed a user interaction interface for the detection system based on the PyQt5 library, which supports image upload, real-time detection, and result visualization, providing an efficient and lightweight solution for steel surface defect detection, with certain practical value.

Keywords: Steel surface defect; Deep learning; YOLO11; PyQt5

目 录

摘 要.....	I
Abstract.....	II
第一章 绪论.....	1
1.1 课题的研究背景和意义	1
1.2 国内外研究现状	1
1.2.1 目标检测算法研究现状.....	1
1.2.2 钢材缺陷检测算法的发展.....	2
1.3 本文章节安排.....	4
第二章 YOLO11算法原理	5
2.1 注意力机制	5
2.2 卷积层	6
2.3 YOLO11算法原理与结构.....	6
2.3.1 主干网络.....	8
2.3.2 颈部网络.....	9
2.4 本章小结	9
第三章 改进的 YOLO11n 目标检测模型	10
3.1 模型整体设计	10
3.2 坐标注意力模块	11
3.3 Ghost 卷积模块.....	12
3.4 本章小结	14
第四章 YOLO11n 目标检测算法实现	15
4.1 实验环境	15
4.2 数据集	15
4.3 评价指标	17
4.3.1 检测精度指标.....	17
4.3.2 检测速度指标.....	19

4.3.3 复杂度指标.....	19
4.4 参数设置	20
4.5 实验结果	20
4.5.1 消融实验.....	20
4.5.2 对比实验.....	24
4.5.3 泛化能力测试.....	24
4.6 本章小结	25
第五章 系统实现与应用测试	26
5.1 系统设计	26
5.1.1 需求分析和可行性研究.....	26
5.1.2 总体方案设计.....	26
5.2 界面设计	27
5.3 功能实现	28
5.3.1 检测参数设置.....	28
5.3.2 原始图片显示.....	29
5.3.3 图像检测.....	29
5.3.4 检测结果显示.....	29
5.4 项目生成可执行文件	30
5.5 项目运行测试	31
5.6 本章小结	35
第六章 总结与展望	36
6.1 总结	36
6.2 展望	37
参考文献.....	38
致谢.....	41

第一章 绪论

1.1 课题的研究背景和意义

作为现代工业体系的关键基础材料，钢材在机械制造、航空航天、能源化工等国民经济支柱产业中具有不可替代的支柱性作用。然而在生产过程中，受多种因素影响，钢材表面容易存在裂纹、结疤、辊印等不同类型的表面缺陷。表面缺陷不仅影响产品外观完整性，也一定程度上降低了钢材的材料力学性能^[1]，因此对钢材表面缺陷进行精准识别对提升产品质量具有重要意义。

传统的检测方式主要依赖工人对钢材进行目视检查，但这种方式难以满足工业环境中高速生产的需要，且存在漏检率高、效率低等显著弊端。尽管有学者尝试采用红外检测、漏磁检测等技术手段，但这些方法往往受限于环境因素和检测速度，未能得到大规模应用^[2]。随着我国工业水平的稳步提升和科技的持续进步，我国在工业智能化及其相关领域取得了巨大的进步，制造与检测的智能化已经成为了企业未来发展的必然趋势。近年来，深度学习领域取得了巨大突破，基于深度学习的目标检测算法已在多种工业情形中得到广泛应用。将深度学习技术应用于钢材缺陷检测，不仅能够显著提高检测效率和准确性，还能有效降低漏检率，从而为提升产品质量和生产效率提供关键支持。这不仅有助于推动我国钢铁行业向智能化、高质化方向转型升级，还具有重要的战略价值。

1.2 国内外研究现状

1.2.1 目标检测算法研究现状

目标检测的核心任务在于对输入的图像数据中的物体进行位置的精准定位，并标注出物体的类别。作为计算机视觉领域的基础任务，目标检测在目标跟踪、图像分割、事件检测等任务中扮演着基础性支撑角色^[3]。凭借其在图像中定位和识别物体的优异性能，目标检测模型已成为当前许多基于深度学习的表面缺陷检测算法（如布料、钢材等）的基础。

传统目标检测算法的处理流程通常涵盖目标区域选择、特征提取及分类决策三个核心阶段^[4]。不过，这类算法面临较多挑战，像计算成本较高、在复杂工业

环境中的适应性欠佳等问题，难以契合实际应用的要求^[5]。

随着高性能计算硬件的发展和大规模标注数据集的涌现，基于深度学习的目标分类与检测算法逐步取代传统图像识别方法，与传统算法相比，深度学习方法具有更高的检测精度和更快的检测速度，在许多传统分类识别问题中都取得了显著更好的结果^[6]。基于深度学习的目标检测算法有两阶段和单阶段两种类型。

两阶段算法的核心思路是将目标检测过程分解为两个阶段：首先生成潜在的目标候选区域，然后对这些候选区进行类别分类。典型的算法包括：R-CNN（Region-based Convolutional Networks）^[7]、Fast R-CNN^[8]、Faster R-CNN^[9]。这类算法因其处理流程因包含候选区域生成等多步操作，导致检测速度相对较慢，即使是经过改进的 Faster R-CNN 模型，虽然比起原本的 CNN 模型已经快上了几倍，但每秒帧数（Frames Per Second, FPS）大部分不会超过20，极大限制了其在实时性要求较高的场景中的应用价值。其检测精度较高的优势，更适用于对检测精度有较高要求的场景。

单阶段算法直接在图像中预测物体的位置和类别，摒弃了生成候选区域的步骤^[10]。典型的算法包括：YOLO（You Only Look Once）^[11]和 SSD(Single Shot Multi Box Detector)^[12]。其核心优势在于检测流程高度简化，推理速度快，能够满足工业实时检测、自动驾驶等对实时性要求极高的应用场景。然而，由于缺乏候选区域的精细化筛选过程，单阶段算法的检测精度通常略低于两阶段算法，在小目标检测和密集目标场景中表现相对薄弱。YOLO 是首个单阶段算法，其将整张图片划分为一定数量的网格，每个网格预测一定数量的边界框，再通过置信度阈值筛选边界框，完全舍弃了候选区域生成的步骤，大幅降低了检测用时。虽然 YOLO 在最初的几个版本中结构粗糙，精度很低达不到使用标准，但经过历年来的迭代，目前检测精度已经相当可用，且检测速度通常达到100帧每秒，远超 Faster R-CNN 等两阶段算法。SSD 算法则采用了先验框机制，并使用了多尺度特征图来捕捉不同大小的目标。

1.2.2 钢材缺陷检测算法的发展

两阶段目标检测算法以 Faster R-CNN 为代表，具有很高的检测精度，但其检测速度相对较慢，且模型尺寸较大，这在一定程度上限制了其在工业场景中的应用。针对上述实际应用中的问题，研究人员围绕提升算法效率与轻量化开展了

改进。张鑫等人^[13]将残差网络引入 Faster R-CNN 中,应用于钢材表面缺陷检测,该方法在检测准确率上较传统方法有小幅提升,但由于模型参数增加,导致实时性较差。Shi 等人^[14]将 ConvNeXt 架构应用于 Faster R-CNN,并引入卷积块注意力模块(Convolutional Block Attention Module, CBAM)和 K-means 聚类优化锚点,进一步提高了检测精度和速度。韩强等人^[15]将 VGG-16 应用在 Faster R-CNN 中,并在最终检测阶段级联了两个阈值不同的检测网络,检测精度达到了 98.29%,但检测速度仍较慢。齐继阳等人^[16]将 CBAM 和双向特征金字塔网络(Bidirectional Feature Pyramid Network, BiFPN)组成了一个新的网络并将其和原 Faster R-CNN 的主干网络相结合,对此前难检测的目标实现了检测精度的提升。

尽管两阶段方法在检测精度上具有显著优势,但其模型尺寸大、检测速度慢的问题仍然是阻碍其在工业应用中的主要因素。

单阶段目标检测算法无需先生成候选区域,可直接在图像中预测目标的位置和类别,将目标检测任务简化为了单一过程。这类算法有着检测速度较快这一显著优势,所以在实时性方面表现更好。当下,与之相关的各项研究着重把关注点放在了如何提升其检测精度方面:刘宁等人^[17]在 YOLOv5 中用 Focal-EIOU (Focal-Efficient Intersection over Union) 损失函数替换了 CIOU (Complete Intersection over Union) 损失函数并加入全局注意力机制,有效提高了模型检测精度。周孟然等人^[18]在 YOLOv5 中加入了坐标注意力机制,并用 FReLU (funnel ReLU) 激活函数搭建了 CBF (Conv+BatchNorm+FReLU) 卷积模块,改进后模型精准率和平均精度均值提升明显。Yang 等人^[19]通过结合 CNN 和 Transformer,实现了多尺度特征的融合,并将一种轻量级的 Faster-C2f (FC) 模块,引入了 YOLOv8s 模型,在确保检测准确性的同时,实现了轻量级模型。姚若禹等人^[20]在 YOLOv8n 中使用 Slim-neck 范式替换了原本的颈部网络,并将 ODConv (Omni-Dimensional Dynamic Convolution) 与 C2f 模块结合,保证了轻量化的同时, mAP50 相较原模型提高了 1.7%。邹彦艳等人^[21]则在 YOLOv8 中将 C2f 模块和可变形卷积网络 (Deformable Convolution Network, DCN) 相结合,并用 GIoU (Generalized Intersection Over Union) 损失函数替换了 CIOU 损失函数,降低了漏检误检率。Li 等人^[22]则将多尺度特征提取 (Multiscale Feature Extraction, MSFE) 模块引入到了 YOLOv5s 中,并且提出了一种新的特征提取模块 EFF (Efficient Feature Fusion),

在保持参数不增加太多的情况下，提高了整体检测精度。

总体而言，单阶段目标检测算法在实时性方面表现出色，但检测精度仍有提升空间。未来的研究方向可能包括进一步优化模型结构，以在检测速度和精度之间取得更好的平衡。

1.3 本文章节安排

本文就钢材表面缺陷检测问题分为六个部分：

第一章绪论部分，首先深入剖析课题的研究背景与核心意义，阐明钢材表面缺陷自动化检测的重要价值。然后梳理国内外研究现状：一方面介绍目标检测算法的发展脉络；另一方面分析现有算法研究在钢材缺陷检测领域的优势与不足。

第二章 YOLO11 算法原理中，解析了 YOLO11 算法的核心架构与技术原理。此外，还从理论上解释了注意力机制和卷积层的数学特性和运行逻辑，以阐明它们在特征提取中所扮演的关键角色，进而为后续优化模型的设计工作提供坚实且可靠的理论支撑，助力后续改进工作开展。

第三章提出了基于 YOLO11n 的改进模型。首先介绍模型整体设计思路，然后详细分析了 CA 模块和 GhostConv 模块的工作原理及其与传统模块相比的优势，说明了选择这两个模块的原因。

第四章进行了算法实现与实验分析，先是对开展实验所依托的环境配置以及所选用的数据集进行详细介绍，为后续实验的科学性提供必要前提。其次介绍评估模型所要采用的评价指标。最后通过消融实验、对比实验与泛化能力测试，验证 CA 模块与 GhostConv 模块的有效性，并分析改进的模型在精度、速度及轻量化上的综合优势。

第五章系统实现与应用测试，首先通过需求分析明确系统功能与技术可行性，继而说明检测流程的具体实现，包括模型加载、推理计算及结果处理等。最后，通过开展实际测试工作，确保系统能用于钢材表面缺陷检测工作。

第六章总结与展望总结，先是对全文的研究工作进行全面且系统的归纳总结，梳理各个章节所取得的研究成果以及核心要点。同时，对研究过程中所暴露出的不足之处进行反思，客观指出当前研究存在的局限性与待改进之处，为后续研究提供参考思路。

第二章 YOLO11算法原理

2.1 注意力机制

注意力机制（Attention Mechanism）其核心原理是使模型在处理输入数据时能够动态调配计算资源，将重点聚焦于关键信息，同时过滤次要或无关的内容，是一种模拟人类信息处理模式的计算技术。这一机制通过构建“查询 - 键 - 值”（Query-Key-Value）交互模型，实现对输入数据的加权聚合，从而增强特征表示的针对性与判别性。在深度学习中，注意力机制可以增强模型对关键特征的提取能力，这让其成为提升模型性能的重要技术手段。

经过多年发展，注意力机制已经形成了成熟的技术体系，由多种类型组成。目前比较有代表性的注意力机制有 SENet、CBAM、PSA、SimAM(Simple Attention Module)等。

注意力机制按其工作原理不同，可以大致分为通道注意力，无参注意力，自注意力，空间注意力，混合注意力等类型。不同的注意力机制其计算效率和适用范围各有差异，要根据背景复杂度、模型轻量化要求等来选择适配的注意力机制。

空间注意力机制将关注点集中于特征图的空间位置分布，抑制和任务无关的区域，突出对任务有关的区域。

通道注意力机制以 SENet 为典型代表，这种注意力机制关注特征图的不同通道，生成各个通道的权重^[23]。在这一过程中，更重要的通道获得的权重更高，将在之后的处理中被更多关注，同时不重要的通道将会被抑制以减少干扰。

混合注意力机制一般融合了多种注意力机制，希望通过不同注意力机制的互补优势来提高整体表现，可能包含了通道、空间、自注意力等机制。代表方法是 CBAM，由一个通道注意力与一个空间注意力模块串联构成。不过该种注意力机制也更加复杂，提高了运算成本。

无参注意力机制区别于上述复杂的注意力机制，以 SimAM 为代表的新型方法通过设计轻量化的计算流程，无需引入额外可训练参数即可生成注意力权重。在保证模型性能的同时，显著降低计算开销，为轻量化模型设计提供了高效的解决方案。

2.2 卷积层

卷积层 (Convolutional Layer) 作为深度学习模型的核心组成单元, 在特征提取过程中发挥着基础性作用。从数学本质来看, 卷积是一种描述两个函数局部相关性的积分变换运算, 其核心思想是通过加权求和的方式捕捉输入信号的局部结构特征。在图像处理场景中, 卷积层的具体操作表现为卷积核与输入图像的逐元素点积运算: 运用卷积核, 使其在输入的特征图上, 以滑动窗口的形式开展逐点卷积操作, 最终生成蕴含空间局部相关性的特征图。

在标准的卷积之外, 为了提高深度学习模型的表现, 还演变出了许多卷积变种, 如线性可变形卷积 (Linear deformable convolution, LDCnv), 小波卷积 (Wavelet convolutions, WTConv), 空间和通道重建卷积 (Spatial and Channel reconstruction Convolution, SCCnv) 等。

提高卷积神经网络表现的一种方法是增大卷积核的大小来模拟视觉 Transformer 中的全局感受野, 但这种方法在卷积核大小大于 7×7 后效果不明显, 且开销过大。为突破这一局限, WTConv 被提出, 其核心创新在于利用小波变换替代传统卷积操作, 来实现大型感受野。相较于标准卷积, WTConv 显著扩展了感受野范围, 更增强了其特征提取的能力。

标准卷积的另一个问题是卷积核形状大小固定, 且初始采样位置也固定, 无法更高效的提取特征。因此提出了 LDCnv, 用于生成任意大小卷积核和不同初始采样位置, 在保持计算效率的同时显著提升了模型对复杂场景的适应能力。

2.3 YOLO11算法原理与结构

在工业质检场景中, 钢材表面缺陷检测需兼顾高精度、实时性的要求。两阶段算法虽然检测精度很高, 但其计算复杂度高、推理速度慢, 难以满足产线实时性要求。而 YOLO 系列算法作为单阶段目标检测算法, 虽然精度差于 Faster R-CNN 等模型, 但显著提升了处理速度, 且复杂度低, 部署较为方便, 更适合对实时性要求严苛的钢材表面缺陷检测任务。因此本文选择 YOLO 系列算法来进行钢铁表面缺陷的检测。

YOLO11是 YOLO 系列的较新版本, 于2024年发布, 它在 YOLOv8和 v10基础上进行扩展和增强, 引入了新的架构, 并优化了参数, 这使得 YOLO11拥有更

高的精度，更快的检测速度，而且模型参数量更少，适合部署在各种环境中。具体来说，YOLO11引入了全新的 C3k2(Cross Stage Partial with kernel size 2)模块和 C2PSA(Convolutional block with Parallel Spatial Attention)模块，这些模块能够增强特征提取，提高模型性能。YOLO11一共有 n、s、m、l、x 五个版本，各版本的模型参数不同，n 版本参数最小，而 x 版本参数最高，尽管增加模型参数量有助于提高检测精度，却会造成检测速度下降，并且模型复杂度的上升会对硬件性能提出更高要求。本文选用了检测精度、速度和参数量都比较均衡的 YOLO11n 模型，因为钢铁表面缺陷检测一般用于工业制造现场中，对实时性要求高，且考虑到经济效益，模型不能过于复杂。YOLO11n 作为 YOLO 系列的算法之一，其核心仍然由四部分构成，输入层(Input)、主干网络(Backbone)、颈部网络(Neck)和检测头(Head)^[24]，其网络结构图如图2-1所示。原始图像经过输入层进行数据增强，尺寸变换等预处理，后输入主干网络，通过卷积神经网络对预处理后的图像进行多层次特征提取，生成不同分辨率的基础特征图。通过颈部网络进一步特征融合后，最终交给检测头，依据提取出的特征，通过回归与分类操作完成目标位置坐标和类别概率的预测并输出结果。




图2-1 YOLO11n 网络结构图

2.3.1 主干网络

YOLO11 的主干网络进行了改进，将 YOLOv8 使用的 C2f（Faster Implementation of CSP Bottleneck with 2 convolutions）模块替换为了 C3K2 模块，并在 SPPF（Spatial Pyramid Pooling - Fast）层后添加了 C2PSA 层。当图像输入主干网络后，会经过卷积层处理，将特征图的空间尺寸缩减。随后进入 C3K2 模块，在维持特征图空间尺寸不变的同时，实现高效的特征提取并降低计算复杂度。经过后续的卷积层与 C3K2 模块处理，特征图的空间尺寸逐步缩减，在进入 SPPF 模块前，长宽已变为原图像的三十二分之一。在 SPPF 模块中进行池化操作后，进入 C2PSA 层增强特征图中的空间注意力，提升了模型对图像中重要部分的关注后，主干网络结束。

1.C3K2模块

YOLO 中一项重要的模块是跨阶段局部网络（Cross Stage Partial Networks, CSP），作为一种优化卷积神经网络效率与性能的有效方法，其核心理念在于通过特征图的分割操作与跨阶段融合机制，来实现计算冗余的降低与梯度信息多样性的增强。该方法通过将特征图划分为不同分支，使一部分分支直接参与跨阶段的特征传递，另一部分分支进行卷积操作后的特征变换，再通过融合操作整合不同路径的信息，既减少了重复计算带来的资源消耗，又通过保留原始特征的完整性与卷积特征的抽象性，提升了模型的特征表达能力，为目标检测任务提供了兼具高效性与准确性的架构设计思路。

CSP 是最基础的模块，用于特征提取和减少计算量。在其基础上衍生出了 C3（CSP Bottleneck with 3 convolutions）用三层卷积来增强特征传递。C3K 则在 C3 基础上允许使用不同大小的卷积核，更加灵活。C2f 则简化了结构，来加速处理过程。

C3K2 模块则是一种最新的 CSP 变体模块，它是 YOLOv8 上的 C2f 模块的进一步发展，结合了 C2f 的速度优势和 C3K(CSP bottleneck module with customizable kernel sizes)的灵活性，能够有效地减少计算量并提取特征。

C3K2 中的参数设置为 True 时，将使用 C3K 进行计算，这时可以使用不同的大小的卷积核，带来了灵活性。设置为 False 时则相当于 C2f，计算速度更快。结构如图2-2所示。




图2-2 C3K2模块结构

2.C2PSA 模块

在 C2(CSP Bottleneck with 2 convolutions)模块内加入了一个金字塔压缩注意力 (Pyramid Squeeze Attention, PSA)机制就构成了 C2PSA 模块，使模型能够更有效地关注图像中的重要区域，从而提高目标检测精度。其结构如图2-3所示。




图2-3 C2PSA 模块结构

2.3.2 颈部网络

颈部网络负责将不同分辨率的特征图进行整合，并传递给检测头进行预测。具体而言，颈部网络会对低、高分辨率特征图分别实施上、下采样处理，通过将不同分辨率特征图拼接在一起，使得特征充分融合，提高对各种尺度特征的预测能力。最后将由检测头进行预测，它负责处理颈部网络输出的特征图，并最终给出预测框和分类标签。

2.4 本章小结

本节主要简述注意力机制与卷积层基础，同时阐述了 YOLO11的算法原理与结构，其通过 C3K2、C2PSA 等模块的改进，相较之前的版本的 YOLO 模型在精度、速度和轻量化间实现平衡，为后续研究奠定理论基础。

第三章 改进的 YOLO11n 目标检测模型

3.1 模型整体设计

尽管 YOLO11n 模型在目标检测上已有很大优势，但仍存在局限性，其中小目标检测精度较低是主要挑战。在目标检测领域中，小目标通常指的是占据像素面积较小、细节信息有限的对象，如尺寸小于 32×32 像素目标^[25]。钢铁表面缺陷中也存在这类小目标缺陷，比如裂纹、麻点等，如图3-1所示，大部分的目标的高和宽都较低。这类密集的小缺陷有效特征较少，让模型难以准确识别，通常来说小目标的检测精度只有普通大目标的一半左右，亟待改进。




图3-1 钢铁缺陷目标高宽比例

另一个问题是模型复杂程度，如果进行改进后模型复杂度大幅上升，对实际工业部署也是不利的。因此在精度提升或基本不变的前提下，要尽可能降低模型复杂度。

本文在 YOLO11n 基础上进行了一些改进，来改善由于复杂小目标多，而导致钢铁表面缺陷检测精度低的问题。注意力机制能够使模型聚焦于缺陷区域的特征，有效增强对目标的定位精度。一般采取的如 SENet 等通道注意力机制会因为忽视目标的位置信息而表现不佳。而 CA 注意力机制则在其基础上加入了位置信息，理论性能更好，因此在颈部网络中加入了 CA 注意力机制，以提高检测精度。然而，CA 机制的引入在提升检测精度的同时，不可避免地增加了计算复杂度，导致模型推理速度下降，且计算成本仍较高。为平衡精度提升与计算效率，将原本的标准卷积模块更改为了 GhostConv 模块，降低参数量，同时提高模型的检测速度。增加了 CA 机制和换用 GhostConv 后的模型网络结构图如图3-2所示，其

中红色部分表示原 YOLO11n 的所有标准卷积均替换为了 GhostConv，橙色部分是在颈部网络中在原16层，19层和22层的 C3K2部分后加入的 CA 注意力机制。




图3-2 改进后的 YOLO11n 网络结构

3.2 坐标注意力模块

YOLO11n 的颈部网络借助 C3K2模块与卷积操作完成特征提取与融合，为进一步提升模型检测性能，在该部分加入 CA 注意力机制。

CA 注意力机制在通道注意力的基础上融入空间位置维度信息，能够更有效地提升模型对目标的定位精度，其结构如图3-3所示，其中 w 和 h 分别是特征图的宽和高， c 是特征图的通道数， r 是缩减比例，此处必须要保证通道数大于缩减比例，否则无法进行操作。

CA 注意力机制会先利用两个一维全局池化操作，分别将垂直和水平方向的输入特征聚合为两个独立的方向感知特征图，然后将这两个特征图进行拼接并用卷积压缩通道数为 c/r ，通过批量归一化和非线性化后进行分离，将完整的特征

向量重新分为水平和垂直两个方向的向量，再通过卷积将通道数调整回 c ，经过 Sigmoid 函数处理，最后将两个注意力图接着被乘到输入特征图上来增强特征图的表示能力^[26]。

该机制架构较为简洁，主要借助池化、拼接、卷积等操作从特征图中生成注意力权重，相较于其他注意力机制较为轻量化，可在避免显著增加计算负担的前提下实现检测精度的提升^[27]。




图3-3 CA 注意力模块结构

3.3 Ghost 卷积模块

传统卷积在工作时通过卷积核对图片进行大量滑动卷积，在卷积核和输入通道数增加时，计算量会大幅上升。

为实现模型轻量化并提升推理速度，本文将标准卷积模块层替换为了 Ghost 卷积模块。作为一种高效的轻量化特征提取技术，Ghost 卷积通过廉价线性变换，来降低计算成本。

廉价线性变换在实际操作中通过使用深度卷积来实现。这种卷积技术的核心特征在于对输入特征图的每个通道独立进行卷积，得到和输入特征图通道数一致的输出特征图。以一张三通道彩色图片为例，如果想要得到4张特征图，进行标

准卷积则需要通过4组滤波器来完成,1组滤波器中包含3个 3×3 的卷积核,分别对应输入图像的3个通道,具体如图3-4所示。而如果使用深度卷积,则只使用3个滤波器,每个滤波器中仅包含1个 3×3 的卷积核来独立处理一个输入通道,具体如图3-5所示。

由于深度卷积中每个通道仅由一个卷积核处理,其计算步骤显著减少,参数量也大幅降低,所以可以相对标准卷积来说是一种廉价线性变换^[28]。传统的卷积神经网络在卷积操作后还会有批归一化和非线性激活的步骤,而廉价线性变换则只使用了卷积,不含批归一化和非线性激活,因此经过的步骤也更少。但其主要问题是产生的特征图数量和输入通道数一致,无法扩展。不过由于 GhostConv 中使用深度卷积函数仅为了生成和核心特征图相同的 Ghost 特征图,无需扩展生成更多的特征图,因此规避了深度卷积存在的问题。




图3-4 标准卷积工作流程




图3-5 深度卷积工作流程

其工作原理与标准卷积层的对比如图3-6所示,首先将用少量标准卷积生成包含关键信息的核心特征图,然后在每个核心特征图上进行廉价线性变换,生成

Ghost 特征图，最后将核心特征图与 Ghost 特征图拼接，生成的特征图与标准卷积相当，但计算量显著下降了^[29]。

标准卷积的计算量 F_1 如式 3-1 所示，其中 m 是输出特征图的通道数， w 和 h 分别是输出特征图的宽和高， c 是输入特征图的通道数， k 是卷积核大小。

Ghost 卷积的计算量由 F_2 和 F_3 两部分组成，如式 3-2，3-3 所示。 F_2 为生成核心特征图所需的计算量，其中 s 为 Ghost 特征倍数，和进行多少廉价操作相关。 d 为廉价操作的核大小，通常为 3。可以看出，标准卷积一步计算出了 m 个通道的输出特征图，而 Ghost 卷积则通过了两步操作，当卷积核大小和通道数都较大时，Ghost 卷积的计算量将小于标准卷积。

$$F_1 = m \times w \times h \times c \times k \times k \quad (3-1)$$

$$F_2 = \frac{m}{s} \times w \times h \times c \times k \times k \quad (3-2)$$

$$F_3 = \frac{m}{s} \times w \times h \times (s - 1) \times d \times d \quad (3-3)$$




图3-6 标准卷积层与 GhostConv 模块结构对比

3.4 本章小结

本章介绍了针对钢铁表面复杂小目标检测精度问题，在 YOLO11n 基础上进行的改进。颈部网络引入 CA 注意力机制以增强目标定位精度，同时替换标准卷积为 GhostConv 模块降低计算成本、提升推理速度。两项改进在保证精度提升的同时实现模型轻量化，为后续检测性能优化提供了具体的网络架构方案。

第四章 YOLO11n 目标检测算法实现

4.1 实验环境

使用 Pytorch2.0.0，在笔记本电脑戴尔 G15上进行 YOLO11n 检测模型的搭建。具体的实验环境见表4-1。

表4-1 实验环境


类别	相关配置
操作系统	Windows10
CPU	Intel i7-11800H
内存	32GB
GPU	NVIDIA GeForce RTX3060Laptop
编程语言	Python 3.10.16
深度学习框架	Pytorch 2.0.0
GPU 加速库	CUDA11.8 CuDNN8.7.0

4.2 数据集

本文采用东北大学公开的 NEU-DET 钢铁缺陷数据集进行实验。该数据集包含1800张分辨率为 200×200 的灰度图像，依据缺陷类型划分为6类常见钢材表面缺陷，分别为麻点(pitted-surface)，裂纹(crazing)，夹杂(inclusion)，斑块(patches)，划痕(scratches)和轧制氧化皮(rolled-inscale)，各缺陷的外观特征如表4-2和图4-1所示，每种缺陷各300张图像^[30]。以8:1:1的比例，将数据集随机划分为训练、验证、测试集，即训练集1440张，验证集和测试集各140张图像。

表4-2 钢材表面缺陷特征

缺陷类别	外观特征
麻点	表面分布密集的微小凹坑或孔洞
裂纹	表现为钢材表面交错的网状裂纹，通常呈细密分布
夹杂	钢材表面或内部嵌入的异物颗粒，表现为不规则的凸起或凹陷区域，颜色与基体存在差异
斑块	钢材表面局部区域的颜色异常，通常呈圆形斑块状
划痕	细长的线性痕迹，方向多与轧制方向一致，深度较浅但长度较长，可能伴随金属光泽变化
轧制氧化皮	形状多样多为鱼鳞状，也有块状或者条状




(a) 裂纹; (b) 夹杂; (c) 斑块; (d) 麻点; (e) 轧制氧化皮; (f) 划痕

图4-1 NEU-DET 中六种钢材表面缺陷图像示例

为验证模型泛化性能,本文引入 GC10-DET 数据集开展实验。GC10-DET 是在钢板制造过程中收集到的表面缺陷数据,共计2294张分辨率为 2048×1000 的灰度图像,总共包含冲孔(punching-hole),焊缝(welding-line),月牙弯(crescent-gap),水斑(water-spot),油斑(oil-spot),丝斑(silk-spot),夹杂(inclusion),压痕(rolled-pit),折痕(crease),腰折(waist folding)共10类表面缺陷^[31],如图4-2所示。

由于 GC10-DET 数据集为 VOC (Visual Object Classes) 格式,所有图片依照类别分开放在各文件夹中,且标签以 xml 格式保存,这与 YOLO 格式不同,还需要进行转换,将标签提取出来并写为 txt 格式。在转换格式并剔除无效数据后,以8:1:1的比例,将数据集随机划分为训练、验证、测试集,即训练集1833张,验证集和测试集各229张图像。



(a) 冲孔；(b) 焊缝；(c) 月牙弯；(d) 水斑；(e) 油斑；(f) 丝斑；(g) 夹杂；
(h) 压痕；(i) 折痕；(j) 腰折

图4-2 GC10-DET 中十种钢材表面缺陷图像示例

4.3 评价指标

为衡量模型检测性能并开展算法间性能比较，需采用多种评价指标进行综合评估。本文从模型复杂度、检测精度及推理速度三个维度进行综合对比分析，确保多维度评估体系的全面性。检测精度方面选取精确率（Precision）、平均精度均值（Mean Average Precision）、召回率（Recall）等指标。每秒帧数（Frames Per Second）用作检测速度指标。FLOPs（Floating Point Operations）、模型参数量（Params）及权重文件大小等指标则展示了模型复杂度。

4.3.1 检测精度指标

当模型对输入图像执行目标检测任务时，会生成大量带有置信度分数的预测边界框。首先通过预设的置信度阈值对预测结果进行筛选，剔除置信度低于阈值的无效预测。随后，基于预测边界框与真实标注框之间的空间重叠程度，即交并比（Intersection over Union, IoU），结合预设的 IoU 判定阈值，将预测结果划分

为四种类型。如表4-3所示。TP(True Positive): 真实类别为正例且预测类别也为正例的正确检测样本, 即目标被准确识别并定位的实例; FP(False positives): 真实类别为负例但被误判为正例的样本, 表现为将背景区域或非目标类别误判为目标的情况; FN(False negatives): 真实类别为正例但未被模型检测到而误判为负例的漏检样本, 即实际存在的目标未被识别的情况; TN(True negatives): 真实类别为负例且预测类别也为负例的正确样本, 即背景或非目标区域未被错误检测的实例。这其中正例是需要检测的目标, 负例是背景或者其他目标。

表4-3 混淆矩阵表

		真实值	
		Positive	Negative
预测值	Positive	TP	FP
	Negative	FN	TN

基于样本预测正确与否的四种情况, 能够对目标检测模型的检测精度进行量化评估。在检测精度的评估中, 常用的指标包括精确率、召回率以及平均精度均值。这些指标通过整合不同预测类别的数量关系, 从不同角度刻画模型的检测效能: 精确率反映模型预测的准确性, 召回率衡量模型对目标的覆盖能力, 而平均精度均值则通过综合多个类别在不同置信度阈值下的平均精度, 形成对模型整体检测性能的全面度量。这种多指标结合的评估框架, 为客观比较不同目标检测模型的优劣提供了科学的量化标准。

精确率 (Precision) 表示模型预测的样本中 TP 所占的比例, 该指标反映了模型准确识别正类目标的能力^[32]。当精确率为0时, 意味着模型将所有预测为正类的样本均判定为假正例 FP, 即不存在正确识别的目标; 而当精确率为1时, 表明所有被预测为正类的样本均为真正例 TP, 不存在误判情况。精确率越高, 说明模型在正类样本预测中真正例的占比越高, 将负类样本错误判定为正类的情况越少, 体现了模型对正类目标预测的严谨性。其计算公式如式4-1。

$$Precision = \frac{TP}{TP+FP} \quad (4-1)$$

召回率 (Recall) 表示模型从所有实际正类样本中正确检测出的正例比例, 该指标体现了模型对正类目标的完整检测能力。当召回率为0时, 意味着模型未能检测到任何实际存在的正类样本; 而当召回率达到1时, 表明所有真正例均被正确识别, 不存在漏检情况。召回率越高, 说明模型对正类目标的漏检率越低, 能够更全面地捕捉到实际存在的正例样本, 反映了模型在正类目标检测中的完整

性与包容性。计算公式如式4-2。

$$Recall = \frac{TP}{TP+FN} \quad (4-2)$$

平均精度均值(Mean Average Precision)是基于精确率和召回率两个基础指标, 由于精确率和召回率往往互相矛盾, 当精确率高时召回率低^[33], 即要求精确率, 减少误检时, 可能漏检较多; 而要求召回率, 减少漏检时, 可能误检较多。而 mAP 就很好的结合了这两点, 精确率和召回率均在可以接受的范围。mAP 从字面意思上看即对所有的 AP (Average Precision) 取平均值, 计算公式如式4-3。而 AP 通过计算该类别的精确度-召回率 (P-R) 曲线的面积得来, 计算公式如式4-4。AP 越大, 精确度和召回率在整体水平上也较高, 反应了该类别的精度, 因此 mAP 就可以反映整个模型的精度。

由于 P-R 曲线和设定的 IoU 阈值相关, 自然 AP 和 mAP 在计算时也和 IoU 阈值有关, 本文所用的为常见的 mAP50, 即 IoU 设定在0.5时计算出的 mAP。

$$AP = \int_0^1 P(R)d(R) \quad (4-3)$$

$$mAP = \frac{\sum_{i=1}^n AP_i}{n} \quad (4-4)$$

4.3.2 检测速度指标

除检测精度指标外, 模型检测速度的重要性不容忽视。在工业现场的实时检测场景中, 只有达到足够的图像处理速度, 才能满足实际应用需求。FPS 作为衡量算法实时性能的关键参数, 反映了模型每秒处理的图像数量, 该指标数值越高, 表明检测速度越快。

FPS 的计算公式如下: 总处理帧数 (Framenum) 除以模型运行的总耗时 (ElapsedTime), 其中 Framenum 代表处理的图像总数, ElapsedTime 为模型从启动到结束的累计时间。

$$FPS = \frac{Framenum}{ElapsedTime} \quad (4-5)$$

4.3.3 复杂度指标

FLOPs(Floating Point Operations)、参数量 (Params) 和权重文件大小都和模型的计算复杂度有关, 可以用来评估模型的轻量化水平。FLOPs 指浮点运算次数, 反映了模型的所需计算量。FLOPs 越大, 表明模型在数据处理时需要执行更复杂

的矩阵运算、卷积操作等计算任务，需要更多的计算资源。参数量是指模型中需要训练的参数总数，通常情况下，模型规模越大，其所需的参数量也会越多。权重文件大小是保存模型参数所占用的存储空间，越复杂的模型，占用的存储空间越大，较小的权重文件也有利于减少存储和传输的开销。模型越复杂，计算量和参数量越大，对运行的设备要求就更高，不利于部署在工业现场中。因此在检测精度和速度差别不太大的情况下，应该尽可能让模型轻量化，来获得更好的经济性。

4.4 参数设置

在开始训练前，先要设置好优化器，`epochs`，批次大小等一系列超参数。本文的所有模型训练均采用同样的超参数，优化器设置为随机梯度下降法，学习率、动量因子、衰减因子都设置为默认参数值，批次大小为16，总训练轮数为300轮。此外，为了让模型更稳定，适应真实数据分布，在最后十轮关闭数据增强。

开始训练后，会加载模型，并从指定的路径中获取训练集和验证集的图片，标签。每个迭代轮次，都从数据加载器中按照图片批次大小取出训练集图片和标签文件，采用数据增强，随机拼接四张训练图像以提升模型对多尺度目标的适应性，并辅以归一化、随机翻转、色彩空间变换等操作增强数据多样性。随后将图片送入模型进行前向传播，输出预测边界框与类别概率，通过 CIoU 损失函数计算出预测值与真实值的误差。然后进行反向传播，计算参数的调整量，用优化器更新网络权重，完成调整后继续进行下一 `batch` 的训练。在这轮的所有 `batch` 都完成后，在验证集上进行预测，计算出 `mAP` 等指标，并进入下一迭代轮次，模型的预测能力就这样在每个迭代轮数中不断提升。

4.5 实验结果

4.5.1 消融实验


为了证明第三章中所采用的改进方法的有效性，以 YOLO11n 为基线模型，进行了消融实验，结果如表4-4所示。第二组实验中加入了 CA 注意力机制，对 `crazing` 这类小目标的检测精度上升，相较基线模型的结果，`mAP50`提高了1.95%，`Recall` 提高了2.52%，`Precision` 提高了0.4%，但增加了模型参数量，使得检测速

度略微下降，FPS 下降了18.58f/s。第三组实验中将标准卷积换成了 Ghost 卷积，和基线模型相比，模型参数下降了12.8%，FLOPs 下降了12.7%，权重文件下降了11.5%，但 mAP 也降至75.69%，说明 GhostConv 可以有效降低模型复杂度，节约计算成本，但会导致检测精度下降。第四组实验在基线模型中同时引入 CA 注意力机制与 GhostConv 模块，结果显示：在 mAP50、召回率、精确率较原模型实现轻微提升的同时，模型参数量、浮点运算量以及权重文件大小均显著下降，且 FPS 维持在124.18f/s。这表明改进后的模型在轻量化设计与检测精度之间达成有效平衡，兼具高效推理能力与可靠检测性能。

表4-4消融实验结果

算法	mAP50 /%	Recall /%	Precision /%	权重 /MB	Params/ ($\times 10^6$)	FLOPs/ G	FPS (f/s)
Yolo11n	78.89	73.53	74.70	5.2	2.58	6.3	133.65
Yolo11n+ca	80.84	76.05	75.10	5.3	2.59	6.3	114.98
Yolo11n +ghostconv	75.69	68.63	74.92	4.6	2.25	5.5	156.38
Yolo11n+ca +ghostconv	79.07	73.76	76.69	4.7	2.26	5.6	124.18

图4-3为检测结果对比。从图上预测框位置和置信度大小，可以看出改进后的模型在原模型检测效果上有一些提升，且在 inclusion 类别中提升较为明显，其他类别的检测效果则基本一致。



(1) 原图像 (2) YOLO11n 检测结果 (3) 运用 CA 和 GhostConv 改进后检测结果

图4-3 检测结果对比

为直观呈现改进模型与原始模型的性能差异，对两者的损失曲线及性能曲线展开对比分析，如图4-4与图4-5，其中蓝色曲线为原模型，橙色曲线为改进后模

型。从损失曲线特征可知，改进模型的损失值下降速率更快，体现出更高的学习效率；同时，其损失曲线的波动幅度显著小于原始模型，表明训练过程的稳定性更强。

从性能曲线表现来看，改进模型在精确率、召回率及 mAP_{50} 三项关键指标上的提升速率均显著优于原始模型，且曲线走势更为平缓，反映出更强的学习能力与更高的训练稳定性。




图4-4 损失曲线对比





图4-5 性能曲线对比

通过图4-6所示的 P-R 曲线对比，也可以看出改进后模型的 P-R 曲线更靠近


右上角,包围面积更大,尤其在 inclusion 和 scratches 两项最明显;而 pitted_surface 和 rolled-in_scale 两类则略差于原模型。分析原因,可能是 inclusion 和 scratches 两类相较其他四种缺陷而言,面积比较大,容易被 CA 注意力机制注意到; pitted_surface, rolled-in_scale 和 crazing 这三类可能是由于部分图片和背景区分度不高,且缺陷太小,导致提取到了目标以外的背景。这也说明了注意力机制的作用是有限的,且在进一步加入如 ghostconv 等轻量化模块后会削弱注意力机制的作用。在综合考虑精确率和召回率的情况下,改进后模型略优于原模型。



(a) 原模型 (b) 改进后模型

图4-6 P-R 曲线对比

此外还利用热力图作为验证有效性的手段之一,通过热力图可以直观地展示模型对输入图像中各个区域的关注程度,偏蓝则关注度低,偏红则高。如图4-7所示的热力图分别取自原模型第19层和改进模型第20层。改进模型的第20层添加了 CA 注意力机制,可以发现,相较原模型,改进后的模型对关键特征的关注度更高,且对周围无关目标的关注度降低了,说明加入的改进是有效的。



(a) 原图像 (b) 原模型 (c) 改进后模型

图4-7 热力图对比

4.5.2 对比实验

为了进一步验证改进后的 YOLO11n 模型的有效性,选取了同样较新且检测效果好的 YOLOv8n 和 YOLOv10n 模型进行对比实验,结果如表4-5所示。就处理速度而言, YOLOv8n 的 FPS 达到了153.26f/s,是几种模型里最高的,但参数量同时也较大。而复杂度方面, YOLOv10n 的 FLOPs 达到了7.7G 是四种模型中最大的,但精度却最低。YOLO11n 虽然 FPS 较低,但 FLOPs 较 v8n 和 v10n 均下降,而且 mAP50也较前两种模型提升。改进后的 YOLO11n 模型精度最高,参数量和 FLOPs 均最低。可以说明改进后的模型较为合理。

表4-5 几种 YOLO 模型对比实验

算法	mAP50 /%	Recall /%	Precision /%	权重 /MB	Params/ ($\times 10^6$)	FLOPs/ G	FPS (f/s)
Yolov8n	77.02	71.28	76.01	5.8	2.90	7.6	153.26
Yolov10n	75.36	64.55	77.33	5.3	2.59	7.7	146.89
Yolo11n	78.89	73.53	74.7	5.2	2.58	6.3	133.65
Yolo11n+ca +ghostconv	79.07	73.76	76.69	4.7	2.26	5.6	124.18

4.5.3 泛化能力测试

为了验证改进后模型的泛化能力,选用了 GC10-DET 数据集,进行 YOLO11n 和改进后模型的实验对比,参数设置和 NEU-DET 数据集训练时相同,验证结果如表4-6,图4-8 所示。可以看出,二者相比,改进后模型的参数量、权重文件大小、FLOPs 都较 YOLO11n 更小,并且 mAP50、Recall、Precision 更高。结果表明,改进后的模型具有一定的通用性。

表4-6 改进 YOLO11n 模型的泛化能力测试

算法	mAP50 /%	Recall /%	Precision /%	权重 /MB	Params/ ($\times 10^6$)	FLOPs/ G	FPS (f/s)
Yolo11n	61.9	51.2	68.0	5.2	2.58	6.3	185.8 3
Yolo11n+ca +ghostconv	65.4	52.9	65.3	4.7	2.27	5.6	178.5 8




图4-8 改进 YOLO11n 模型的泛化能力测试

4.6 本章小结

本章围绕 YOLO 模型开展实验研究，5 个小节分别为实验环境搭建、数据集选用、评价指标设定、参数设置、实验结果分析，详细说明了实验的环境背景和实验步骤及结果。

首先说明了实验所用的平台和数据集。数据集选择了 NEU-DET 和 GC10-DET 两种数据集，分别用作消融对比实验和泛化测试，并详细说明了两种数据集中目标的特点。

实验方面先通过消融实验验证了 CA 注意力与 GhostConv 模块的有效性，并用实际的检测结果图、性能曲线、P-R 曲线和热力图这多种对比方式，可视化的说明了引入改进是有效且可行的，针对其中暴露出的问题也进行了解释。随后通过对比实验表明改进模型在精度、轻量化程度上优于 YOLOv8n、v10n 等版本，还通过泛化能力测试进一步证实了其通用性。

第五章 系统实现与应用测试

5.1 系统设计

5.1.1 需求分析和可行性研究

1. 需求分析

本文所设计的钢铁缺陷检测系统，需要根据用户输入的图片，检测出其中的钢铁缺陷类别。系统界面首先要具备能让用户方便地导入图像的功能，并支持常见图像格式。还要在界面上清晰展示检测结果，像缺陷的类别、位置、置信度等信息，并同时展示原图片，方便用户对比。此外还应提供检测记录的保存和展示，方便用户查看检测结果。最后要考虑到系统的易用性，界面设计需简洁直观，易于操作，在出错时提醒用户哪里发生了错误，让普通用户也能轻松上手。

2. 可行性研究

在该系统的可行性方面，从技术角度来看，该检测系统使用的 YOLO11n 是一个成熟的目标检测模型，依赖文件小，便于集成到 Python 程序中，并且检测速度快，识别准确率高。Python 中也有众多用于图像处理和数据处理的库，例如 OpenCV、NumPy 等，能够辅助完成图像导入、处理和结果展示等功能。因此具备一定的技术可行性。从经济角度来看，该系统对计算机硬件的要求低，且系统的操作流程简单明了，符合用户的使用习惯，不会给用户带来过多的操作负担，培训成本和维护成本也较低，因此经济可行性较高。

5.1.2 总体方案设计

本系统利用 YOLO 算法作为系统的检测模块，用于检测图片中的钢铁表面缺陷。整体程序使用 Python 进行编写，而图形界面使用 PyQt5 进行开发，缩短开发时间并且具有用户友好的特性。本系统设计了两种检测模式，可以检测单张图片，或者遍历一整个文件夹的图片，并将结果输出到指定的文件夹中。

系统的界面设计应该简洁、直观，方便用户进行操作，可以分为几个区域，图像显示区会同时显示导入的原图像和检测后的图像，配置区域让用户可以进行图像导入，模型权重文件的选择等功能，还需要有一区域将检测后的信息显示以

文本形式展示。

系统运行流程如图5-1所示，系统启动后直接显示主界面，检测前需先导入模型权重文件并校验有效性，若文件异常则提示错误信息。接下来用户根据自己的需求，通过界面控件选择单张图像或指定文件夹作为输入源，路径信息实时显示在对应文本框中，完成后点击对应的“开始检测”按钮，调用模型进行推理，检测完成后，将检测结果显示在图像显示区域和文本信息区域。用户选择退出则系统关闭所有进程，并停止运行。




图5-1 系统运行流程图

5.2 界面设计

为了保持简洁明了，方便用户操作，本文仅设置了一个主界面。界面通过 QtDesigner 进行可视化开发，划分为左侧的参数选择区，和右侧的结果显示区，如图5-2所示。参数选择区让用户可以选择权重文件、单张图片、输入和输出文件夹，并将其路径显示在文本框中。右侧则包含了开始检测的功能，并能够显示图像，和文字版检测结果。

在左侧的参数选择区中，集成文件选择功能模块，通过四个 QPushButton 控件分别实现权重文件、单张图片、输入文件夹、输出文件夹的路径选择功能。还配套使用了 QTextBrowser 文本框，用于实时展示用户选择的文件或目录路径，

确保输入信息清晰可查。

右侧结果呈现区：上方设置两个图像显示区域，初始状态下通过 QLabel 控件分别标注“原始图像预览”与“检测结果显示”，检测完成后动态加载对应的输入图像与标注结果。中部配置“单图检测启动”和“批量检测启动”两个功能按钮，触发模型推理流程。底部采用 QTextBrowser 控件构建检测信息输出栏，以文本形式展示缺陷类别、定位坐标、置信度等详细检测结果，支持多信息行的滚动查看。

右侧的结果显示区中，上方设置两个图像显示区域，初始状态下通过 QLabel 控件分别显示“显示原始图像”和“显示检测结果”的文字，检测完成后动态加载对应的输入图像与检测结果。中间则是“开始单张图片检测”和“开始检测文件夹”两个按钮，点击可触发对应功能。最下方是一个 QTextBrowser 控件，文本形式展示缺陷类别、定位坐标、置信度等详细检测结果。



图5-2 系统界面

5.3 功能实现

5.3.1 检测参数设置

参数设置中的四个按钮均需要让用户选择对应的文件或者路径，使用了

QFileDialog 控件来完成该功能，该控件可以让用户在弹出的弹窗中自行选择文件。得到路径后，显示在旁边的 QTextBrowser 控件框中。

在选择完权重文件的路径后，会立即进行权重文件的检查，确保可以用于下面的图像检测环境，YOLO11n 中提供了 `model = YOLO(model_path)` 这一种方式，用于加载模型，`model_path` 即为模型的路径。若检验正常则在旁边的文本框中显示对应信息，错误则利用 QMessageBox 控件，弹出错误信息提示的弹窗。

5.3.2 原始图片显示

在原始图片的显示环节，如果是单张图片，在选择完后会立即调用 QPixmap 类下的 `setPixmap()` 函数进行图片显示。如果是文件夹遍历，则会在检测每张图片时分别调用 `setPixmap()` 函数进行图片显示。

5.3.3 图像检测

检测前如果是单张图片，没有放入图片时不起效，如果是文件夹遍历，先要判断是否选择了输入和输出文件夹，如果其中一个路径缺失或输入文件夹中没有图片，都会用 QMessageBox 控件，弹出弹窗，提醒用户正确选择后再检测。

检测单张图片时，使用 YOLO11n 中提供的 `model.predict()` 函数即可完成，输入为图片的路径。

检测文件夹时，会使用 QProgressDialog 控件，用进度条方式显示进度。和检测单张图片时使用的方法类似，遍历整个文件夹的图片。在检测完后会用 os 库中的 `os.makedirs()` 方法创建目录，并用 OpenCV 库将图像数组变为图像，保存在输出文件夹。

5.3.4 检测结果显示

在推理完图片后，YOLO11n 返回的结果为一个列表，其中包含了原始图像、检测框、类别等信息，用图5-3所示代码可以获取这些信息，并构建固定格式的文本，将其显示在 QTextBrowser 文本框中。

```

for result in results:
    boxes = result.bboxes.xyxy.cpu().numpy()
    scores = result.bboxes.conf.cpu().numpy()
    classes = result.bboxes.cls.cpu().numpy().astype(int)

    # 获取类别名称
    class_names = [self.model.names[cls] for cls in classes]

    # 构建检测结果文本
    result_text += "<b>检测结果: </b><br>"
    for i, (box, score, cls_name) in enumerate(zip(boxes, scores, class_names), 1):
        result_text += (
            f"{i}. 类别: {cls_name}<br>"
            f" 置信度: {score:.2f}<br>"
            f" 坐标: {box.round(2)}<br><br>" # 保留两位小数
        )

    # 在 textBrowser 中显示带格式的结果
    self.textBrowser.setHtml(result_text)

```

图5-3 检测结果显示代码

对于检测后的图片，由于是数组形式，还需要通过图5-4所示函数进行转换，才能进行输出。

```

qimage = QImage(annotated_img.data,
                 annotated_img.shape[1],
                 annotated_img.shape[0],
                 annotated_img.shape[1]*3,
                 QImage.Format_RGB888)
self.output.setPixmap(QPixmap.fromImage(qimage))

```

图5-4 检测后图片转换代码

5.4 项目生成可执行文件

在完成钢铁缺陷检测系统开发后，还要考虑到用户可能缺乏 Python 编程环境的配置，也未安装程序所需的依赖库，导致无法运行程序。为解决这一问题，就需要将项目打包成可执行文件。使用 PyInstaller 就可以满足这一需求。经其处理后的程序已经将 Python 源代码、各类第三方库以及整个运行时环境整合起来，无需额外运行环境，可直接在目标平台上独立运行。

本文的检测系统 python 文件命名为 base_ui.py，打包时只需要使用 PyInstaller

命令即可。完成后会在文件所在位置的目录下生成 `base_ui.exe` 文件，点击该文件即可运行检测系统。

5.5 项目运行测试

在点开可执行文件后，即进入检测系统，左侧栏为参数设置，可以选择图片，权重文件，输入输出文件夹，右侧为结果显示，上方可以显示原始图片和检测后的图片，下方显示文字显示结果。

开始检测前，首先要选择检测用到的算法，点击“选择权重文件”按钮后会弹出窗口，选择需要用到的模型权重文件，如图5-5所示。




图5-5 选择权重文件

如果选择的模型文件无法加载，则会弹出相应的提示，在弹窗内会指出“加载模型失败：Ran out of input”。此时必须重新回到上一步，选择正确的权重文件，如图5-6所示。



图5-6 加载模型失败

若模型权重文件选择正确，则无弹窗提示，且在按钮旁边的栏中现实已经加载的权重文件的路径，如图5-7所示。




图5-7 加载模型成功

当点击“选择图片”按钮后，弹出弹窗，在其中选择一张图片进行检测。待图片选择完毕，所选图片的路径信息便会在按钮旁边的对应框中呈现出来，而且此图片也会同步展示在图片检测这一栏目之中，如图5-8所示。




图5-8 显示原始图片

正确选择了权重文件和输入输出目录后，点击“开始单张图片检测”按钮即开始检测。在检测流程完成之后，所生成的检测图片会呈现在界面的右侧区域，与之对应的文件路径以及详细的检测结果，也会在下方的 QTextBrowser 文本框中显示，如图5-9所示。




图5-9 检测结果显示

进行一整个文件夹的检测时，必须指定输入输出文件夹路径，若其中一个未

选择就点击“开始检测文件夹”按钮，会弹出错误弹窗，提示请先选择输入/输出目录，如图5-10所示。




图5-10 输入或输出目录未选择

还考虑到了输入目录中可能没有正确放置图片，此时也会弹窗报错，如图5-11所示。




图5-11 输入目录没有图片

正确选择了权重文件和输入输出目录后，点击“开始检测文件夹”按钮即开始检测。会弹出弹窗显示此时的进度，在左下角显示正在处理图片的名称，并和单张图片检测时一样显示原图片和检测结果，如图5-12所示。




图5-12 遍历文件夹检测

当文件夹中所有图片都完成检测后，会弹出弹窗提示已经处理完成，并打开

输出文件夹，供用户查看检测完成的图像，如图5-13所示。




图5-13 完成遍历文件夹检测

5.6 本章小结

本章介绍了钢铁表面缺陷检测系统的实现与测试。基于 PyQt5 构建了用户界面，支持单图与批量检测功能，通过参数设置、结果可视化及异常处理提升易用性。利用 PyInstaller 打包为独立可执行文件，经测试验证系统功能完整、操作便捷，满足工业场景下的缺陷检测需求。

第六章 总结与展望

6.1 总结

作为钢铁生产质量管控的重要一环,钢铁缺陷检测对于保障产品品质与生产效率至关重要。利用深度学习方法可以进行自动化检测,有效提高检测速度、精度,基于此背景,本文展开了相应的研究探讨。

本文首先分析了在钢铁缺陷检测领域应用深度学习算法的必要性,随后围绕目标检测技术展开详细阐述,梳理了该技术的发展脉络和在钢铁表面缺陷检测领域的应用情况。

在此基础上,详细介绍了 YOLO11 算法的架构原理,以及注意力机制与卷积层的核心机制。研究以 YOLO11n 为基础模型展开改进:在颈部网络嵌入 CA 注意力机制,增强模型对小尺寸缺陷目标的检测能力;采用 Ghost 卷积替代传统卷积层,显著降低模型复杂度并提升推理速度。

在 PyTorch 框架下搭建了实验环境,并使用了 NEU-DET 和 GC10-DET 数据集。两种数据集包含多种缺陷类型,基本涵盖了实际需要。在 NEU-DET 数据集上进行了模型训练,通过消融实验分析准确率召回率等指标,并加入了实际的检测结果图、性能曲线、P-R 曲线和热力图这四种可视化对比方式,证明了引入改进的有效性,即保障检测精度以及维持检测速度的前提下,成功实现了模型的轻量化。为进一步验证改进模型所具备的优势,开展了同 YOLOv8n、YOLOv10n、YOLO11n 这类基准模型之间的对比实验,通过对比分析来进一步展现其在各方面性能上的表现。最后还利用 GC10-DET 数据集,证明了改进的模型具有良好的泛化性能,在其他目标检测的任务中同样具有技术先进性。

此外,研究基于 PyQt5 框架开发了钢铁表面缺陷检测系统,该系统具备单图检测与文件夹批量检测两种模式,支持模型自主切换、检测结果实时可视化标注及本地化存储功能,操作便捷且实用性较强。

从应用价值来看,该系统能够实现钢铁表面缺陷的快速检测,可以减轻相关人员的工作压力,并提高钢铁生产的工作效率,有现实意义。

在经济性层面,轻量化模型设计降低了硬件依赖,适合部署在工业现场的终

端。且人机交互界面简洁，培训和维护成本低，提供了一种高效、经济的解决方案。

6.2 展望

本文提出的改进模型和钢铁表面缺陷检测系统，虽然有一定成果，但在性能优化和系统功能拓展方面，仍存在改进空间。

在算法方面，虽然实现了轻量化与低参数数量的目标，但检测速度相比 YOLOv8n 等模型仍存在差距，在精度层面对比 Faster R-CNN 等高精度模型也尚存有可进一步提升的余地。以 NEU-DET 数据集为例，改进后的模型在 `pitted_surface`，`rolled-in_scale` 和 `crazing` 这三类目标上表现不佳，一方面是缺陷本身的问题，另一方面则是注意力机制作用已到瓶颈，且 GhostConv 机制会削弱注意力机制对精度的提高。

展望后续的研究方向，可以再针对 CA 注意力机制和 GhostConv 的配合进行调整，如调整具体引入的位置等。或者考虑引入其他改进方法，比如换用更新的注意力机制和卷积层，来实现检测速度以及识别能力的提升。选用的 NEU-DET 数据集的样本还过少，在未来工作中，还应该引入更多复杂情况下的数据，来提高模型在实际工业环境中的识别效果。

在检测系统方面，目前只有图片检测功能，与实际钢铁产线的连续在线检测存在差异，后续可以添加视频处理功能，实现动态检测。其次，还可以引入数据库等方法，将检测后的数据更好保存。未来工作中可以在这两方面继续设计检测系统，以符合实际需要。

参考文献

- [1] 吴平川,路同浚,王炎.带钢表面自动检测系统研究现状与展望[J].钢铁,2000,35(6):70-75.
- [2] 程万胜.钢板表面缺陷检测技术的研究[D].哈尔滨:哈尔滨工业大学,2008.
- [3] 南晓虎,丁雷.深度学习的典型目标检测算法综述[J].计算机应用研究,2020,37(S2):15-21.
- [4] 唐小虎. 基于深度学习的遥感目标检测与方向估计[D]. 西安:西安电子科技大学,2020.
- [5] 罗会兰,陈鸿坤.基于深度学习的目标检测研究综述[J].电子学报,2020,48(06):1230-1239.
- [6] 王永生,姬嗣愚.基于深度学习的目标检测算法综述[J].计算机与数字工程,2023,51(06):1231-1237.
- [7] Girshick R, Donahue J, Darrell T, et al. Rich Feature Hierarchies for Accurate Object Detection and Semantic Segmentation[C]Proceedings of The IEEE Conference on Computer Vision and Pattern Recognition. Columbus, OH, USA, 2014:580-587.
- [8] Girshick R. Fast R-CNN[C]Proceedings of The IEEE International Conference on Computer Vision. Santiago, Chile,2015:1440-1448.
- [9] Ren S, He K, Girshick R, et al. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks[J].IEEE Transactions on Pattern Analysis & Machine Intelligence,2017,39(6):1137-1149.
- [10] 何植仟,曹立杰. UAVAI-YOLO:无人机航拍图像的小目标检测模型[J]. 智能科学与技术学报,2024,6(2):262-271.
- [11] Redmon J, Divvala S, Girshick R, et al. You Only Look Once: Unified, Real-time Object Detection[C]Proceedings of the IEEE conference on computer vision and pattern recognition. Las Vegas, NV, USA,2016: 779-788.
- [12] Liu W, Anguelov D, Erhan D, et al. SSD: Single Shot Multibox Detector[C]Proceedings of the 14th European Conference on Computer Vision. Amsterdam, The Netherlands, 2016: 21-37.
- [13] 张鑫.基于改进 RCNN 的钢铁表面缺陷检测方法的研究与实现[D].沈阳:东北大学,2019.
- [14] Shi X, Zhou S, Tai Y, et al. An Improved Faster R-CNN for Steel Surface Defect Detection[C]2022 IEEE 24th International Workshop on Multimedia Signal Processing (MMSP), Shanghai,China,2022:1-5.
- [15] 韩强,张喆,续欣莹,等. 基于 FF R-CNN 钢材表面缺陷检测算法[J]. 太原理工大学学报

- 报,2021,52(5):754-763.
- [16] 齐继阳, 吴宇帆. Strip Steel Surface Defect Detection Algorithm Based on Improved Faster R-CNN[J]. 中国焊接（英文版）,2024,33(2):11-22
- [17] 刘宁,欧阳泽,马文源,等.钢铁零件表面缺陷检测的改进 YOLOv5-FGC 识别算法[J].制造业自动化,2024,46(12):24-33.
- [18] 周孟然,王昊男,高立鹏,等.基于 YOLOv5s-FCS 的钢材表面缺陷检测[J].科学技术与工程,2024,24(14):5901-5910.
- [19] Yang S, Xie Y, Wu J, et al. CFE-YOLOv8s: Improved YOLOv8s for Steel Surface Defect Detection[J]. Electronics, 2024, 13(14): 2771-2794.
- [20] 姚若禹,郑世玲,史怡璇,等. 基于改进 YOLOv8n 的钢材表面缺陷检测算法[J]. 聊城大学学报（自然科学版）,2025,38(2):177-189.
- [21] 邹彦艳,曹衍芬,张馨月,李志,崔世龙.基于 YOLOv8-DSG 的钢铁表面缺陷检测算法[J].吉林大学学报(信息科学版),2025,43(1):116-125
- [22] Li Z, Wei X, Hassaballah M. et al. A Deep Learning Model for Steel Surface Defect Detection[J]. Complex & Intelligent Systems. 2024,10(1):885-897.
- [23] 张艺严. 基于改进 YOLOv5的航拍图像小目标检测系统的设计与实现[D]. 石家庄:河北科技大学,2023.
- [24] 戴林华,黎远松,石睿. 基于改进 YOLOv8的带钢表面缺陷检测算法[J]. 制造技术与机床,2024,(11):139-148.
- [25] 王伟家. 面向钢铁表面缺陷的小目标检测算法研究[D]. 哈尔滨:哈尔滨工业大学,2024.
- [26] 王贞,邱杭,吴斌,等. 基于 CCG-YOLOv8的施工场景下安全帽佩戴检测[J]. 武汉理工大学学报,2024,46(6):73-80.
- [27] Hou Q, Zhou D, Feng J. Coordinate Attention for Efficient Mobile Network Design[C]Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Nashville, TN, USA,2021: 13708-13717.
- [28] 马媛.基于深度学习的细粒度果品品种检测算法研究与实现[D]. 咸阳:西北农林科技大学,2023.
- [29] Han K, Wang Y, Tian Q, et al. GhostNet: More Features from Cheap Operations[C]Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Seattle, WA, USA, 2020: 1577-1586.

- [30] He Y, Song K C, Meng Q G, et al. An End-to-End Steel Surface Defect Detection Approach via Fusing Multiple Hierarchical Features [J]. IEEE Transactions on Instrumentation and Measurement, 2019, 69(4): 1493-1504.
- [31] Lv X M, Duan F J, Jiang J J, et al. Deep Metallic Surface Defect Detection: The new benchmark and detection network[J]. Sensors, 2020, 20(6): 1562.
- [32] 蔡汪洋. 基于 Yolov8s 的交通标志检测方法改进[J]. 计算机科学与应用, 2024, 14(10): 33-43.
- [33] 徐壮壮. 基于深度学习的疲劳驾驶检测算法研究与设计[D]. 徐州: 中国矿业大学, 2023.

致谢

时光荏苒，大学四年的求学生涯如白驹过隙，在这即将挥别校园的时刻，我的毕业论文工作也接近尾声。值此之际，向所有给予我帮助与支持的师长、家人和朋友致以最诚挚的谢意。

首先，我由衷的感谢肖迪老师，本课题从选题的确定、研究框架的搭建到实验的开展、论文的撰写与修改，都是在肖老师的指导下完成的。肖老师在毕业设计期间，给我提供了很多宝贵的意见和帮助，让我得以克服重重困难，顺利完成论文。

同时，我也要感谢四年来所有为我授课的老师，你们在课堂上倾囊相授，课堂后为我答疑解惑，为我传授了专业知识。老师们的辛勤付出，我将永远铭记于心。

其次，感谢我的家人，对我的学业、生活方面的全力支持，你们的陪伴和支持，让我能够顺利度过这四年大学时光。

最后，我要感谢一同走过大学时光的同学们，尤其是朝夕相处的舍友们。我们一起学习，一起进步，四年的相处，我们不仅是彼此学业上的伙伴，更是生活中的挚友，你们的陪伴让这四年的时间成为我人生最美好的回忆。

毕业是人生旅途的新的起点。未来，我将带着这份感恩之心在新的征程中继续勇敢前行，不负青春，不负韶华。

再次向所有关心、支持和帮助过我的人致以最诚挚的感谢！