

K-Nearest Neighbors (K最近邻)

- 一般用于分类问题

案例:

已知数据 $X = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} = \begin{pmatrix} x_{11} & x_{12} & \dots & x_{1d} \\ x_{21} & x_{22} & \dots & x_{2d} \\ \vdots & \vdots & & \vdots \\ x_{n1} & x_{n2} & \dots & x_{nd} \end{pmatrix}$

x_0 - 1 $\times$ 数据集

对应的标签为 $y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}$, $y_i \in \{1, 2, 3, \dots, C\}$ 其中 $i=1, \dots, n$.

判断输入数据 x_0 的类别, 其中 $x_0 = (x_{01} \ x_{02} \ \dots \ x_{0d})$

KNN 算法:

1. 计算 x_0 与 X 中每个向量的距离 (欧氏距离 $d(u, v) = \|u - v\|_2 = \sqrt{\sum_{i=1}^d (u_i - v_i)^2}$)

$$\text{dist} = [\|x_0 - x_1\|_2, \|x_0 - x_2\|_2, \dots, \|x_0 - x_n\|_2]$$


2. 从 dist 中取前 K 小的元素, 说明 x_0 与这 K 个元素对应的向量距离最近
 K 个最近向量的标签为: $c_1, c_2, \dots, c_K \in \{1, 2, \dots, C\}$

这 K 个标签进行投票, 得票多的标签即为 x_0 的标签。

如果有平票可以随机选择一个。

可视化解释

K Nearest Neighbors



如何同时计算多个数据类别？ t_i X
T个数据

计算 $t_1, t_2, \dots, t_T$ 和 X 的距离，其中 $t_i = (t_{i1}, t_{i2}, \dots, t_{id})$ $1 \leq i \leq T$

$$\text{同上可知 } \text{dist}(t_1, X) = [\|t_1 - x_1\|_2, \|t_1 - x_2\|_2, \dots, \|t_1 - x_n\|_2]$$

$$\text{dist}(t_2, X) = [\|t_2 - x_1\|_2, \|t_2 - x_2\|_2, \dots, \|t_2 - x_n\|_2]$$

$\vdots$

$$\text{dist}(t_T, X) = [\|t_T - x_1\|_2, \|t_T - x_2\|_2, \dots, \|t_T - x_n\|_2]$$

T个数据与X

$$\text{dist} = \begin{pmatrix} \text{dist}(t_1, X) \\ \text{dist}(t_2, X) \\ \vdots \\ \text{dist}(t_T, X) \end{pmatrix} = \begin{pmatrix} \|t_1 - x_1\|_2, \|t_1 - x_2\|_2, \dots, \|t_1 - x_n\|_2 \\ \|t_2 - x_1\|_2, \|t_2 - x_2\|_2, \dots, \|t_2 - x_n\|_2 \\ \vdots \\ \|t_T - x_1\|_2, \|t_T - x_2\|_2, \dots, \|t_T - x_n\|_2 \end{pmatrix}$$

$$\text{记 } \text{dist}^2 = \begin{pmatrix} \|t_1 - x_1\|_2^2, \|t_1 - x_2\|_2^2, \dots, \|t_1 - x_n\|_2^2 \\ \|t_2 - x_1\|_2^2, \|t_2 - x_2\|_2^2, \dots, \|t_2 - x_n\|_2^2 \\ \vdots \\ \|t_T - x_1\|_2^2, \|t_T - x_2\|_2^2, \dots, \|t_T - x_n\|_2^2 \end{pmatrix}$$

$$= \begin{pmatrix} \|t_1\|_2^2 + \|x_1\|_2^2 - 2t_1 \cdot x_1^T, \|t_1\|_2^2 + \|x_2\|_2^2 - 2t_1 \cdot x_2^T, \dots, \|t_1\|_2^2 + \|x_n\|_2^2 - 2t_1 \cdot x_n^T \\ \|t_2\|_2^2 + \|x_1\|_2^2 - 2t_2 \cdot x_1^T, \|t_2\|_2^2 + \|x_2\|_2^2 - 2t_2 \cdot x_2^T, \dots, \|t_2\|_2^2 + \|x_n\|_2^2 - 2t_2 \cdot x_n^T \\ \vdots \\ \|t_T\|_2^2 + \|x_1\|_2^2 - 2t_T \cdot x_1^T, \|t_T\|_2^2 + \|x_2\|_2^2 - 2t_T \cdot x_2^T, \dots, \|t_T\|_2^2 + \|x_n\|_2^2 - 2t_T \cdot x_n^T \end{pmatrix}$$

$$= \begin{pmatrix} \|t_1\|_2^2 & \|t_1\|_2^2 & \dots & \|t_1\|_2^2 \\ \|t_2\|_2^2 & \|t_2\|_2^2 & \dots & \|t_2\|_2^2 \\ \vdots & \vdots & & \vdots \\ \|t_T\|_2^2 & \|t_T\|_2^2 & \dots & \|t_T\|_2^2 \end{pmatrix}_{T \times n} + \begin{pmatrix} \|x_1\|_2^2 & \|x_2\|_2^2 & \dots & \|x_n\|_2^2 \\ \|x_1\|_2^2 & \|x_2\|_2^2 & \dots & \|x_n\|_2^2 \\ \vdots & \vdots & & \vdots \\ \|x_1\|_2^2 & \|x_2\|_2^2 & \dots & \|x_n\|_2^2 \end{pmatrix}_{T \times n} - \begin{pmatrix} 2t_1 \cdot x_1^T & 2t_1 \cdot x_2^T & \dots & 2t_1 \cdot x_n^T \\ 2t_2 \cdot x_1^T & 2t_2 \cdot x_2^T & \dots & 2t_2 \cdot x_n^T \\ \vdots & \vdots & & \vdots \\ 2t_T \cdot x_1^T & 2t_T \cdot x_2^T & \dots & 2t_T \cdot x_n^T \end{pmatrix}$$

(broadcast)
广播机制

$$= \begin{pmatrix} \|t_1\|_2^2 \\ \|t_2\|_2^2 \\ \vdots \\ \|t_T\|_2^2 \end{pmatrix}_{T \times 1} + \begin{pmatrix} \|x_1\|_2^2 & \|x_2\|_2^2 & \dots & \|x_n\|_2^2 \end{pmatrix}_{1 \times n} - 2 \begin{pmatrix} t_1 \\ t_2 \\ \vdots \\ t_T \end{pmatrix}_{T \times d} \begin{pmatrix} x_1^T & x_2^T & \dots & x_n^T \end{pmatrix}_{d \times n}$$